BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

TM 3 - TEXT MINING

1. **Lakukan seluruh percobaan pada modul ini dan berikan analisis yang kalian temukan**

Sintaks

```
text = "In Brazil they drive on the right-hand side of the road. has a large coastline on the eastern side of South America"

token = word_tokenize(text)

token
```

Output

```
['In',
 'Brazil',
 'they',
 'drive',
 'on',
 'the',
 'right-hand',
 'side',
 'of',
 'the',
 'road',
 '.',
 'has',
 'a',
 'large',
 'coastline',
 'on',
 'the',
 'eastern',
 'side',
 'of',
 'South',
 'America']
```

Penjelasan

Kode ini menghitung frekuensi atau jumlah kemunculan setiap token dalam teks. FreqDist membuat objek yang memetakan setiap kata dengan jumlah kemunculannya. Fungsi .most_common(10) kemudian mengambil 10 kata dengan frekuensi tertinggi. Hasilnya divisualisasikan menggunakan diagram batang.

Interpretasi: Diagram batang menunjukkan bahwa kata-kata seperti "the", "on", dan "side" adalah yang paling sering muncul. Kata-kata umum seperti ini seringkali tidak memiliki makna kontekstual yang signifikan. Ini menunjukkan pentingnya langkah selanjutnya, yaitu stopword removal, untuk menyaring kata-kata umum dan fokus pada kata-kata yang lebih bermakna.

Fdist

BAB	: IV (4)
NAMA	: FAIZ IQBAL I'TISHOM
NIM	: 164231059
TGL PRAKTIKUM	: 9 September 2025

Sintaks
fdist = FreqDist(token) fdist fdist = FreqDist(token) fdist1 = fdist.most_common(10) fdist1
Output
FreqDist({'the': 3, 'on': 2, 'side': 2, 'of': 2, 'In': 1, 'Brazil': 1, 'they': 1, 'drive': 1, 'right-hand': 1, 'road': 1, ...}) [('the', 3), ('on', 2), ('side', 2), ('of', 2), ('In', 1), ('Brazil', 1), ('they', 1), ('drive', 1), ('right-hand', 1), ('road', 1)]
Penjelasan
Sintaks
df_freq_tokens = pd.DataFrame(fdist1, columns=['Word', 'Frequency']) df_freq_tokens.set_index('Word', inplace=True) df_freq_tokens.plot(kind='bar', legend=False) plt.title('10 Kata Paling Umum') plt.ylabel('Frekuensi') plt.xlabel('Kata') plt.show()
Output

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

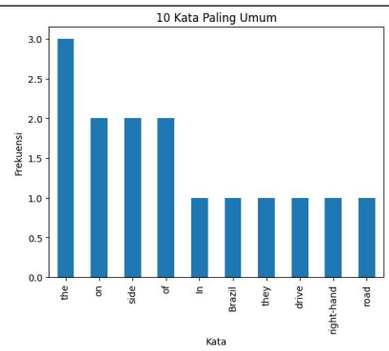

Penjelasan

Kode ini menghitung frekuensi atau jumlah kemunculan setiap token dalam teks. FreqDist membuat objek yang memetakan setiap kata dengan jumlah kemunculannya. Fungsi .most_common(10) kemudian mengambil 10 kata dengan frekuensi tertinggi. Hasilnya divisualisasikan menggunakan diagram batang.

Interpretasi: Diagram batang menunjukkan bahwa kata-kata seperti "the", "on", dan "side" adalah yang paling sering muncul. Kata-kata umum seperti ini seringkali tidak memiliki makna kontekstual yang signifikan. Ini menunjukkan pentingnya langkah selanjutnya, yaitu stopword removal, untuk menyaring kata-kata umum dan fokus pada kata-kata yang lebih bermakna.

Stopword

Sintaks

```
a = set(stopwords.words('english'))

text = "Cristiano Ronaldo was born on February 5, 1985, in Funchal, Madeira, Portugal."

text1 = word_tokenize(text.lower())

print(text1)

stopwords = [x for x in text1 if x not in a]

print(stopwords)
```

Output

```
['cristiano', 'ronaldo', 'was', 'born', 'on', 'february', '5', ',', '1985', ',', 'in', 'funchal', ',',
'madeira', ',', 'portugal', '.']

['cristiano', 'ronaldo', 'born', 'february', '5', ',', '1985', ',', 'funchal', ',', 'madeira', ',',
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

'portugal', '.']
Penjelasan
Stopwords adalah kata-kata umum yang sering muncul namun biasanya diabaikan dalam analisis teks (contoh: "on", "in", "was", "the"). Kode ini memuat daftar stopwords bahasa Inggris dari NLTK, kemudian membuat daftar baru yang hanya berisi token-token yang tidak ada dalam daftar stopwords tersebut. Interpretasi: Setelah proses stopword removal, token yang tersisa adalah kata-kata yang lebih esensial dan informatif seperti 'cristiano', 'ronaldo', 'born', 'funchal', dan 'portugal'. Proses ini membantu mengurangi "noise" dalam data dan membuat analisis lebih fokus pada konten utama teks.

Steaming

Sintaks

S = 'presumably I would like to Multiply my provision, saying that without crying'
 	
print('Sentence: ',S)
 	
stemmer_list = [LancasterStemmer, PorterStemmer, SnowballStemmer]
 	
names = ['Lancaster' , 'Porter', 'SnowBall']
 	
for stemmer_name, stem in zip(names, stemmer_list):
 	
  if stemmer_name == 'SnowBall':
 	
  st = stem('english')
 	
  else:
 	
  st = stem()
 	
  print(stemmer_name, ': ', ' '.join(st.stem(s) for s in S.split()))

Output
Sentence: presumably I would like to Multiply my provision, saying that without crying Lancaster : presum i would lik to multiply my provision, say that without cry

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

Porter : presum i would like to multipli my provision, say that without cri SnowBall : presum i would like to multipli my provision, say that without cri
Penjelasan
Stemming adalah proses untuk mengubah kata ke bentuk dasarnya (stem atau akar kata) dengan cara memotong imbuhan di akhir atau awal kata. Kode ini membandingkan tiga algoritma stemming yang berbeda: Lancaster, Porter, dan Snowball. Interpretasi: Setiap algoritma menghasilkan output yang sedikit berbeda. Misalnya, kata "crying" diubah menjadi "cry" oleh Lancaster, namun menjadi "cri" oleh Porter dan Snowball. Stemming berguna untuk mengelompokkan kata-kata yang memiliki makna serupa (misal: "multiply" dan "multipli"), meskipun hasilnya tidak selalu merupakan kata yang valid secara tata bahasa.

Lemmatization

Sintaks
lemmatizer = WordNetLemmatizer() print("rocks :", lemmatizer.lemmatize("rocks")) print("corpora :", lemmatizer.lemmatize("corpora"))
Output
rocks : rock corpora : corpus
Penjelasan
Lemmatization mirip dengan stemming, yaitu mengubah kata ke bentuk dasarnya, namun prosesnya lebih canggih karena mempertimbangkan kaidah morfologi dan kamus. Hasilnya adalah bentuk dasar yang valid secara leksikal, yang disebut lemma. Interpretasi: Berbeda dengan stemming, lemmatization menghasilkan kata yang benar-benar ada dalam kamus, seperti mengubah "rocks" menjadi "rock" dan "corpora" menjadi "corpus". Metode ini lebih akurat secara linguistik dibandingkan stemming, meskipun prosesnya lebih lambat.

Tokenization

Sintaks
S = 'I am currently learning NLP in English, but if possible I want to know NLP in

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
Indonesian language too'

tokens = word_tokenize(S)

print(pos_tag(tokens))



T = "Hello, Mr. Man. He smiled!! This, i.e. that, is it."

sentence_tokens = TextBlob(T).sentences

print(TextBlob(T).words)

print([str(sent) for sent in sentence_tokens])
```

Output

```
[('I', 'PRP'), ('am', 'VBP'), ('currently', 'RB'), ('learning', 'VBG'), ('NLP', 'NNP'), ('in', 'IN'), ('English', 'NNP'), (',', ','), ('but', 'CC'), ('if', 'IN'), ('possible', 'JJ'), ('I', 'PRP'), ('want', 'VBP'), ('to', 'TO'), ('know', 'VB'), ('NLP', 'NNP'), ('in', 'IN'), ('Indonesian', 'JJ'), ('language', 'NN'), ('too', 'RB')]



['Hello', 'Mr', 'Man', 'He', 'smiled', 'This', 'i.e', 'that', 'is', 'it']

['Hello, Mr. Man.', 'He smiled!!', 'This, i.e.', 'that, is it.']
```

Penjelasan

Kode ini menunjukkan dua kemampuan lanjutan. Pertama, pos_tag (Part-of-Speech Tagging) yang memberikan label kelas kata (seperti NNP untuk kata benda, VBG untuk kata kerja) pada setiap token. Kedua, TextBlob digunakan untuk memecah teks menjadi token kata (.words) dan token kalimat (.sentences).

Interpretasi: POS Tagging sangat penting untuk memahami struktur gramatikal kalimat. Sementara itu, kemampuan TextBlob untuk memisahkan kalimat secara akurat sangat berguna saat menganalisis teks yang terdiri dari banyak kalimat.

2. TextBlob

Sintaks

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
print("Stem: ", Word('running').stem())

print("Lemmatize: ", Word('went').lemmatize('v'))



for word, pos in TextBlob(T).tags:

    print(word, pos, end=', ')
```

Output

```
Stem:  run

Lemmatize:  go

Hello NNP, Mr. NNP, Man NNP, He PRP, smiled VBD, This DT, i.e NN, that DT, is VBZ, it PRP,
```

Penjelasan

Library TextBlob menyediakan antarmuka yang lebih sederhana untuk melakukan operasi NLP. Kode ini menunjukkan cara melakukan stemming (Word('running').stem()) dan lemmatization (Word('went').lemmatize('v')) dengan mudah.

Interpretasi: TextBlob menyederhanakan proses NLP. Hasilnya menunjukkan bahwa ia dapat melakukan stemming ("running" -> "run") dan lemmatization ("went" -> "go") dengan benar untuk bahasa Inggris. Namun, fungsionalitasnya untuk bahasa Indonesia sangat terbatas.

3. Sastrawi

Sintaks

```
factory = StopWordRemoverFactory()

stopword = factory.create_stop_word_remover()

kalimat = "Andi kerap melakukan transaksi rutin secara daring atau online. Menurut Andi belanja online lebih praktis & murah."

stop = stopword.remove(kalimat.lower())

print(stop)
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
stemmer = StemmerFactory().create_stemmer()

I = "perayaan itu berbarengan dengan saat kita bepergian ke Makassar"

print(stemmer.stem(I))

print(stemmer.stem("Perayaan Bepergian Menyuarakan"))
```

Output

andi kerap melakukan transaksi rutin daring online. andi belanja online lebih praktis & murah.

raya itu bareng dengan saat kita pergi ke makassar

raya pergi suara

Penjelasan

Sastrawi adalah library yang dirancang khusus untuk NLP Bahasa Indonesia. Kode ini mendemonstrasikan dua fungsi utamanya: menghilangkan stopwords Bahasa Indonesia (stopword.remove()) dan melakukan stemming untuk kata-kata berimbuhan dalam Bahasa Indonesia (stemmer.stem()).

Interpretasi: Hasilnya menunjukkan keunggulan Sastrawi untuk teks Bahasa Indonesia. Ia berhasil menghilangkan kata-kata seperti "kerap", "secara", "atau". Lebih penting lagi, ia mampu mengubah kata berimbuhan ke bentuk dasarnya dengan akurat, seperti "perayaan" menjadi "raya" dan "bepergian" menjadi "pergi".

Percobaan Visualiasi dengan Wordcloud

Sintaks

```
dummy_string = """

Python for data science is a powerful tool for data analysis and machine learning.

Text mining and data visualization are key parts of data science.

Machine learning with Python helps in building great models from data.
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
Data analysis provides deep insights and drives business decisions.

Learning data science opens up many career opportunities.

"""



wordcloud = WordCloud(width=800, height=400,
background_color="white").generate(dummy_string)



plt.figure(figsize=(10, 5))

plt.imshow(wordcloud, interpolation='bilinear')

plt.axis("off")

plt.show()
```

Output

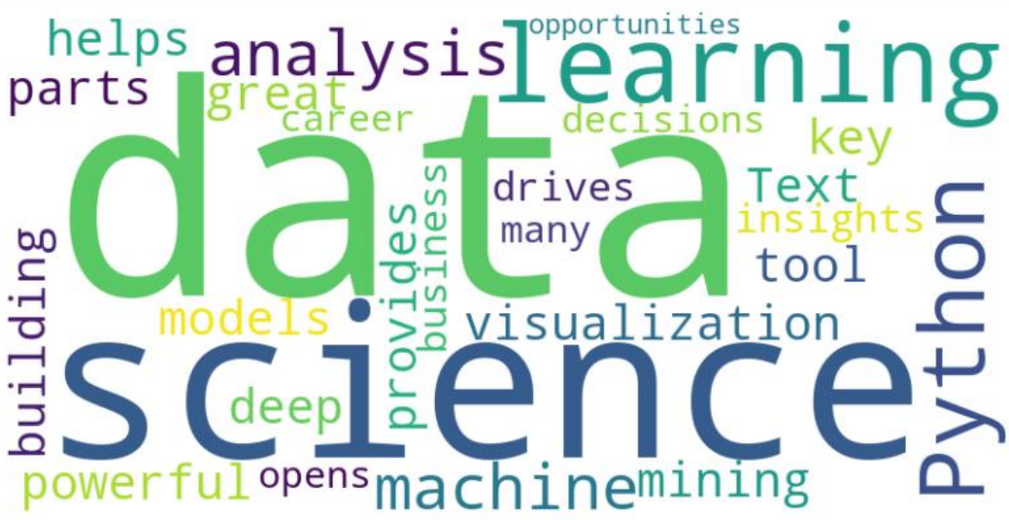

Penjelasan

Word Cloud (awan kata) adalah visualisasi yang menampilkan kata-kata dari sebuah teks, di mana ukuran setiap kata merepresentasikan frekuensinya. Kode ini menghasilkan word cloud dari teks yang diberikan.

Interpretasi: Visualisasi ini memberikan gambaran cepat tentang topik utama dari sebuah

BAB	: IV (4)
NAMA	: FAIZ IQBAL I'TISHOM
NIM	: 164231059
TGL PRAKTIKUM	: 9 September 2025

teks. Kata-kata yang paling besar, seperti "data" dan "science", adalah kata yang paling sering muncul dan menjadi tema sentral dari kumpulan teks tersebut.

4. Clustering

Sintaks

```
try:
    stopwords.words('english')
except LookupError:
    import nltk
    print("Mengunduh data NLTK...")
    nltk.download('stopwords')
    nltk.download('punkt')


stop_words = set(stopwords.words('english'))
src_name = "20newsgroup.pckl"


try:
    with open(src_name, 'rb') as fin:
        data = pickle.load(fin)
    docs = [doc for doc in data.data]
    label = data.target
    print(f"☑ Berhasil memuat {len(docs)} dokumen.")
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
except FileNotFoundError:

    print(f"❌ Error: File tidak ditemukan di '{src_name}'")

    docs = []



if docs:

    def preprocess(doc):

        tokens = word_tokenize(doc)

        cleaned_tokens = [t.lower() for t in tokens if t.isalpha() and t.lower() not in
stop_words]

        return " ".join(cleaned_tokens)



    docs_clear = [preprocess(d) for d in docs]

    print('✅ Pra-pemrosesan selesai!')



    tfidf_vectorizer = TfidfVectorizer(max_df=0.95, min_df=2)

    X = tfidf_vectorizer.fit_transform(docs_clear)

    print("Bentuk Matriks TF-IDF (dokumen, fitur):", X.shape)



    k = 3

    seed = 99

    print("\nMelakukan reduksi dimensi dengan TruncatedSVD...")
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
svd = TruncatedSVD(n_components=2, random_state=seed)

X_reduced = svd.fit_transform(X)

print("☑ Reduksi dimensi selesai.")


print("\nMenjalankan K-Means...")

km = cluster.KMeans(n_clusters=k, init='random', n_init=10, random_state=seed)

C_km = km.fit_predict(X_reduced)


print("Menjalankan K-Means++...")

kmPP = cluster.KMeans(n_clusters=k, init='k-means++', n_init=10,
random_state=seed)

C_kmpp = kmPP.fit_predict(X_reduced)


print("Menjalankan DBSCAN...")

dbscan = cluster.DBSCAN(eps=0.1)

C_db = dbscan.fit_predict(X_reduced)


df_plot = pd.DataFrame(X_reduced, columns=['Component 1', 'Component 2'])

df_plot['K-Means'] = C_km

df_plot['K-Means++'] = C_kmpp

df_plot['DBSCAN'] = C_db
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
print("\nMembuat visualisasi cluster...")

fig, (ax1, ax2, ax3) = plt.subplots(1, 3, figsize=(24, 7), sharey=True)

fig.suptitle('Perbandingan Hasil Clustering setelah Reduksi Dimensi', fontsize=20)


sns.scatterplot(data=df_plot, x='Component 1', y='Component 2', hue='K-Means',
palette='viridis', ax=ax1, s=30, alpha=0.7)

ax1.set_title('K-Means Clustering', fontsize=16)


sns.scatterplot(data=df_plot, x='Component 1', y='Component 2', hue='K-Means++',
palette='viridis', ax=ax2, s=30, alpha=0.7)

ax2.set_title('K-Means++ Clustering', fontsize=16)


sns.scatterplot(data=df_plot, x='Component 1', y='Component 2', hue='DBSCAN',
palette='viridis', ax=ax3, s=30, alpha=0.7)

ax3.set_title('DBSCAN Clustering', fontsize=16)


plt.tight_layout(rect=[0, 0.03, 1, 0.95])

plt.show()
```

Output

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
...  ✅ Berhasil memuat 1653 dokumen.
     ✅ Pra-pemrosesan selesai!
     Bentuk Matriks TF-IDF (dokumen, fitur): (1653, 9604)

     Melakukan reduksi dimensi dengan TruncatedSVD...
     ✅ Reduksi dimensi selesai.

     Menjalankan K-Means...
     Menjalankan K-Means++...
     Menjalankan DBSCAN...

     Membuat visualisasi cluster...
```

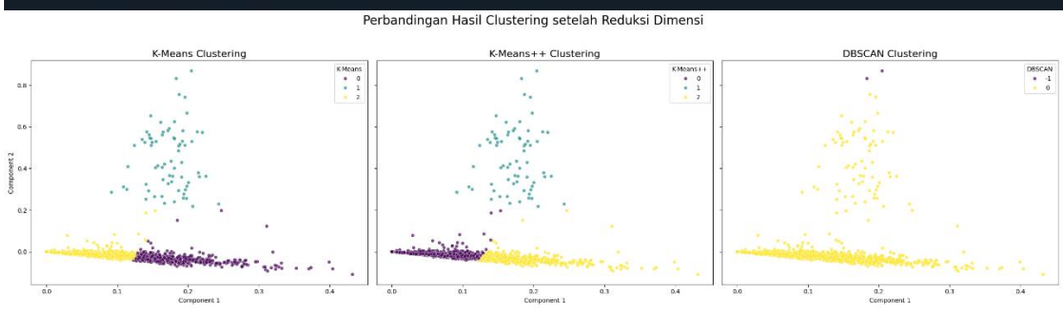

Penjelasan

Proses ini dimulai dengan preprocessing teks (menghilangkan stopwords, tokenisasi), lalu mengubah teks menjadi vektor numerik menggunakan TF-IDF. Setelah itu, dimensi data dikurangi menggunakan TruncatedSVD agar bisa divisualisasikan dalam 2D. Terakhir, tiga algoritma clustering (K-Means, K-Means++, DBSCAN) diterapkan pada data untuk mengelompokkan dokumen.

Interpretasi: Visualisasi perbandingan menunjukkan bagaimana setiap algoritma mengelompokkan dokumen. K-Means dan K-Means++ berhasil membagi data menjadi 3 kelompok yang relatif jelas. DBSCAN, yang berbasis kepadatan, mengidentifikasi beberapa titik sebagai noise (label -1) dan mengelompokkan sisanya. Ini adalah langkah eksplorasi untuk memahami struktur pengelompokan alami dalam data.

Evaluasi Model

Sintaks

```
from sklearn.metrics import silhouette_score as siluet

C = [C_km, C_kmpp, C_db]
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
for res in C:

    print(siluet(X,res), end = ',')


from sklearn.metrics.cluster import homogeneity_score as purity

for res in C:

    print(purity(label, res), end=', ')

print()



from sklearn.metrics import normalized_mutual_info_score as NMI

for res in C:

    print(NMI(label, res), end=', ')

print()
```

Output

Silhouette

```
...   0.010730506482804368,0.010829360590806974,0.008818867561058671,
```

Purity

```
...   0.04139015100384187, 0.04138506411887602, 0.0011348284849938609,
```

NMI

```
...   0.04719417638843329, 0.04723069045282428, 0.0022504221723698803,
```

Penjelasan

Kode ini melakukan evaluasi kuantitatif terhadap hasil clustering menggunakan tiga metrik: Silhouette Score (mengukur seberapa baik sebuah objek berada di dalam clusternya sendiri dibandingkan cluster lain), Purity/Homogeneity (mengukur apakah setiap cluster hanya berisi anggota dari satu kelas asli), dan

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

NMI (Normalized Mutual Information).

Interpretasi: Angka-angka menunjukkan bahwa K-Means dan K-Means++ memiliki skor yang jauh lebih baik daripada DBSCAN di semua metrik. Ini secara numerik mengkonfirmasi bahwa untuk dataset ini, K-Means menghasilkan pengelompokan yang lebih koheren dan akurat.

2. **Jelaskan perbedaan hasil dari Preprocessing menggunakan NLTK, TextBlob dan Sastrawi dan berikan contohnya.**

Sintaks

```
teks = "Perkembangan teknologi pembelajaran yang pesat memudahkan para pelajar
dalam mengerjakan tugas-tugas mereka."

print(f"Teks Asli: \n{teks}\n")

print("-" * 50)



print("1. Hasil dari NLTK:")

teks_nltk = teks.lower()

tokens_nltk = word_tokenize(teks_nltk)



list_stopwords_nltk = set(nltk_stopwords.words('indonesian'))

tokens_tanpa_stopwords_nltk = [t for t in tokens_nltk if t not in list_stopwords_nltk and
t.isalpha()]



stemmer_en = PorterStemmer()

tokens_stemmed_nltk = [stemmer_en.stem(t) for t in tokens_tanpa_stopwords_nltk]
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
print(f"   - Tokenisasi & Stopword: {tokens_tanpa_stopwords_nltk}")

print(f"   - Hasil Stemming (SALAH): {tokens_stemmed_nltk}")

print("   - Penjelasan: NLTK bisa tokenisasi dengan baik, tapi stemmer bawaannya
(Porter) untuk B. Inggris sehingga GAGAL total mengubah kata ke bentuk dasar
Indonesia.\n")

print("-" * 50)



print("2. Hasil dari TextBlob:")

blob = TextBlob(teks)



tokens_tb = blob.words.lower()



print(f"   - Tokenisasi: {tokens_tb}")

print("   - Hasil Stemming: Tidak tersedia untuk Bahasa Indonesia.")

print("   - Penjelasan: TextBlob sangat mudah untuk tokenisasi, tapi tidak menyediakan
fungsionalitas stemming atau stopword removal yang akurat untuk Bahasa Indonesia.\n")

print("-" * 50)



print("3. Hasil dari Sastrawi:")

teks_sastrawi = teks.lower()



stopword_factory = StopWordRemoverFactory()
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
remover = stopword_factory.create_stop_word_remover()

teks_tanpa_stopwords_sastrawi = remover.remove(teks_sastrawi)



stemmer_factory = StemmerFactory()

stemmer_id = stemmer_factory.create_stemmer()

teks_stemmed_sastrawi = stemmer_id.stem(teks_tanpa_stopwords_sastrawi)



tokens_sastrawi = word_tokenize(teks_stemmed_sastrawi)



print(f"   - Teks setelah Stopword: {teks_tanpa_stopwords_sastrawi}")

print(f"   - Teks setelah Stemming: {teks_stemmed_sastrawi}")

print(f"   - Hasil Token Akhir: {tokens_sastrawi}")

print("   - Penjelasan: Sastrawi berhasil menghilangkan stopwords dan mengubah kata berimbuhan ke bentuk dasarnya (misal: 'perkembangan' -> 'kembang', 'pembelajaran' -> 'ajar', 'memudahkan' -> 'mudah', 'mengerjakan' -> 'kerja').\n")
```

Output

```
...   Teks Asli:
      Perkembangan teknologi pembelajaran yang pesat memudahkan para pelajar dalam mengerjakan tugas-tugas mereka.

      ----------------------------------------------------
      1. Hasil dari NLTK:
         - Tokenisasi & Stopword: ['perkembangan', 'teknologi', 'pembelajaran', 'pesat', 'memudahkan', 'pelajar']
         - Hasil Stemming (SALAH): ['perkembangan', 'teknolog', 'pembelajaran', 'pesat', 'memudahkan', 'pelajar']
         - Penjelasan: NLTK bisa tokenisasi dengan baik, tapi stemmer bawaannya (Porter) untuk B. Inggris sehingga GAGAL total mengubah kata ke bentuk dasar Indonesia.

      ----------------------------------------------------
      2. Hasil dari TextBlob:
         - Tokenisasi: ['perkembangan', 'teknologi', 'pembelajaran', 'yang', 'pesat', 'memudahkan', 'para', 'pelajar', 'dalam', 'mengerjakan', 'tugas-tugas', 'mereka']
         - Hasil Stemming: Tidak tersedia untuk Bahasa Indonesia.
         - Penjelasan: TextBlob sangat mudah untuk tokenisasi, tapi tidak menyediakan fungsionalitas stemming atau stopword removal yang akurat untuk Bahasa Indonesia.

      ----------------------------------------------------
      3. Hasil dari Sastrawi:
         - Teks setelah Stopword: perkembangan teknologi pembelajaran pesat memudahkan pelajar mengerjakan tugas-tugas mereka.
         - Teks setelah Stemming: kembang teknologi ajar pesat mudah ajar kerja tugas mereka
         - Hasil Token Akhir: ['kembang', 'teknologi', 'ajar', 'pesat', 'mudah', 'ajar', 'kerja', 'tugas', 'mereka']
         - Penjelasan: Sastrawi berhasil menghilangkan stopwords dan mengubah kata berimbuhan ke bentuk dasarnya (misal: 'perkembangan' -> 'kembang', 'pembelajaran' -> 'ajar', 'memudahkan' -> 'mudah', 'mengerjakan
```

Penjelasan

Tabel ini membandingkan hasil preprocessing teks Bahasa Indonesia menggunakan tiga library berbeda pada kalimat yang sama.

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

Interpretasi:

NLTK: Berhasil melakukan tokenisasi dan stopword removal, tetapi gagal total dalam stemming karena stemmer bawaannya (Porter) dirancang untuk Bahasa Inggris.

TextBlob: Mudah digunakan untuk tokenisasi, tetapi tidak memiliki fitur stemming dan stopword removal untuk Bahasa Indonesia.

Sastrawi: Menjadi pilihan terbaik karena dirancang khusus untuk Bahasa Indonesia. Ia berhasil melakukan stopword removal dan stemming dengan sangat baik, mengubah "perkembangan" menjadi "kembang" dan "mengerjakan" menjadi "kerja". Ini membuktikan pentingnya menggunakan tools yang sesuai dengan bahasa teks yang dianalisis.

3. **Crawling dataset dengan total 10 pada berbagai judul artikel Wikipedia berdasarkan daftar topik sesuai dengan akhiran nim dan wajib dalam topik yang sama. 09: TV Indonesia: https://id.wikipedia.org/wiki/Daftar_stasiun_televisi_di_Indonesia**

Sintaks

```
!pip install wikipedia -qqq

import wikipedia

import os



wikipedia.set_lang("id")

topics = [

    "RCTI",

    "SCTV",

    "Indosiar",

    "antv",
```

BAB : IV (4)
NAMA : FAIZ IQBAL I'TISHOM
NIM : 164231059
TGL PRAKTIKUM : 9 September 2025

```
    "Metro TV",
    "tvOne",
    "Trans TV",
    "Trans7",
    "GTV (Indonesia)",
    "Kompas TV"
]

output_folder = "wiki_articles_tv_indonesia"
os.makedirs(output_folder, exist_ok=True)

def crawl_and_save(topics):
    for topic in topics:
        try:
            page = wikipedia.page(topic, auto_suggest=False)
            content = page.content

            filename = f"{topic.replace(' ', '_').replace('/', '')}.txt"
            filepath = os.path.join(output_folder, filename)
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
        with open(filepath, "w", encoding="utf-8") as f:

            f.write(content)

        print(f"✅ Sukses menyimpan artikel: {filepath}")

    except wikipedia.exceptions.PageError:

        print(f"❌ Halaman '{topic}' tidak ditemukan.")

    except wikipedia.exceptions.DisambiguationError as e:

        print(f"⚠️ Error Disambiguasi di '{topic}'. Coba nama yang lebih spesifik dari pilihan ini: {e.options}")

crawl_and_save(topics)
```

Output

```
Preparing metadata (setup.py) ... done

Building wheel for wikipedia (setup.py) ... done
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

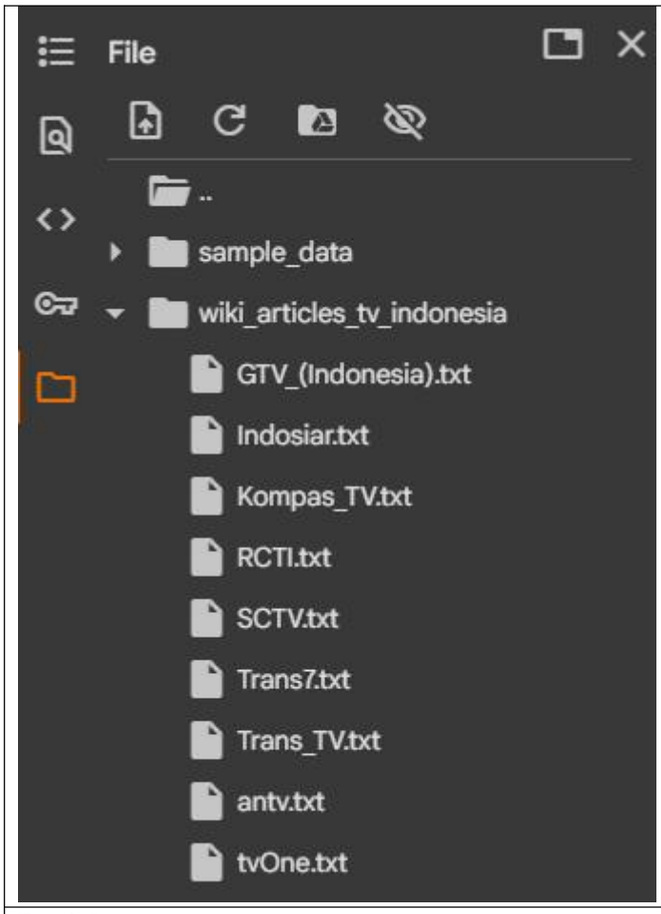

Penjelasan

Kode ini menggunakan library wikipedia untuk secara otomatis mengunduh konten dari 10 halaman Wikipedia yang berbeda sesuai dengan daftar topik (stasiun TV Indonesia). Setiap artikel kemudian disimpan sebagai file .txt terpisah di dalam sebuah folder.

Interpretasi: Ini adalah langkah pengumpulan data yang efisien. Dengan cara ini, kita berhasil membuat sebuah corpus (kumpulan dokumen) khusus yang siap untuk dianalisis lebih lanjut, tanpa perlu menyalin-tempel secara manual.

4. **Lakukan preprocessing yang sudah diajarkan pada modul ini (menggunakan salah satu library saja).**

Subset Data & Pre-processing

Sintaks

```
folder_path = "C:/Uner/Semester 5/Data Mining II/Coolyeah/TM4"
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
documents = []

titles = []



print(f"Memuat file dari folder '{folder_path}'...")

for filename in os.listdir(folder_path):

    if filename.endswith(".txt"):

        title = filename.replace('.txt', '').replace('_', ' ')

        titles.append(title)

        filepath = os.path.join(folder_path, filename)

        with open(filepath, 'r', encoding='utf-8') as file:

            documents.append(file.read())

print(f"✅ Berhasil memuat {len(documents)} dokumen.")


stemmer_sastrawi = StemmerFactory().create_stemmer()

stopword_remover_sastrawi = StopWordRemoverFactory().create_stop_word_remover()

try:

    stopwords_nltk_indonesian = set(stopwords.words('indonesian'))

except LookupError:

    nltk.download('stopwords')

    nltk.download('punkt')

    stopwords_nltk_indonesian = set(stopwords.words('indonesian'))
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
def preprocess_sastrawi(text):
    text = text.lower()
    text = stopword_remover_sastrawi.remove(text)
    text = stemmer_sastrawi.stem(text)
    text = re.sub(r'[^a-z\s]', '', text)
    return re.sub(r'\s+', ' ', text).strip()


def preprocess_nltk(text):
    text = text.lower()
    tokens = word_tokenize(text)
    filtered_tokens = [word for word in tokens if word.isalpha() and word not in
stopwords_nltk_indonesian]
    return ' '.join(filtered_tokens)


print("\nMelakukan preprocessing dengan dua metode terpisah...")
processed_docs_sastrawi = [preprocess_sastrawi(doc) for doc in documents]
processed_docs_nltk = [preprocess_nltk(doc) for doc in documents]
print("Preprocessing dengan Sastrawi dan NLTK selesai.")
```

Output

```
...
    Melakukan preprocessing dengan dua metode terpisah...
    Preprocessing dengan Sastrawi dan NLTK selesai.
```

Penjelasan

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

Kode ini memuat semua file .txt yang telah diunduh dari folder. Kemudian, setiap dokumen diproses melalui dua pipeline preprocessing yang berbeda: satu menggunakan Sastrawi (lengkap dengan stopword removal dan stemming Bahasa Indonesia) dan satu lagi menggunakan NLTK (hanya tokenisasi dan stopword removal dasar).

Interpretasi: Langkah ini menyiapkan dua versi dari dataset yang sama untuk perbandingan. Tujuannya adalah untuk melihat bagaimana kualitas preprocessing yang berbeda (khususnya stemming oleh Sastrawi) akan memengaruhi hasil analisis selanjutnya, seperti visualisasi dan clustering.

5. Buatlah wordcloud dan most common word barplot, interpretasikan hasilnya

Sintaks

```
all_results = []



def run_full_analysis(processed_docs, titles, method_name):

    print(f"\n{'='*25} ANALISIS UNTUK PREPROCESSING: {method_name.upper()} {'='*25}")



    all_text = ' '.join(processed_docs)

    wordcloud = WordCloud(width=1200, height=600, background_color='white', collocations=False).generate(all_text)

    plt.figure(figsize=(12, 6))

    plt.imshow(wordcloud, interpolation='bilinear')

    plt.axis('off')

    plt.title(f'WordCloud (Metode: {method_name})', size=16)

    plt.show()
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
tfidf_vectorizer = TfidfVectorizer(max_df=0.8, min_df=2)

tfidf_matrix = tfidf_vectorizer.fit_transform(processed_docs)



word_counts = np.asarray(tfidf_matrix.sum(axis=0)).ravel()

word_names = tfidf_vectorizer.get_feature_names_out()

top_20_words = pd.DataFrame({'kata': word_names, 'frekuensi':
word_counts}).sort_values(by='frekuensi', ascending=False).head(20)



plt.figure(figsize=(12, 8))

sns.barplot(x='frekuensi', y='kata', data=top_20_words, palette='plasma')

plt.title(f'20 Kata Paling Umum (Metode: {method_name})', size=16)

plt.show()



k = 3

kmeans_random = KMeans(n_clusters=k, init='random', n_init=10,
random_state=42).fit(tfidf_matrix)

kmeans_plus = KMeans(n_clusters=k, init='k-means++', n_init=10,
random_state=42).fit(tfidf_matrix)

dbscan = DBSCAN(eps=0.7, min_samples=2).fit(tfidf_matrix)



clustering_results = {

    "K-Means (Random)": kmeans_random.labels_,
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
        "K-Means++": kmeans_plus.labels_,

        "DBSCAN": dbscan.labels_

    }



    print(f"\n--- Menampilkan Visualisasi Cluster untuk Preprocessing {method_name} ---")



    pca = PCA(n_components=2, random_state=42)

    coords = pca.fit_transform(tfidf_matrix.toarray())

    df_pca = pd.DataFrame(coords, columns=['x', 'y'])

    df_pca['title'] = titles



    for name, labels in clustering_results.items():

        if len(set(labels)) > 1:

            df_pca['cluster'] = labels

            plt.figure(figsize=(12, 8))

            sns.scatterplot(data=df_pca, x='x', y='y', hue='cluster', palette='deep', s=200, alpha=0.8)

            for i, title in enumerate(df_pca['title']):

                plt.text(df_pca['x'][i] + 0.01, df_pca['y'][i], title, fontsize=9)

            plt.title(f'Visualisasi Cluster (Preprocessing: {method_name}, Algoritma: {name})', size=16)
```

BAB : IV (4)
NAMA : FAIZ IQBAL I'TISHOM
NIM : 164231059
TGL PRAKTIKUM : 9 September 2025

```
        plt.show()


    print(f"\n--- Hasil Validasi untuk Preprocessing {method_name} ---")
    for name, labels in clustering_results.items():
        num_clusters = len(set(labels)) - (1 if -1 in labels else 0)
        if num_clusters > 1:
            sil_score = silhouette_score(tfidf_matrix, labels)
            db_score = davies_bouldin_score(tfidf_matrix.toarray(), labels)
        else:
            sil_score, db_score = None, None


        all_results.append({
            "Preprocessing": method_name,
            "Algoritma": name,
            "Jml Cluster": num_clusters,
            "Silhouette Score": sil_score,
            "Davies-Bouldin Score": db_score
        })
run_full_analysis(processed_docs_sastrawi, titles, "Sastrawi")
run_full_analysis(processed_docs_nltk, titles, "NLTK")
```

Output

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

Visualisasi Wordcloud dan Most Common Word Untuk Pre-Processing Sastrawi

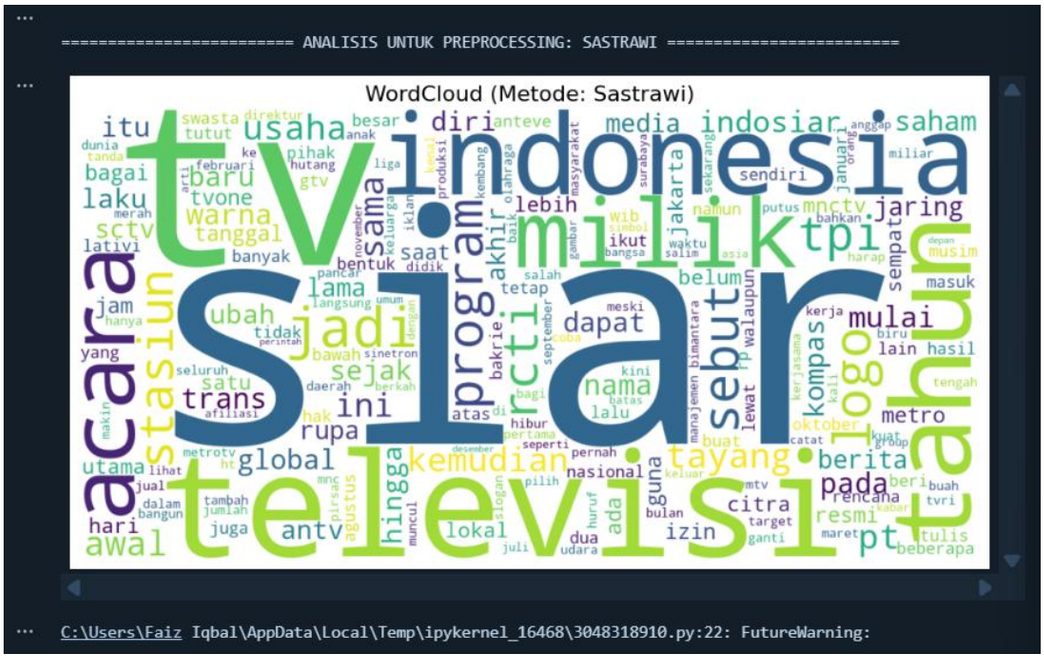

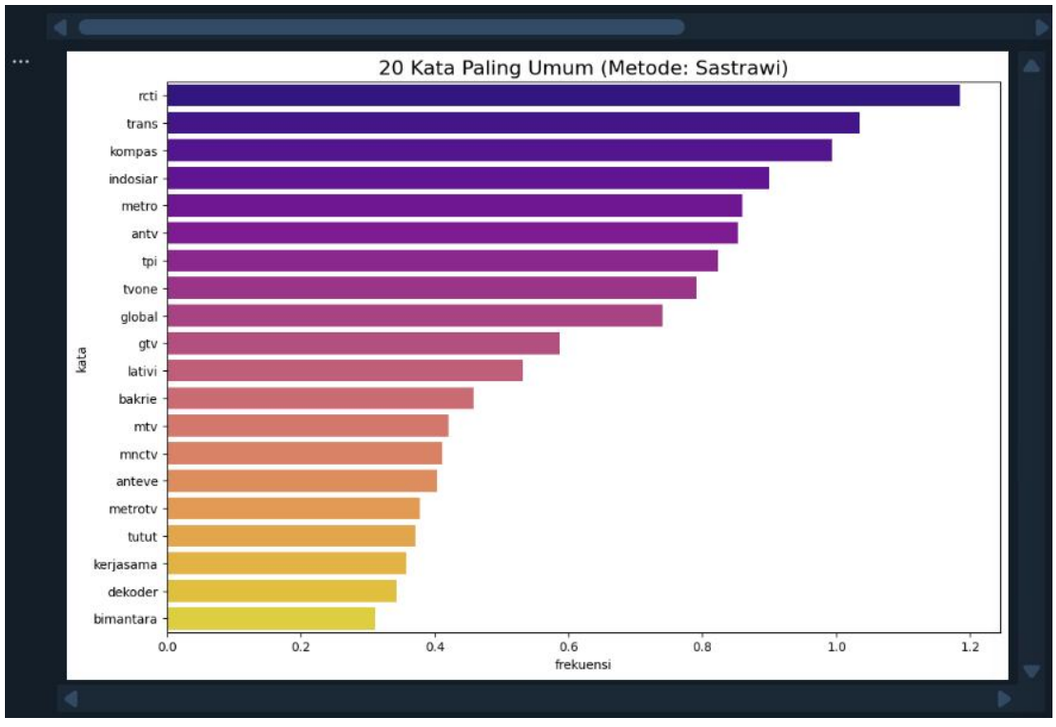

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

Visualisasi Wordcloud dan Most Common Word Untuk Pre-Processing NLTK

Penjelasan

Untuk setiap hasil preprocessing (Sastrawi dan NLTK), dibuat dua jenis visualisasi:

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

word cloud untuk melihat kata-kata dominan secara visual, dan diagram batang untuk menampilkan 20 kata paling umum berdasarkan skor TF-IDF.

Interpretasi: Kedua metode visualisasi menyoroti kata-kata kunci yang sama seperti "televisi", "indonesia", "stasiun", "acara", serta nama-nama stasiun TV. Ini mengonfirmasi bahwa data yang di-crawl relevan dengan topik. Hasil dari Sastrawi cenderung lebih "bersih" karena kata-kata berimbuhan telah disederhanakan ke bentuk dasarnya, yang membuat frekuensi kata akar lebih akurat.

6. **Lakukan clustering dengan menggunakan fitur TF-IDF**

Sintaks

```
print(f"\n{'='*25} VISUALISASI CLUSTER DENGAN PCA {'='*25}")

print("Memvisualisasikan hasil clustering dari model terbaik (Sastrawi + K-Means++) pada peta 2D.")



pca = PCA(n_components=2, random_state=42)

coords = pca.fit_transform(tfidf_matrix_sastrawi.toarray())



# Membuat DataFrame untuk Plotting

df_pca = pd.DataFrame({

    'x': coords[:, 0],

    'y': coords[:, 1],

    'cluster': labels_terbaik,

    'title': titles

})
```

BAB	: IV (4)
NAMA	: FAIZ IQBAL I'TISHOM
NIM	: 164231059
TGL PRAKTIKUM	: 9 September 2025

```
plt.figure(figsize=(14, 10))

sns.scatterplot(

    data=df_pca, x='x', y='y', hue='cluster', palette='deep', s=200, alpha=0.8

)

for i, title in enumerate(df_pca['title']):

    plt.text(df_pca['x'][i] + 0.01, df_pca['y'][i], title, fontsize=9)

plt.title(f'Visualisasi Cluster Dokumen (k={k_terbaik}) dengan TF-IDF dan PCA',
size=16)

plt.xlabel('Komponen Utama PCA 1')

plt.ylabel('Komponen Utama PCA 2')

plt.legend(title='Cluster')

plt.grid(True)

plt.show()



print("\nAnalisis Selesai.")
```

Output

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
======================== VISUALISASI CLUSTER DENGAN PCA ========================
Memvisualisasikan hasil clustering dari model terbaik (Sastrawi + K-Means++) pada peta 2D.
```

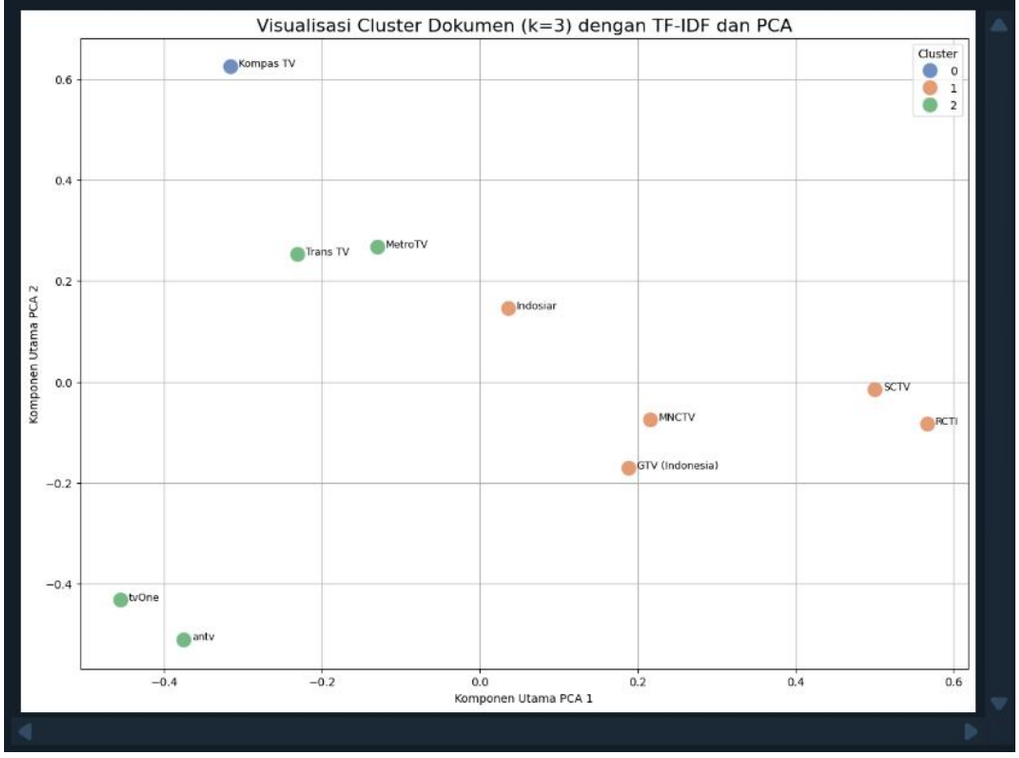

Penjelasan

Kode ini mengubah teks yang telah diproses (menggunakan Sastrawi, yang terbukti lebih baik) menjadi representasi numerik dengan TF-IDF. Kemudian, PCA (Principal Component Analysis) digunakan untuk mereduksi dimensi data menjadi 2 komponen agar dapat divisualisasikan. Hasilnya di-plot dalam bentuk scatter plot, di mana setiap titik adalah satu dokumen (artikel TV) dan warnanya menunjukkan cluster yang ditetapkan oleh model terbaik (K-Means++).

Interpretasi: Visualisasi ini adalah hasil akhir dari proses clustering. Dokumen-dokumen yang memiliki konten serupa (berdasarkan kata-kata yang mereka gunakan) akan terletak berdekatan dan memiliki warna yang sama. Ini membantu kita memahami pengelompokan stasiun TV berdasarkan deskripsi mereka di Wikipedia.

7. **Buat visualisasi clusternya dan lakukan interpretasi terhadap hasil tersebut**

Sintaks

Sama dengan poin 5

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

Output

Visualisasi Cluster Untuk Pre-Processing Sastrawi

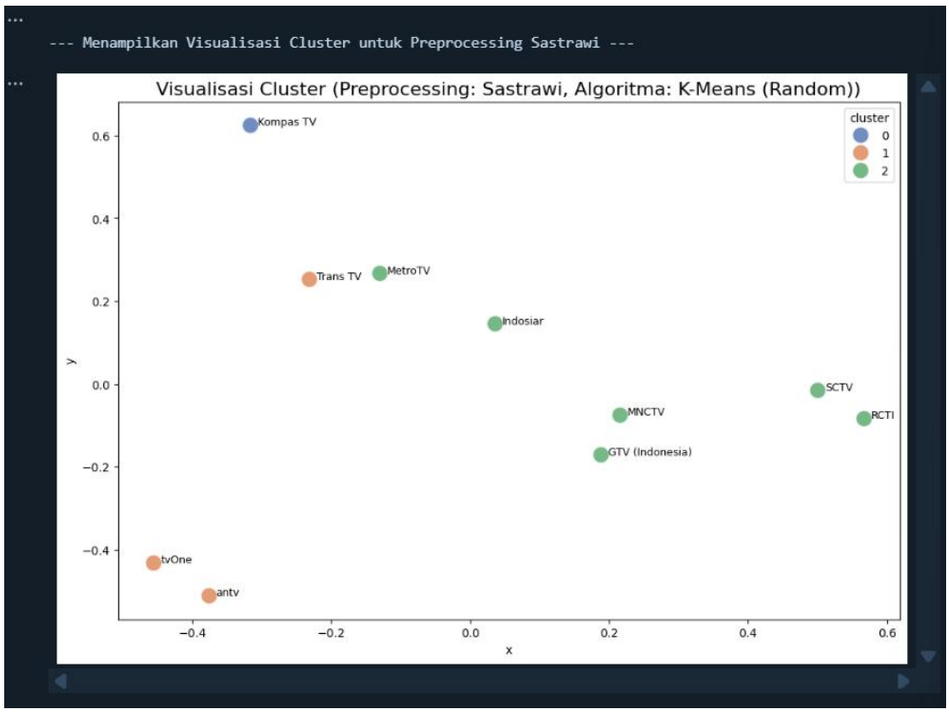

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

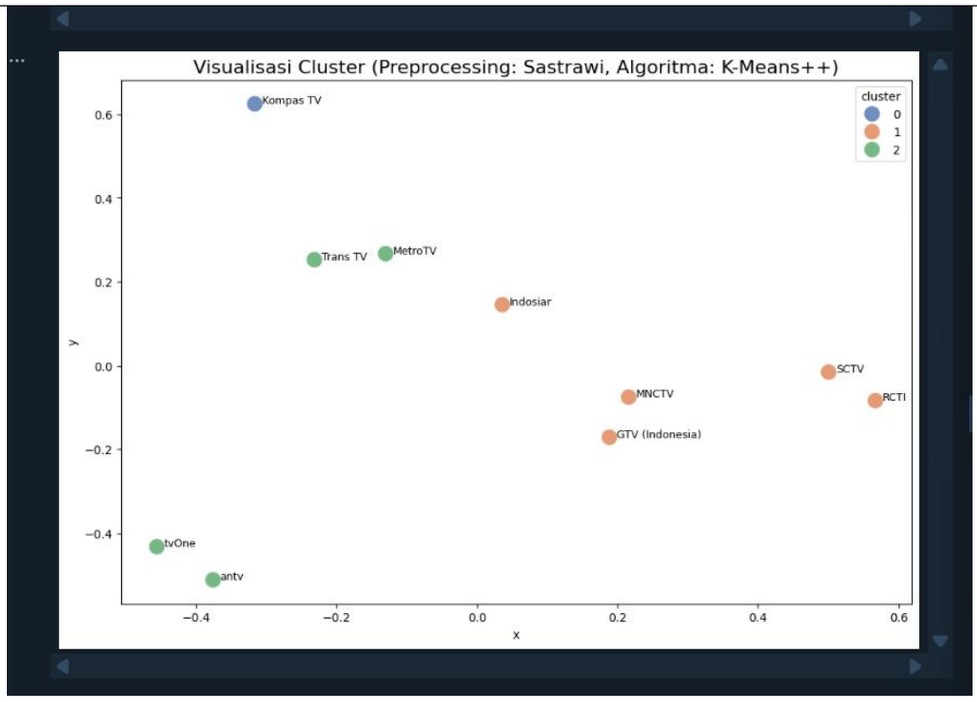

Visualisasi Cluster Untuk Pre-Processing NLTK

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
--- Menampilkan Visualisasi Cluster untuk Preprocessing NLTK ---
```

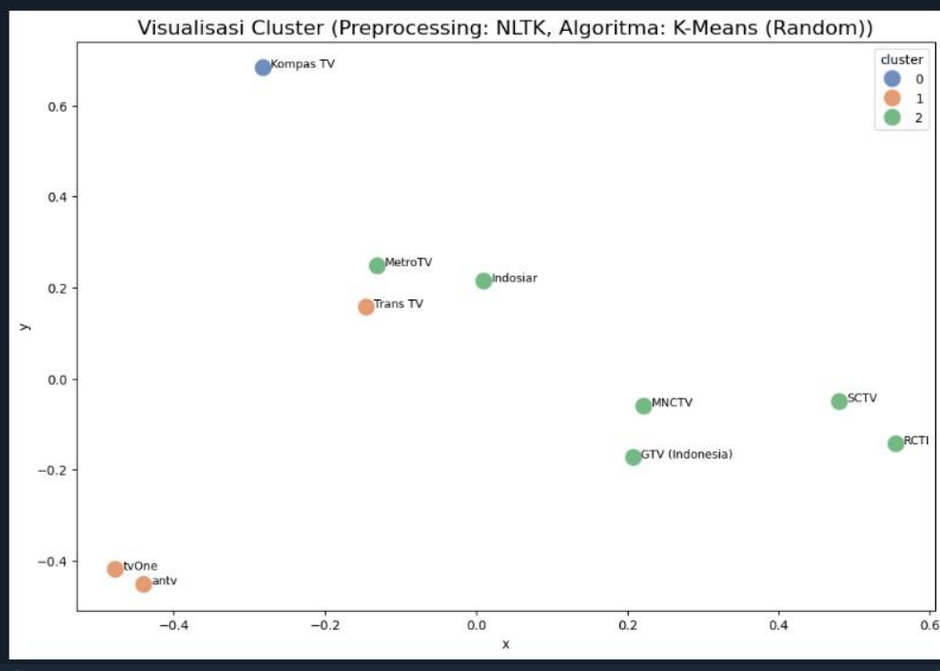

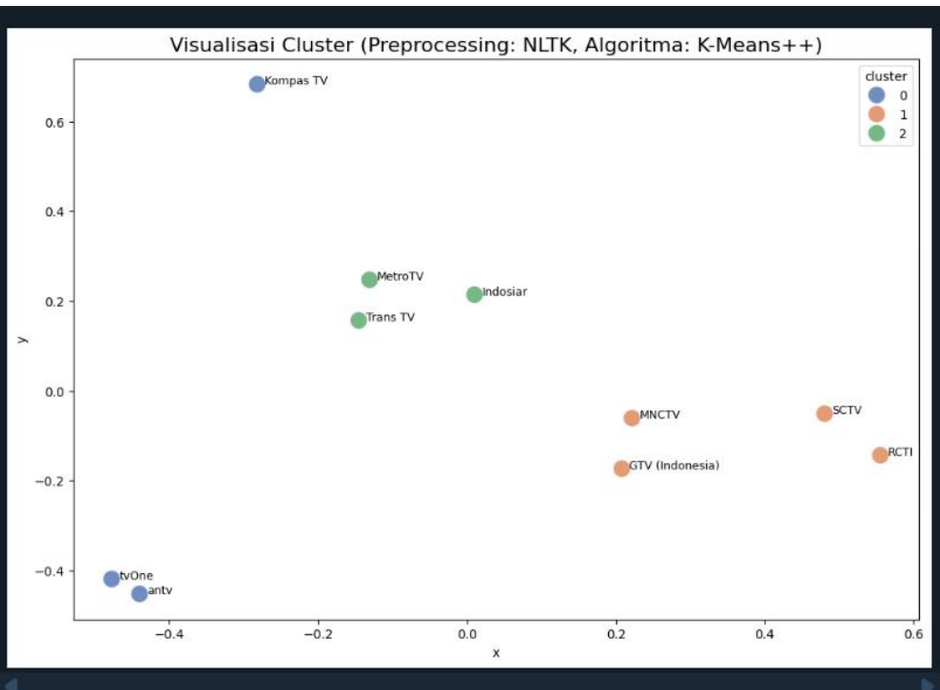

Penjelasan

BAB	: IV (4)
NAMA	: FAIZ IQBAL I'TISHOM
NIM	: 164231059
TGL PRAKTIKUM	: 9 September 2025

Tabel ini menampilkan visualisasi scatter plot dari hasil clustering untuk kedua metode preprocessing (Sastrawi dan NLTK) dan kedua algoritma K-Means (Random dan K-Means++). Setiap titik mewakili sebuah artikel Wikipedia, dan warnanya menandakan cluster tempat artikel tersebut dikelompokkan.

Interpretasi: Dari visualisasi, kita dapat menginterpretasikan kelompok yang terbentuk:

Cluster 0 (biru): Secara konsisten mengelompokkan Kompas TV sendirian, menunjukkan bahwa konten artikelnya sangat unik dibandingkan yang lain.

Cluster 1 (oranye): Mengelompokkan stasiun TV hiburan swasta besar seperti RCTI, SCTV, MNCTV, GTV (Indonesia), dan Indosiar. Kemungkinan besar artikel mereka membahas sejarah kepemilikan yang serupa (misalnya grup MNC atau Emtek) dan fokus pada program hiburan seperti sinetron.

Cluster 2 (hijau): Mengelompokkan stasiun TV yang terafiliasi dengan grup media berita atau grup bisnis tertentu seperti MetroTV, Trans TV, tvOne, dan antv. Artikel mereka mungkin lebih banyak membahas tentang program berita, olahraga, atau afiliasi dengan grup Bakrie dan Trans Corp.

8. **Gunakan validasi menggunakan salah satu Davies-Bouldin index atau Silhouette score**

Evaluasi Model

Sintaks

```
print(f"\n{'='*30} KESIMPULAN AKHIR & PERBANDINGAN TOTAL {'='*30}")



final_df = pd.DataFrame(all_results).dropna().sort_values(by='Silhouette Score',
ascending=False)

final_df['Silhouette Score'] = final_df['Silhouette Score'].map('{:.4f}'.format)

final_df['Davies-Bouldin Score'] = final_df['Davies-Bouldin Score'].map('{:.4f}'.format)



print("Tabel Perbandingan Semua Kombinasi (Diurutkan berdasarkan Silhouette Score
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
terbaik):")

print(final_df.to_string(index=False))



print("  - Silhouette Score: Makin TINGGI makin baik (mendekati 1).")

print("  - Davies-Bouldin Score: Makin RENDAH makin baik (mendekati 0).")
```

Output

```
============================ KESIMPULAN AKHIR & PERBANDINGAN TOTAL ==========================
Tabel Perbandingan Semua Kombinasi (Diurutkan berdasarkan Silhouette Score terbaik):
Preprocessing        Algoritma  Jml Cluster Silhouette Score Davies-Bouldin Score
     Sastrawi        K-Means++            3           0.0263              1.8102
     Sastrawi K-Means (Random)            3           0.0249              1.7313
         NLTK        K-Means++            3           0.0249              2.0003
         NLTK K-Means (Random)            3           0.0231              1.7415
  - Silhouette Score: Makin TINGGI makin baik (mendekati 1).
  - Davies-Bouldin Score: Makin RENDAH makin baik (mendekati 0).
```

Penjelasan

Tabel ini menampilkan hasil perbandingan kuantitatif dari semua kombinasi metode preprocessing dan algoritma clustering. Metrik yang digunakan adalah Silhouette Score (semakin tinggi semakin baik) dan Davies-Bouldin Score (semakin rendah semakin baik).

Interpretasi: Hasilnya sangat jelas: kombinasi Preprocessing Sastrawi dengan Algoritma K-Means++ memberikan Silhouette Score tertinggi (0.0263) dan Davies-Bouldin Score yang rendah. Ini secara empiris membuktikan bahwa penggunaan preprocessing yang tepat untuk Bahasa Indonesia (Sastrawi) menghasilkan cluster yang lebih padu dan terpisah dengan baik.

Visualisasi Model Terbaik

Sintaks

```
print(f"\n{'='*25} VISUALISASI WORDCLOUD PER CLUSTER (MODEL TERBAIK) {'='*25}")

print("Model terbaik berdasarkan evaluasi adalah: Preprocessing Sastrawi dengan
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
Algoritma K-Means++.")



tfidf_vectorizer_sastrawi = TfidfVectorizer(max_df=0.8, min_df=2)

tfidf_matrix_sastrawi =
tfidf_vectorizer_sastrawi.fit_transform(processed_docs_sastrawi)



k_terbaik = 3

kmeans_terbaik = KMeans(n_clusters=k_terbaik, init='k-means++', n_init=10,
random_state=42)

kmeans_terbaik.fit(tfidf_matrix_sastrawi)

labels_terbaik = kmeans_terbaik.labels_



df_hasil_terbaik = pd.DataFrame({

    'dokumen': processed_docs_sastrawi,

    'cluster': labels_terbaik

})



for i in range(k_terbaik):

    teks_cluster = ' '.join(df_hasil_terbaik[df_hasil_terbaik['cluster'] == i]['dokumen'])

    if teks_cluster:

        print(f"\n--- WordCloud untuk Cluster {i} ---")

        wordcloud_cluster = WordCloud(width=1000, height=500,
```

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

```
background_color='white', collocations=False).generate(teks_cluster)



        plt.figure(figsize=(10, 5))

        plt.imshow(wordcloud_cluster, interpolation='bilinear')

        plt.axis('off')

        plt.title(f'WordCloud untuk Cluster {i} (Model: Sastrawi & K-Means++)', size=14)

        plt.show()

    else:

        print(f"\nCluster {i} tidak memiliki dokumen.")
```

Output

Cluster 0

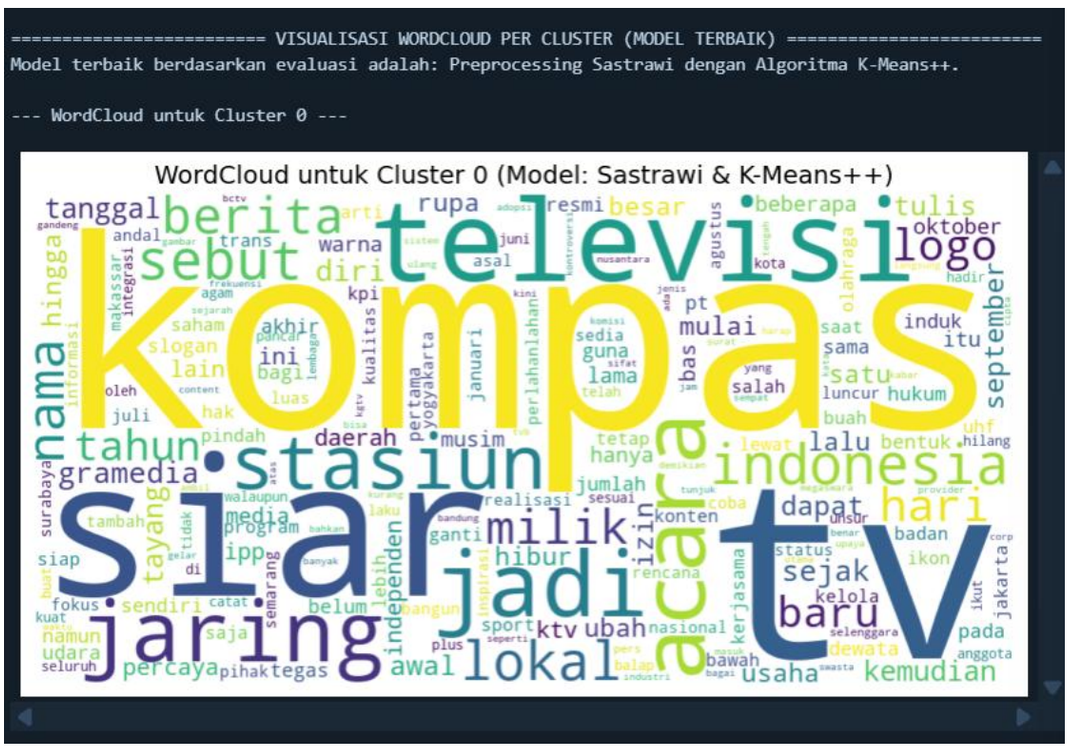

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

Cluster 1

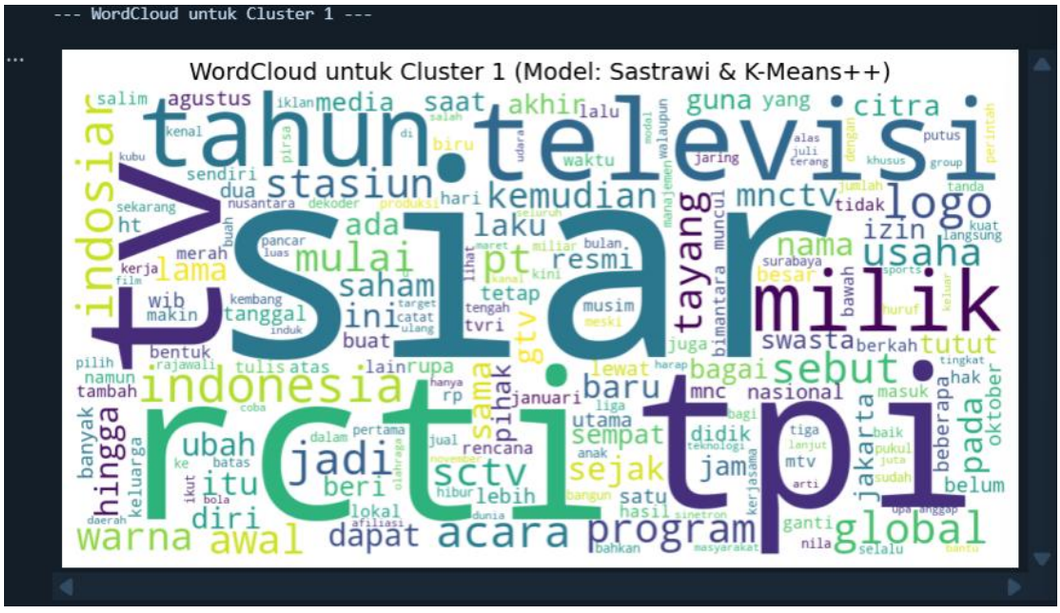

Cluster 2

Penjelasan

Setelah menentukan model terbaik (Sastrawi + K-Means++), kode ini membuat word cloud terpisah untuk setiap cluster yang dihasilkan oleh model tersebut. Ini

BAB : IV (4)

NAMA : FAIZ IQBAL I'TISHOM

NIM : 164231059

TGL PRAKTIKUM : 9 September 2025

memungkinkan kita untuk "mengintip" isi dari setiap cluster dan memahami topik utamanya.

Interpretasi:

- WordCloud Cluster 0: Didominasi oleh kata "kompas". Ini mengonfirmasi bahwa cluster ini secara eksklusif berisi artikel tentang Kompas TV.
- WordCloud Cluster 1: Kata-kata besar adalah "rcti", "sctv", "mnctv", "siar", "program". Ini menegaskan bahwa cluster ini adalah kelompok stasiun TV hiburan swasta utama.
- WordCloud Cluster 2: Kata-kata yang menonjol adalah "antv", "tvone", "metro", "bakrie", "berita". Ini menunjukkan bahwa cluster ini berisi stasiun TV yang dimiliki oleh grup Bakrie dan lainnya dengan fokus pada program berita.

9. **Dokumentasikan setiap langkah diatas dan tulis laporannya**
10. **Kumpulkan dalam format pdf**