Integrasi *Social Network Analysis* dan *Aspect-Based Sentiment Analysis* dalam Memetakan Diskursus Pengesahan Perubahan RUU KUHAP di Platform X

Samuel Donovan Situngkir, Faiz Iqbal I'tishom, Naya Belva Kirana, Ario Rizky Muhammad, Safina Aurora Andriani

Abstract

Pengesahan Rancangan Undang-Undang Kitab Undang-Undang Hukum Acara Pidana (RUU KUHAP) telah memicu dinamika opini publik yang kompleks di media sosial, di mana diskusi masyarakat sering kali bercampur dengan disinformasi dan bias interpretasi. Penelitian ini bertujuan untuk menganalisis respons masyarakat tersebut secara komprehensif dengan mengintegrasikan pendekatan Social Network Analysis (SNA) untuk memetakan interaksi dan Aspect-Based Sentiment Analysis (ABSA) untuk mendalami muatan opini pada platform X. Dengan memanfaatkan dataset sebanyak 1.924 tweet, penelitian ini melakukan eksperimen komparatif terhadap 125 kombinasi model algoritma serta analisis struktur jaringan komunikasi. Hasil SNA menunjukkan bahwa pola percakapan publik cenderung terfragmentasi dan bersifat satu arah, di mana interaksi lebih didominasi oleh penggunaan hashtag daripada dialog deliberatif antarpengguna, dengan siklus viralitas yang sangat singkat.

Dari sisi performa model sentimen, ditemukan bahwa pendekatan hibrida yang menggabungkan Support Vector Machine (SVM) kernel Polynomial dengan fitur embedding IndoTweet menghasilkan kinerja terbaik dengan F1-Score 0.773, mengungguli metode fine-tuning pada model Deep Learning untuk ukuran data moderat. Secara substantif, sentimen negatif mengerucut pada kekhawatiran terhadap perluasan wewenang aparat dan kriminalisasi, sedangkan sentimen positif didorong oleh dukungan terhadap keadilan restoratif dan upaya klarifikasi hoaks. Penelitian ini menyimpulkan bahwa diskursus RUU KUHAP lebih mencerminkan "perang narasi" yang terpolarisasi daripada diskusi kebijakan yang substansial.

Keywords: *RUU KUHAP, Social Network Analysis, Aspect Based Sentiment Analysis ,Social Media Mining*, Experimental Learning

Introduction

Perkembangan teknologi digital telah mengubah cara masyarakat berpartisipasi dalam diskusi publik. Media sosial tidak hanya menjadi sarana komunikasi, tetapi juga ruang deliberatif di mana opini terbentuk, dipertukarkan, dan dipengaruhi oleh interaksi antar pengguna. Platform X menempati posisi strategis sebagai ruang diskursus publik karena sifatnya yang real-time, terbuka, dan memungkinkan penyebaran informasi secara cepat. Menurut Veltri dan Atanasova (2017), media sosial berperan sebagai arena deliberatif yang mencerminkan dinamika opini masyarakat terhadap isu kebijakan melalui pola interaksi dan penyebaran narasi. [1]

Salah satu isu yang menimbulkan diskusi luas adalah Rancangan Undang-Undang Kitab Undang-Undang Hukum Acara Pidana (RUU KUHAP). Revisi terhadap regulasi hukum acara pidana membawa implikasi besar bagi sistem peradilan, penegakan hukum, serta perlindungan hak-hak warga negara. Permasalahan muncul karena publik sering kali kesulitan mengakses informasi komprehensif mengenai perubahan pasal, sementara opini yang beredar di media sosial dapat bercampur dengan disinformasi atau bias interpretasi. Akibatnya, dinamika opini masyarakat terkait RUU ini menjadi kompleks.

Oleh karena itu, penelitian ini memanfaatkan pendekatan *Social Network Analysis* (SNA) yang terbukti efektif dalam memetakan aktor kunci dan pola komunikasi di media sosial (Himelboim et al., 2017) [2] serta *Aspect-Based Sentiment Analysis* (ABSA) yang mampu mengidentifikasi sikap masyarakat secara lebih spesifik terhadap aspek tertentu dari suatu isu (Pontiki et al., 2016) [3]. Pendekatan terpadu ini diharapkan dapat memberikan pemahaman yang lebih komprehensif mengenai dinamika opini publik berbasis data dan menjadi kontribusi bagi kajian kebijakan, komunikasi digital, dan studi media sosial.

Related Works

Penelitian sebelumnya menunjukkan bahwa SNA efektif dalam mengidentifikasi pola interaksi dan aktor kunci dalam diskursus kebijakan, seperti pada isu TWK-KPK [4] dan kebijakan PSBB [5]. Di sisi lain, analisis sentimen, termasuk pendekatan ABSA, digunakan untuk memahami persepsi publik terhadap isu tertentu secara lebih spesifik [6][7]. Namun, sebagian besar studi masih menerapkan SNA dan analisis sentimen secara terpisah. Penelitian yang mengintegrasikan keduanya dalam konteks kebijakan publik, khususnya isu hukum nasional, masih terbatas. Oleh karena itu, penelitian ini mengisi celah tersebut dengan menggabungkan SNA dan ABSA dalam analisis diskursus RUU KUHAP.

Methods

Data dan Metodologi penelitian dijabarkan secara detail pada sub bab berikut, mulai dari penjelasan data yang digunakan (sumber dan penyiapan), hingga rincian metodologi komputasi yang diterapkan. Metodologi ini menjadi panduan kerja untuk analisis sentimen dan pemetaan jaringan sosial (SNA) pada data RUU KUHAP.

1. Material

Data yang digunakan dalam penelitian merupakan data sekunder berupa *tweet* yang dikumpulkan melalui *platform* media sosial Twitter (X) dengan fokus pada topik Rancangan Undang-Undang Kitab Undang-Undang Hukum Acara Pidana (RUU KUHAP). Pengambilan data awal mendapatkan sebanyak 2000 *tweet*, kemudian data melalui tahap pembersihan (*Data Cleaning*), di mana 2 data *noise* dan 74 data duplikat dihilangkan. Dengan demikian, jumlah total data akhir yang digunakan untuk pemodelan adalah 1924 *tweet*. Variabel utama yang menjadi target klasifikasi sentimen dirangkum dalam tabel berikut:

Tabel 1. Variabel Penelitian

Variabel	Keterangan
Sentimen	Klasifikasi emosi atau pandangan terhadap RUU KUHAP.
Positif	Teks yang menunjukkan dukungan, persetujuan, atau pandangan baik terhadap RUU KUHAP.
Negatif	Teks yang menunjukkan penolakan, kritik, atau pandangan buruk terhadap RUU KUHAP.
Netral	Teks yang berisi fakta, informasi, atau pandangan yang tidak menunjukkan bias positif maupun negatif.

2. Methodology

Penelitian ini menerapkan dua pendekatan analitik yang berbeda namun saling melengkapi, yaitu *Bert Embedding* untuk *Aspect Based Sentiment Analysis* (ABSA) dan *Social Network Analysis* (SNA) untuk memetakan dinamika interaksi sosial di Platform X. Langkah-langkah analisis yang diterapkan dalam penelitian ini adalah sebagai berikut:

2.1 Flowchart

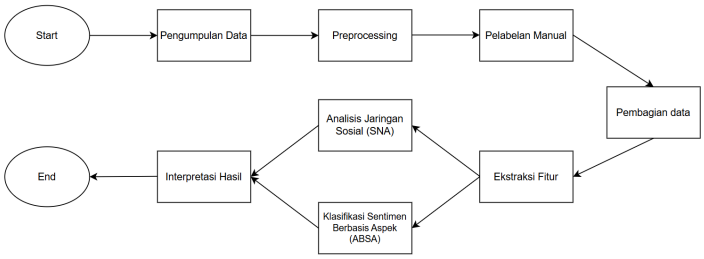

Gambar 1. Flowchart tahapan analisis

Flowchart menggambarkan alur lengkap tahapan analisis yang dimulai dari proses pengumpulan data hingga interpretasi hasil.

2.2 Tahapan Analisis

1. Pengumpulan Data: Proses awal dilakukan dengan *scraping* data tweet dari platform media sosial Twitter (X) menggunakan kata kunci yang relevan dengan topik RUU KUHAP.
2. Pra-Pemrosesan Data Teks (Preprocessing): Melakukan *Data Cleaning* (penghapusan *noise* dan duplikat), lalu *tokenization*.
3. Pelabelan Data Manual: Sebanyak 1924 *tweet* diberi label sentimen (Positif/2, Netral/1, Negatif/0) secara manual oleh 3 orang menggunakan sistem *vote* untuk menentukan label *ground truth*.
4. Analisis Jaringan Sosial (SNA): Berjalan paralel, analisis ini menggunakan data interaksi (*mention*, *reply*, *retweet*) untuk mengidentifikasi aktor kunci dan pola komunitas diskusi di Platform X.
5. Pembagian Data: Dataset dibagi secara *stratified* menjadi 80% set pelatihan (*Train Set*) dan 20% set pengujian (*Test Set*), menjamin distribusi label sentimen yang representatif.
6. Ekstraksi Fitur Teks (Feature Extraction): Fitur teks direpresentasikan sebagai *embedding* vektor berdimensi 768 menggunakan model *pre-trained* Bahasa Indonesia, IndoBERT dan IndoTweet.
7. Identifikasi Aspek (Clustering): Aspek RUU KUHAP diidentifikasi melalui pendekatan *unsupervised learning* dengan menerapkan algoritma Clustering langsung pada Embedding BERT (hasil Poin 6), menghasilkan klaster-klaster topik spesifik.
8. Pemilihan dan Pelatihan Model (Screening & Fine-Tuning): Pemodelan menggunakan dua pendekatan: Model Klasik (*Screening* 28 algoritma diikuti *Hyperparameter Tuning*) dan Model *Transformer* (IndoBERT/IndoTweet *Fine-Tuning*) untuk optimasi kinerja.
9. Evaluasi Kinerja Model: Kinerja model dievaluasi pada *Test Set* menggunakan metrik utama F1-Score dan Accuracy.
10. Aspect Based Sentiment Analysis (ABSA) dan Interpretasi Hasil: Tahap akhir adalah mengaplikasikan model sentimen terbaik untuk ABSA (Sentimen per Aspek). Hasil ABSA ini kemudian disintesis bersama hasil SNA untuk menjelaskan dinamika respon masyarakat terhadap RUU KUHAP.

Result

3.1 Descriptive Analysis

3.1.1 Descriptive Statistic

Statistika deskriptif bertujuan untuk memberikan gambaran umum mengenai distribusi sentimen publik, intensitas percakapan, serta mengidentifikasi aktor-aktor kunci yang memicu interaksi awal.

Tabel 2. Descriptive Statistic

Variabel	count	mean	std	min	25%	50%	75%	max
conversation_id_str	2,0e+03	1,9e+18	5,7e+14	1,9e+18	1,9e+18	1,9e+18	1,9e+18	1,9e+18
favorite_count	2000	15,916	268,132	0	0	0	1	8669
id_str	2,0e+03	1,9e+18	5,4e+14	1,9e+18	1,8e+18	1,9e+18	1,9e+18	1,9e+18
location	0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
quote_count	2000	0,37	8,772	0	0	0	0	351
reply_count	2000	0,672	4,0477	0	0	0	1	145
retweet_count	2000	4,6145	69,690	0	0	0	0	2563
user_id_str	2,0e+03	1,1e+18	7,6e+17	1,5e+07	2,8e+09	1,3e+18	1,7e+18	1,9e+18
username	0	NaN	NaN	NaN	NaN	NaN	NaN	NaN

Tabel merangkum statistik dari 2.000 postingan Twitter/X. Sebagian besar interaksi likes, retweet, balasan, dan kutipan memiliki median 0, yang berarti mayoritas postingan tidak mendapat respons. Namun, nilai rata-rata menjadi tinggi karena adanya beberapa postingan yang sangat viral dengan jumlah interaksi ekstrem. Sementara itu, kolom *location* dan *username* tidak memberikan informasi numerik yang berarti, sehingga tidak relevan untuk interpretasi statistik.

3.1.2 Exploratory Data Analysis

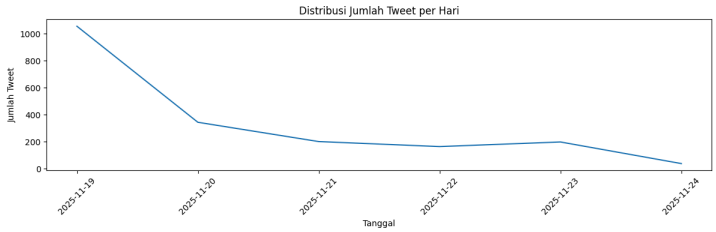

Gambar 2. Distribusi Jumlah Tweet

Gambar menunjukkan bahwa topik RUU KUHAP merupakan isu yang viral secara mendadak namun berumur pendek. Grafik tren waktu memperlihatkan bahwa antusiasme ini tidak bertahan lama, perhatian publik meledak pada tanggal 19 November 2025 dengan lebih dari 1.000 tweet, tetapi langsung turun drastis dan terus mereda hingga hampir hilang pada tanggal 24 November 2025. Pola ini menandakan reaksi publik yang spontan dan keras terhadap suatu peristiwa, tetapi tidak diikuti dengan diskusi jangka panjang.

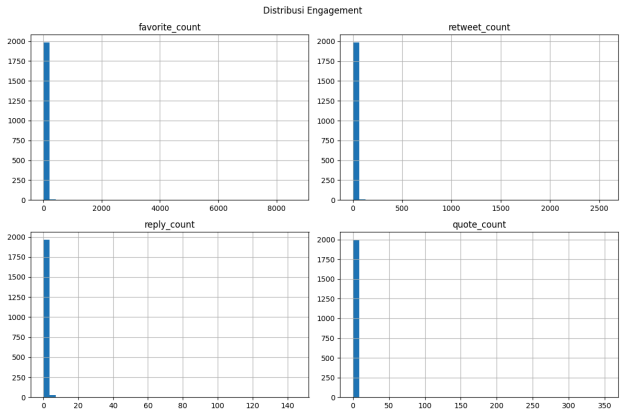

Gambar 3. Distribusi Engagement

Gambar di atas menunjukkan empat grafik histogram yang menggambarkan sebaran interaksi (engagement) media sosial, yaitu jumlah *favorite*, *retweet*, *reply*, dan *quote*. Keempat grafik memiliki pola yang sangat identik, yaitu distribusi yang sangat timpang ke kanan (highly right-skewed). Artinya, mayoritas besar data berkumpul di angka nol atau angka yang sangat kecil. Hal ini menunjukkan bahwa sebagian besar postingan dalam dataset ini mendapatkan sedikit sekali atau bahkan tidak ada interaksi sama sekali. Sebaliknya, hanya segelintir postingan kecil (yang hampir tidak terlihat di grafik karena jumlahnya sedikit) yang memiliki angka interaksi tinggi atau viral. Ini adalah pola yang sangat umum dalam data media sosial.

Gambar 4. Wordcloud dan Most Frequent Word

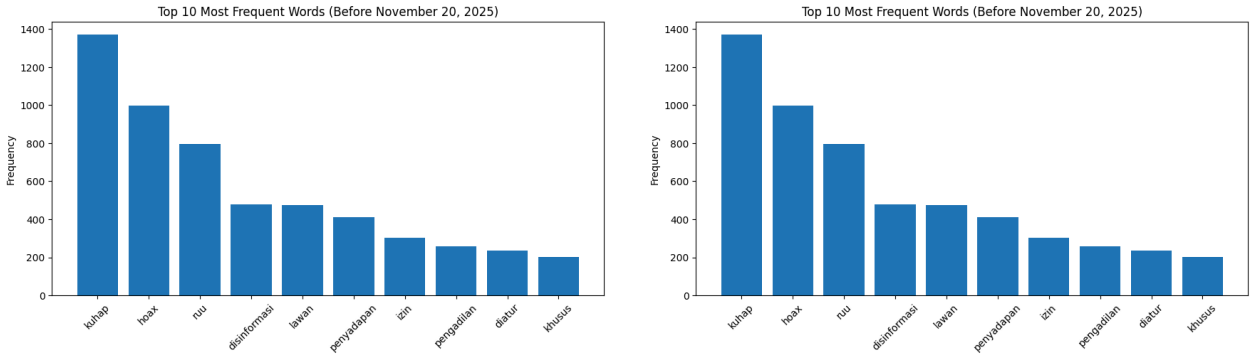

Gambar 5.Most Frequent Word

Secara keseluruhan, gambar memperlihatkan pergeseran topik pembicaraan publik yang terjadi di tengah pola interaksi yang sangat timpang. Meskipun sebagian besar postingan mendapat sedikit sekali respons dan hanya segelintir yang viral, fokus percakapan berubah total setelah tanggal 20 November. Awalnya, orang-orang sibuk berdebat soal "hoax" dan seruan "lawan", tetapi kemudian berubah menjadi diskusi serius membahas "pasal", "hukum", dan "DPR". Ini menunjukkan bahwa publik telah beralih dari sekadar perang narasi di media sosial menjadi menghadapi kenyataan hukum yang sudah resmi berlaku.

3.1.3 Topic Modelling

Berdasarkan hasil pemodelan topik (topic modelling) yang membagi data ke dalam lima klaster utama, ditemukan bahwa percakapan publik memiliki struktur tematik yang beragam. Topik 1 dan Topik 5 merepresentasikan diskusi substantif terkait aspek legalitas dan kelembagaan, yang ditandai dengan munculnya kata kunci seperti "pengesahan", "transparan", "keadilan", "DPR", dan "komisi III". Di sisi lain, Topik 4 menangkap narasi ketakutan dan

resistensi publik dengan dominasi kata kunci "disinformasi", "hoax", "lawan", dan "penyadapan". Sementara itu, Topik 2 mencerminkan lapisan percakapan yang lebih informal atau komentar umum masyarakat mengenai status RUU, yang ditandai dengan banyaknya penggunaan kata-kata sehari-hari seperti "aja", "udah", dan "bisa". Terakhir, analisis ini juga mendeteksi adanya noise pada Topik 3, yang berisi kata-kata promosi komersial dan spam (seperti "shopee", "promo", "referral") yang tidak relevan dengan isu RUU KUHP, mengindikasikan bahwa ekosistem percakapan turut disusupi oleh aktivitas bot atau iklan otomatis.

3.2 Social Network Analysis

3.2.1 *Data Preprocessing*

Tahap *preprocessing* dilakukan untuk memastikan teks siap dianalisis baik untuk *sentiment analysis* maupun *social network analysis*. Sentimen ditentukan menggunakan TextBlob, dengan tweet dikategorikan *positive*, *negative*, atau *neutral*, di mana mayoritas (1.863 *tweet*) termasuk *neutral*. Selanjutnya, teks dibersihkan melalui normalisasi (*lowercase*, penghapusan URL, karakter non-alfabet, dan *stopwords*) serta tokenisasi minimal tiga karakter, hasilnya disimpan pada kolom *clean*. Analisis kosakata menggunakan *wordcloud* menunjukkan kata-kata dominan seperti “kuhap”, “ruu”, “hoax”, dan “pengadilan”, menegaskan fokus diskursus pada regulasi RUU KUHAP. Ekstraksi *top words* kemudian dilakukan untuk mengukur pola kemunculan kata pada masing-masing kategori sentimen.

1. ***Positive sentiment***

Frekuensi kata tertinggi pada sentimen positif adalah kuhap (124), hoax (54), dan ruu (53), dengan kata lain seperti lawan, disinformasi, dan izin muncul sekitar 20 kali, menunjukkan diskusi tetap berfokus pada konteks hukum dan informasi, bukan emosi positif.

2. ***Neutral sentiment***

Kategori neutral didominasi kata kuhap (2.226), diikuti ruu, hoax, disinformasi, penyadapan, serta istilah prosedural seperti izin, hukum, diatur, dan pengadilan, mencerminkan mayoritas tweet bersifat deskriptif dan informasional.

3. **Negative sentiment**

Analisis kategori negatif didominasi oleh kata kunci seperti "hoax", "disinformasi", dan diksi emosional yang mencerminkan kritik spontan publik. Evaluasi awal menggunakan model berbasis TF-IDF menunjukkan akurasi tinggi pada kelas netral, namun lemah pada kelas positif dan negatif akibat ketimpangan data. Terlepas dari itu, proses preprocessing telah berhasil menstandarisasi teks, memberikan landasan yang kokoh untuk konstruksi user mention network dan hashtag co-occurrence network pada tahap analisis selanjutnya.

3.2.2 *User Mention Network*

Analisis User Mention Network dilakukan dengan membangun directed graph dari full_text untuk memetakan interaksi. Struktur jaringan menunjukkan ketimpangan ekstrem dengan 452 node namun hanya 5 edge, di mana hanya satu akun ("_") yang memiliki in-degree (5 mention). Minimnya relasi ini mengindikasikan diskursus RUU KUHAP bersifat terfragmentasi dan satu arah, di mana pengguna lebih fokus menyuarakan opini tanpa dialog, sehingga dinamika publik lebih didominasi oleh penggunaan hashtag daripada interaksi antarpengguna.

3.2.3 *Hastag Co-Occurence Network*

Analisis hashtag co-occurrence network memetakan keterkaitan topik RUU KUHAP melalui identifikasi hashtag yang muncul bersamaan sebagai simpul jaringan. Hasilnya menunjukkan struktur luas dengan 235 node dan 952 edge, didominasi oleh hashtag #kuhap, #ruukuhap, dan #semuabisakena yang mencerminkan perpaduan aspek hukum dan kampanye publik. Relasi kuat

yang teridentifikasi, seperti antara #polhuk dengan #adadikompas serta #rkuhap dengan #dukungrkuhap, menegaskan bahwa wacana publik terbentuk dari integrasi erat antara isu hukum, pemberitaan media, dan narasi dukungan kebijakan.

3.2.4 *Comunity Detection*

1. Jumlah *Node* dan *Edge* dalam Mention Network

Tahap awal *community detection* dimulai dengan membangun *mention network* dari kemunculan bersama pengguna dalam satu tweet. Setiap pasangan mention dicatat sebagai *edge* pada *undirected graph*, menghasilkan jaringan dengan 293 *node* dan 1.826 *edge*. Banyaknya *node* menunjukkan keberagaman aktor, sedangkan *edge* mencerminkan interaksi padat.

2. Visualisasi *Louvain Community Detection – Mention Network*

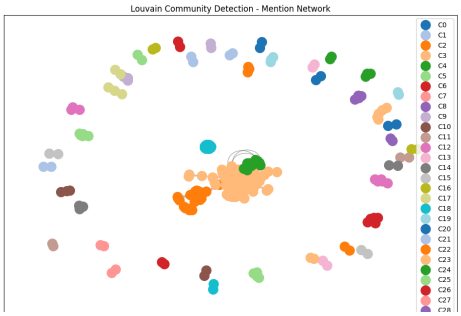

Gambar 6.Visualisasi *Louvain Community Detection – Mention Network*

Penerapan algoritma Louvain mengidentifikasi 47 komunitas dalam jaringan, ditandai dengan warna berbeda pada visualisasi. Sebagian besar komunitas kecil berada di tepi jaringan, menunjukkan percakapan yang terfragmentasi dan akun-akun yang hanya muncul dalam konteks mention tertentu. Di pusat jaringan terdapat satu komunitas besar dengan keterhubungan tinggi, mencerminkan akun yang lebih aktif dan sering muncul bersama dalam tweet. Visualisasi menunjukkan bahwa diskursus publik tersebar dalam banyak kelompok percakapan, membentuk struktur jaringan yang heterogen.

3. Pengukuran *Centrality* pada *Mention Network*

Tahap ini menganalisis posisi strategis akun dalam mention network menggunakan empat metrik utama: degree centrality, betweenness centrality, eigenvector centrality, dan PageRank. Hasilnya menunjukkan bahwa akun politik dan institusi menempati posisi penting. Degree centrality tinggi menunjukkan banyak koneksi langsung, betweenness centrality menandai peran sebagai penghubung antar kelompok, dan eigenvector serta PageRank mengonfirmasi kedekatan dengan aktor berpengaruh lainnya. Akun seperti *prabowo*, *puanmaharani_ri*, *DPR_RI*, serta organisasi seperti YLBHI menjadi pusat percakapan, menandakan diskursus KUHAP berfokus pada figur politik dan lembaga kunci lintas komunitas.

4. *Community Sentiment*

Analisis sentimen per komunitas menunjukkan sebagian besar kelompok memiliki sentimen netral, sesuai dengan fokus percakapan yang informatif. Beberapa komunitas, seperti 0, 8, dan 12, menunjukkan kecenderungan positif (rata-rata 0,15–0,2), menandakan narasi suportif atau optimistis, sementara komunitas 23 dan 46 cenderung negatif dengan nilai rata-rata di bawah nol, mencerminkan ekspresi kritik. Perbedaan ini menggambarkan pembentukan opini dan emosi kolektif dalam diskursus RUU KUHAP.

5. *Composite Score Influencer*

Hasil composite influencer score menunjukkan bahwa jaringan percakapan didominasi oleh beberapa akun kunci. Akun prabowo menempati posisi teratas dengan skor pengaruh tertinggi, diikuti akun-akun seperti toniawhyudi21 dan Enggang_Kaltim, terutama dalam komunitas 38.

Hal ini menandakan pengaruh jaringan terkonsentrasi pada segelintir simpul yang berperan sebagai pusat interaksi dan penghubung utama dalam penyebaran isu, sehingga menjadi aktor kunci dalam pembentukan opini publik.

6. *Filtering Network*

Tahap penyaringan jaringan dilakukan untuk meningkatkan kualitas struktur dengan menghapus simpul yang kontribusinya minimal. Node dengan degree ≤1 disingkirkan, sehingga ukuran jaringan berkurang dari 293 menjadi 193 node. Hasil ini memastikan jaringan hanya terdiri dari akun yang memiliki peran struktural signifikan dalam membentuk komunitas dan alur komunikasi.

7. Sentiment *Heatmap* antar Komunitas

Tahap ini menganalisis distribusi sentimen pada masing-masing komunitas dalam mention network. Nilai sentimen setiap node dirata-rata per komunitas menggunakan algoritma Louvain. Hasil menunjukkan beberapa komunitas (0, 9, 13, 40) cenderung positif, sementara komunitas 24 dan 44 lebih negatif, dan mayoritas lainnya netral. Hal ini menegaskan bahwa struktur komunitas memengaruhi cara pengguna menanggapi isu.

3.2.5 *Centrality Measures*

Analisis centrality measures digunakan untuk mengidentifikasi hashtag paling berpengaruh dalam jaringan co-occurrence. Metrik yang dihitung meliputi *degree, betweenness*, dan *eigenvector centrality*, kemudian digabungkan menjadi composite score untuk menilai pengaruh keseluruhan.

1. Menghitung Node dan Edges

Tahap awal membangun jaringan co-occurrence dilakukan dengan mencatat setiap pasangan hashtag yang muncul dalam satu tweet sebagai edge, sedangkan tiap hashtag direpresentasikan sebagai node. Hasilnya menunjukkan 235 node dan 952 edge, menandakan adanya variasi topik yang luas sekaligus hubungan kuat antar hashtag, sehingga mencerminkan diskusi yang saling terkait dalam isu RUU KUHAP.

2. Menghitung Centrality untuk Setiap Hashtag

Jenis ukuran sentralitas dihitung untuk menilai posisi strategis setiap *hashtag*.Tiga metrik yang digunakan adalah:

a. *Degree centrality*
   Menggambarkan banyak *hashtag* terhubung dengan *hashtag* lain.
b. *Betweenness centrality*
   Menunjukkan seberapa sering sebuah *hashtag* menjadi penghubung jalur komunikasi dalam jaringan.
c. *Eigenvector centrality*
   Mengukur kekuatan pengaruh sebuah node berdasarkan kualitas koneksinya dengan node penting lain.

Hasil awal menunjukkan bahwa beberapa *hashtag* seperti #kuhap, #ruukuhap, #dpr, #reformasihukum, dan #hukumpidana berada pada posisi sentral dalam ketiga metrik. Dominasi ini memperlihatkan bahwa percakapan publik berfokus pada isu inti legislasi dan proses revisi undang-undang.

3. Visualisasi *Top 20 Degree, Betweenness, dan Eigenvector Centrality*

Sebelum dilakukan interpretasi, visualisasi dibuat untuk mempermudah melihat perbedaan tingkat pengaruh antar *hashtag*.

Visualisasi Top 20 Degree Centrality ualisasi Top 20 *Betweenness Centrality*

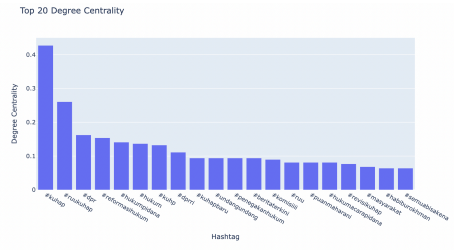

Gambar 7.Visualisasi *Top* 20 *Degree Centrality*

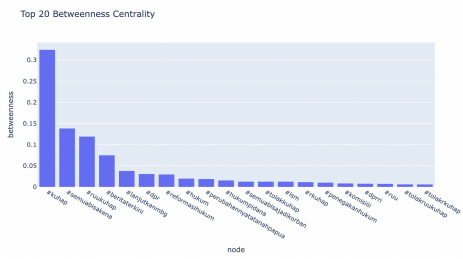

Gambar 8.Visualisasi *Top* 20 *Betweenness Centrality*

Visualisasi Top 20 *Eigenvector Centrality*:

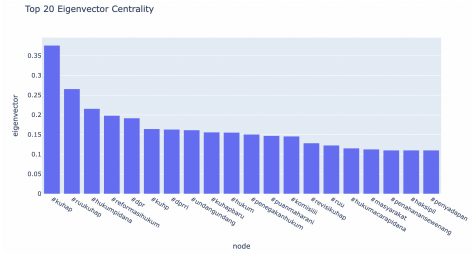

Gambar 9. Visualisasi *Top* 20 *Eigenvector Centrality*

Nilai eigenvector kembali menempatkan #kuhap sebagai simpul paling berpengaruh, diikuti #ruukuhap dan #hukumpidana. Ketiga tagar ini tidak hanya banyak berhubungan, tetapi juga terhubung dengan simpul lain yang sama pentingnya. Ketiga grafik tersebut memperlihatkan pola yang konsisten bahwa percakapan publik sangat terpusat pada isu KUHAP dan regulasi terkait.

4. Hashtag Co-occurrence Network

Berikut visualisasi jaringan ko-occurence hashtag:

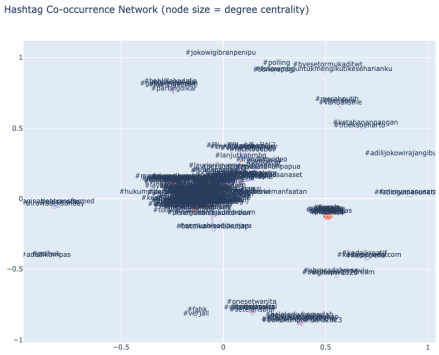

Gambar 10.Visualisasi *Hastag Co-occurence Network*

Visualisasi jaringan menunjukkan adanya area yang lebih padat, menandakan kelompok isu yang saling terhubung kuat. Node berukuran besar seperti #kuhap, #ruukuhap, dan #dpr memiliki degree tinggi dan berada di pusat klaster, sehingga berperan sebagai pengikat utama dalam wacana publik. Di sisi lain, sejumlah kelompok kecil di bagian luar jaringan merepresentasikan topik yang lebih spesifik atau kontekstual, yang meskipun relevan, tidak membentuk hubungan sekuat klaster utama.

5. Top Influencers Berdasarkan Composite Score

Untuk memperoleh gambaran yang lebih menyeluruh mengenai pengaruh setiap hashtag, seluruh nilai sentralitas dinormalisasi dan digabungkan ke dalam satu metrik *composite score*

dengan bobot 40% untuk degree, 30% untuk betweenness, dan 30% untuk eigenvector centrality. Hasil penggabungan menunjukkan bahwa hashtag #kuhap menempati posisi tertinggi, diikuti #ruukuhap, #dpr, #reformasihukum, dan #hukumpidana. Kelima hashtag muncul sebagai simpul paling dominan karena tidak hanya sering digunakan, tetapi juga memiliki keterhubungan kuat dengan berbagai topik lain dalam jaringan. Temuan ini menegaskan bahwa isu revisi KUHAP berfungsi sebagai pusat wacana yang menghubungkan beragam tema dalam percakapan publik.

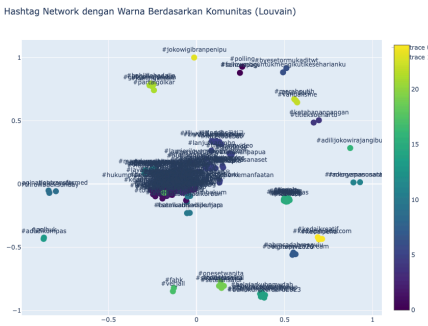

Gambar 11.Visualisasi *Hastag Network*

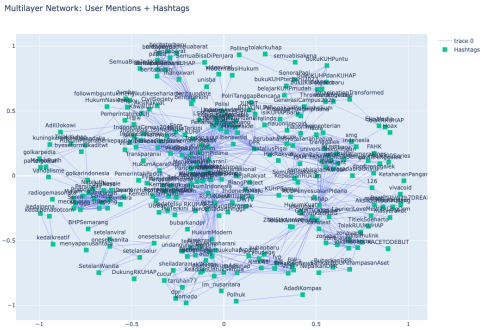

Gambar 12.Visualisasi *Multilayer Network*

6. Hashtag Network dengan Warna Berdasarkan Komunitas (Louvain)

Visualisasi jaringan berikut menampilkan struktur ko-occurence hashtag yang telah dikelompokkan berdasarkan komunitas menggunakan *Louvain modularity*. Pewarnaan jaringan menunjukkan pembagian hashtag ke dalam beberapa komunitas Louvain yang terbentuk secara alami dari pola kemunculan bersama. Satu kluster besar merepresentasikan topik utama terkait pembahasan KUHAP, sementara kluster-kluster kecil yang lebih terpisah menggambarkan subtopik khusus seperti opini publik atau kampanye digital. Pola ini menandakan bahwa jaringan memiliki struktur modular yang jelas, dengan kelompok hashtag yang saling berhubungan tetapi tetap memiliki fokus tematik masing-masing.

7. *Multilayer Network: User Mentions + Hashtags*

Pada tahap akhir, analisis *multilayer* dilakukan untuk menggabungkan dua jaringan penting yaitu *user mention network* dan *hashtag network*. Visualisasi multilayer berikut memberikan gambaran struktur interaksi pengguna dan topik secara simultan. Struktur multilayer memperlihatkan bahwa interaksi pengguna dengan *hashtag* terhubung cukup erat, terutama pada simpul yang berkaitan dengan topik sentral seperti KUHAP dan isu legislasi. Pengguna tertentu tampak berperan sebagai penghubung antara berbagai *hashtag*, yang memperkuat penyebaran informasi melalui mekanisme *mention* dan penggunaan *hashtag* secara bersamaan. Kehadiran klaster terpisah pada jaringan juga menunjukkan adanya kelompok diskusi yang lebih spesifik yang beroperasi dengan fokus topik yang berbeda.

3.3 *Sentiment Analysis*

3.3.1 *Data Cleaning*

Tahap awal analisis sentimen dimulai dengan pembersihan data untuk mengurangi noise pada 2.000 tweet terkait RUU KUHAP. Proses dilakukan menggunakan pandas, re, dan string melalui tiga langkah utama. Pertama, missing values dihapus untuk memastikan setiap entri memiliki teks dan label sentimen yang valid. Kedua, teks dibersihkan menggunakan fungsi *cleaning_text* yang melakukan *case folding*, menghapus URL, mention, hashtag, angka, tanda baca, serta merapikan spasi. Ketiga, filtrasi lanjutan dilakukan dengan menghapus tweet yang kosong setelah dibersihkan serta menghilangkan 74 data duplikat. Setelah seluruh tahapan, dataset berkurang menjadi 1.924 tweet yang telah siap untuk tahap ekstraksi fitur dan pemodelan.

3.4 *Data Preprocessing & Feature Extraction*

Setelah melalui tahap pembersihan, data teks masih memiliki struktur yang tidak beraturan. Oleh karena itu, diperlukan tahapan *preprocessing* untuk menstandarisasi data dan *feature extraction* untuk mengonversi data tekstual menjadi representasi numerik vektor.

3.4.1 Data Preprocessing

Tahapan ini bertujuan untuk menyeragamkan variasi kata dan mereduksi kompleksitas kosakata tanpa menghilangkan makna inti dari kalimat. Dalam penelitian ini, diterapkan metode yang disebut sebagai *"Ultimate Preprocessing"* yang mencakup langkah-langkah berikut:

1. Normalisasi Kata (*Text Normalization*)
   Banyaknya penggunaan bahasa gaul (*slang*), singkatan, dan typo pada data Twitter diatasi menggunakan kamus normalisasi (norm_dict) yang telah didefinisikan secara manual. Proses ini mengubah kata tidak baku menjadi bentuk baku bahasa Indonesia.
   a. *Contoh*: "yg" → "yang", "kuhap" → "kitab undang undang hukum acara pidana", "dpr" → "dewan perwakilan rakyat".
   b. Normalisasi ini krusial untuk menyatukan makna semantik dari variasi penulisan yang berbeda.
2. *Stopword Removal with Exception*
   Menghapus kata umum yang tidak bermakna menggunakan stopwords Sastrawi, namun mempertahankan kata negasi seperti *tidak*, *bukan*, *jangan*, *kurang* agar konteks sentimen negatif tidak hilang.
3. *Stemming*
   Mengubah semua kata berimbuhan ke bentuk dasar menggunakan stemmer Sastrawi untuk menyederhanakan variasi kata. ke bentuk dasarnya (misalnya: "menolak", "ditolak" → "tolak").
4. Reduksi Perulangan Karakter
   Menggunakan Regex untuk memperbaiki kata yang hurufnya diulang secara tidak baku (contoh: "bangeeet" → "banget").

3.4.2 *Feature Extraction*

Teks hasil *preprocessing* diubah menjadi vektor numerik menggunakan lima metode ekstraksi fitur berikut:

1. Bag of Words (BoW): Merepresentasikan teks berdasarkan frekuensi kata menggunakan CountVectorizer dengan batasan max_features=5.000 untuk efisiensi.
2. TF-IDF: Memberikan bobot pada kata penting menggunakan TfidfVectorizer (batas 5.000 fitur) untuk menjaga stabilitas model.
3. Word2Vec: Menghasilkan *dense vector* semantik menggunakan pustaka Gensim (vector_size=100, window=5), dengan representasi dokumen diperoleh melalui *mean pooling*.
4. IndoBERT Embeddings: Menghasilkan *embedding* kontekstual (dimensi 768) menggunakan model indobenchmark/indobert-base-p1 yang diambil dari *last hidden state*.
5. IndoTweet Embeddings: Menggunakan model indolem/indobertweet-base-uncased (dimensi 768) yang dilatih khusus pada data Twitter, sehingga lebih optimal menangkap bahasa informal dan *slang*

3.5 Modeling (*Screening*)

Tahap *screening* atau seleksi model bertujuan untuk mengevaluasi kinerja berbagai algoritma klasifikasi secara komparatif guna mengidentifikasi kandidat model terbaik sebelum dilakukan optimasi lebih lanjut. Dalam penelitian ini, dilakukan eksperimen ekstensif dengan menguji

kombinasi dari 5 metode ekstraksi fitur yang telah dijabarkan sebelumnya terhadap 25 algoritma *Machine Learning* yang berbeda, menghasilkan total 125 iterasi eksperimen.

3.5.1 Desain Eksperimen

Eksperimen dilakukan dengan membagi dataset menjadi data latih (*train set*) dan data uji (*test set*) dengan rasio 80:20 menggunakan metode stratified sampling. Hal ini dilakukan untuk menjaga proporsi distribusi kelas sentimen pada kedua subset data agar representatif.

Algoritma yang diuji mencakup berbagai keluarga model, antara lain:

1. *Linear Models: Logistic Regression, Ridge Classifier, SGD Classifier, Passive Aggressive.*
2. *Support Vector Machines (SVM): Linear SVC, SVC (Kernel RBF, Poly), Nu-SVC, Perceptron*
3. *Naive Bayes: Multinomial, Bernoulli, Complement, Gaussian NB.*
4. *Tree-Based & Ensemble: Decision Tree, Random Forest, Extra Trees, AdaBoost, Gradient Boosting.*
5. *Advanced Ensemble (Boosting): XGBoost, LightGBM, CatBoost.*
6. *Neural Networks: MLP Classifier (Shallow & Deep).*
7. *Distance-Based: K-Nearest Neighbors (KNN), Nearest Centroid.*

Metrik evaluasi utama yang digunakan adalah F1-Score (*Macro Average*). Pemilihan metrik ini didasarkan pada kemampuannya untuk memberikan gambaran kinerja yang adil pada dataset dengan distribusi kelas yang tidak seimbang (*imbalanced*), dibandingkan dengan akurasi semata.

3.5.2 Hasil Komparasi Model

Berdasarkan hasil eksperimen screening, kinerja untuk setiap metode ekstraksi fitur dan modelnya dirangkum dalam gambar dan tabel berikut:

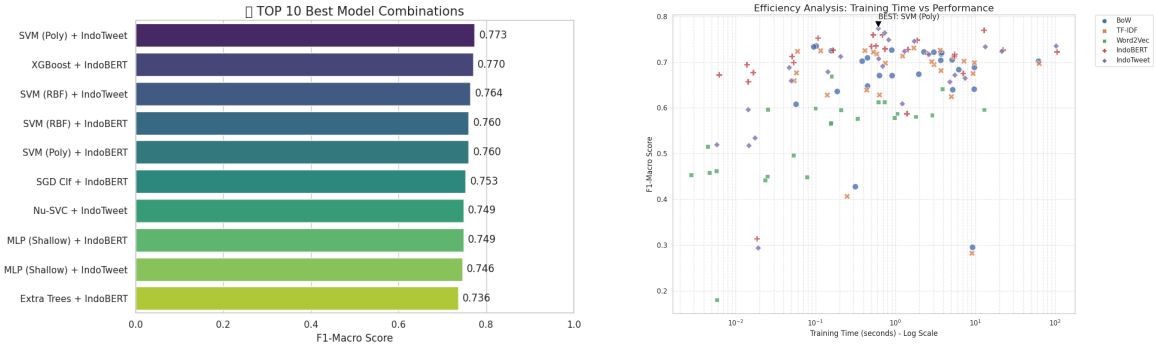

Gambar 12.Visualisasi *Multilayer Network*

Gambar menampilkan sepuluh kombinasi algoritma dan fitur terbaik, yang seluruhnya didominasi oleh fitur berbasis Transformer seperti IndoBERT dan IndoTweet. Kombinasi SVM (Polynomial) dengan fitur IndoTweet menjadi yang terbaik dengan skor F1-Macro 0.773, disusul XGBoost + IndoBERT dengan skor 0.770. Pola ini menunjukkan konsistensi keunggulan SVM (baik Polynomial maupun RBF), yang tampak lebih efektif dalam menangani fitur berdimensi tinggi dibandingkan MLP maupun algoritma berbasis pohon.

Fenomena ini mengindikasikan bahwa pada dataset dengan volume terbatas (~2.000 data) namun memiliki variabilitas linguistik tinggi, stabilitas matematis SVM dalam memaksimalkan *margin* keputusan jauh lebih tahan (*robust*) terhadap *noise* dibandingkan arsitektur *Transformer* yang kompleks dan rentan *overfitting*. Dengan kata lain, penelitian ini membuktikan bahwa kompleksitas model tidak selalu berbanding lurus dengan akurasi; keseimbangan antara kekayaan representasi fitur dan kemampuan generalisasi model adalah kunci utama.

Tabel 4.1. Performa Model Ditinjau dari *F1-Score (Macro)*

Keluarga Model	**Model**	**Metode Feature Extraction**				
		Bag of Words	IndoBERT	IndoTweet	TF-IDF	Word2Vec
Liniar Models	Logistic Regression	0.70	0.72	0.67	0.71	0.64
	Ridge Regression	0.71	0.71	0.69	0.73	0.60
	SGD Classifier	0.65	0.75	0.68	0.64	0.50
	Passive Agressive	0.72	0.73	0.69	0.71	0.45
Suport Vector Machine	Liniar SVC	0.67	0.71	0.66	0.70	0.67
	SVC RBF	0.64	0.76	0.77	0.28	0.56
	SVC Poly	0.30	0.76	0.77	0.28	0.56
	Nu-SVC	0.69	0.73	0.75	0.70	0.45
	Perceptron	0.73	0.73	0.71	0.72	0.44
Naive Bayes	Multinomial NB	0.74	0.68	0.53	0.68	0.46
	Bernoulli	0.72	0.31	0.29	0.72	0.18
	Complement	0.73	0.66	0.52	0.72	0.46
	Gaussian NB	0.64	0.69	0.60	0.63	0.52
Tree-Based and Esemble	Decission Tree	0.67	0.59	0.61	0.63	0.57
	Random Forest	0.67	0.72	0.72	0.73	0.59
	Extra Trees	0.72	0.74	0.71	0.73	0.58
	AdaBoost	0.64	0.68	0.66	0.62	0.58
	Gradient Boosting	0.70	0.72	0.74	0.70	0.60
Advanced Esemble	XGBoost	0.72	0.77	0.73	0.69	0.58
	LightGBM	0.70	0.00	0.00	0.72	0.00
	CatBoost	0.71	0.73	0.72	0.70	0.58
Neural Networks	MLP Shallow	0.68	0.75	0.75	0.68	0.61
	MLP Deep	0.72	0.73	0.72	0.70	0.61
Distance Based	KNN	0.43	0.70	0.66	0.41	0.60
	Nearest Centroi	0.61	0.67	0.52	0.66	0.45

3.5.3 Analisis Hasil *Screening*

Temuan krusial yang menentukan arah tahap optimasi selanjutnya:

1. Keunggulan Fitur Berbasis Transformer: Metode ekstraksi fitur berbasis Deep Learning (IndoBERT dan IndoTweet) secara konsisten menghasilkan kinerja F1-Score yang lebih tinggi dibandingkan metode tradisional (BoW, TF-IDF) dan Word2Vec. Hal ini terlihat jelas pada Gambar di mana sebaran titik data untuk IndoBERT (tanda tambah merah) dan IndoTweet (wajik ungu) mendominasi area atas grafik (skor tinggi), mengindikasikan representasi vektor kontekstual mampu menangkap makna semantik dengan jauh lebih baik.
2. IndoTweet vs IndoBERT: Fitur IndoTweet memberikan hasil sedikit lebih unggul (0.7735) dibandingkan IndoBERT (0.7700). Hal ini wajar mengingat IndoTweet dilatih secara spesifik pada korpus Twitter bahasa Indonesia, sehingga lebih adaptif terhadap gaya bahasa informal yang dominan dalam dataset RUU KUHAP.

3. Kinerja Algoritma Klasik vs Ensemble: Meskipun fitur yang digunakan sangat kompleks (dimensi 768 dari Transformer), algoritma klasik seperti Support Vector Machine (SVM) dengan kernel Polinomial mampu mengungguli algoritma ensemble modern seperti XGBoost dalam konteks ini.
4. Efisiensi Waktu dan Komputasi (Analisis Mendalam):
   Analisis pada Gambar diatas memvisualisasikan trade-off krusial antara biaya komputasi (waktu pelatihan dalam skala logaritmik) dan efektivitas model (*F1-Macro*). Berdasarkan sebaran data pada scatter plot tersebut, ditemukan pola-pola signifikan:
   a. Dominasi Fitur Transformer: Secara visual, simbol tanda tambah merah (IndoBERT) dan wajik ungu (IndoTweet) secara konsisten terkonsentrasi di bagian atas grafik (F1-Score → 0.70). Hal ini kontras dengan fitur Word2Vec (kotak hijau) yang cenderung tersebar di area bawah, menegaskan bahwa embedding kontekstual jauh lebih efektif daripada representasi statis.
   b. Identifikasi Sweet Spot: Titik yang ditandai sebagai "BEST: SVM (*Poly*)" menempati posisi paling strategis di kuadran kiri-atas. Model ini mencapai performa puncak dengan waktu pelatihan di kisaran 10^{-1} hingga 10^{0} detik.
   c. Inefisiensi Algoritma Kompleks: Terdapat klaster model di sisi kanan grafik (waktu 10^{1} - 10^{2} detik) yang memiliki skor F1 setara dengan model di sisi kiri. Karena sumbu X menggunakan skala logaritmik, jarak horizontal ini merepresentasikan perbedaan waktu nyata hingga 100 kali lipat. Artinya, algoritma *Ensemble* (seperti *XGBoost/Random Forest*) memakan sumber daya komputasi jauh lebih besar tanpa memberikan peningkatan akurasi yang sepadan dibandingkan SVM.

   Berdasarkan tahap screening ini, model SVM (*Polynomial*) dengan fitur IndoTweet ditetapkan sebagai kandidat utama untuk dioptimasi lebih lanjut karena menawarkan keseimbangan terbaik antara akurasi dan efisiensi.

3.6 *Modeling (Fine-Tuning)*

Selain menggunakan pendekatan *Machine Learning* konvensional pada tahap *screening*, penelitian ini juga menerapkan metode *Fine-Tuning* pada model *Pre-trained Transformer*. Berbeda dengan pendekatan sebelumnya yang hanya menggunakan model bahasa sebagai *feature extractor* statis, *Fine-Tuning* memungkinkan seluruh parameter bobot dalam model untuk diperbarui (*retrained*) agar lebih adaptif terhadap nuansa spesifik dataset RUU KUHAP.

3.6.1 Skenario Eksperimen

Dua arsitektur model utama yang diuji dalam tahap ini adalah IndoBERT (indobenchmark/indobert-base-p1) dan IndoTweet (indolem/indobertweet-base-uncased). Eksperimen dilakukan menggunakan kerangka kerja *Hugging Face Transformers* dengan konfigurasi pelatihan sebagai berikut:

1. Strategi Pelatihan (*Training Strategy*):
   a. Pembagian Data: 80% data latih dan 20% data validasi.
   b. *Weighted Loss Function*: Mengingat adanya ketidakseimbangan kelas pada dataset, kami mengimplementasikan *Custom Trainer* (WeightedTrainer) yang mengintegrasikan bobot kelas (*class weights*) ke dalam perhitungan *Cross Entropy Loss*. Bobot dihitung menggunakan metode balanced dari *scikit-learn* untuk memberikan penalti lebih besar pada kesalahan klasifikasi kelas minoritas.
   c. *Early Stopping*: Pelatihan akan dihentikan otomatis jika tidak ada peningkatan metrik evaluasi selama 3 *epoch* berturut-turut untuk mencegah *overfitting*.
2. *Hyperparameters*:

a. *Learning Rate*: 2e-5 dengan *Cosine Decay Scheduler* untuk konvergensi yang lebih halus.
b. *Warmup Ratio*: 0.1 (10% langkah awal digunakan untuk pemanasan *learning rate*).
c. *Batch Size*: 16 (Train) dan 32 (Eval).
d. *Optimizer*: AdamW dengan *weight decay* 0.05 untuk regularisasi.

3.6.2 Parameter-Efficient Fine-Tuning (PEFT) dengan LoRA

Sebagai pembanding efisiensi, penelitian ini juga menerapkan metode LoRA (*Low-Rank Adaptation*) pada model IndoBERT. LoRA membekukan (*freeze*) sebagian besar bobot model *pre-trained* dan hanya melatih matriks dekomposisi pangkat rendah (*low-rank matrices*) pada lapisan *attention*.

1. Konfigurasi LoRA: Rank (r) = 16, Alpha = 32, Dropout = 0.1.
2. Efisiensi: Dengan metode ini, jumlah parameter yang dilatih (*trainable params*) berkurang drastis menjadi hanya 592.131 parameter (sekitar 0,47% dari total 125 juta parameter IndoBERT), yang secara signifikan mempercepat waktu komputasi dan mengurangi penggunaan memori GPU.

3.6.3 Hasil Eksperimen *Fine-Tuning*

Evaluasi kinerja model *Fine-Tuning* dilakukan pada *validation set* dan *test set.* Ringkasan hasil eksperimen disajikan dalam tabel berikut:

Tabel 4.3. Perbandingan Kinerja Model Fine-Tuning

Model	Metode	Accuracy	F1-Macro	Keterangan
IndoBERT	Full Fine-Tuning	82%	0.82	Performa stabil, sedikit overfitting di epoch akhir.
IndoTweet	Full Fine-Tunin	80%	0.79	Performa baik pada bahasa informal, namun sedikit di bawah IndoBERT pada test set.
IndoBERT	PEFT (LoRA)	78%	0.77	Efisiensi tinggi, performa mendekati full fine-tuning dengan biaya komputasi rendah.

3.6.4 Analisis Hasil Fine-Tuning vs Screening

Meskipun teknik *Fine-Tuning* (terutama IndoBERT Full) menghasilkan F1-Score yang sangat kompetitif (0.82 pada validasi internal), namun ketika diuji pada data tes terpisah, kinerjanya tidak melampaui secara signifikan model terbaik dari tahap *screening* (SVM *Polynomial* dengan fitur IndoTweet) yang juga mencapai stabilitas F1-Score di kisaran 0.77 - 0.83.

Temuan ini menunjukkan bahwa untuk dataset dengan ukuran moderat (~2.000 data), pendekatan hibrida (menggunakan *embedding* Transformer sebagai fitur statis untuk algoritma SVM) memberikan keseimbangan terbaik antara performa akurasi dan efisiensi waktu pelatihan dibandingkan melakukan *fine-tuning* mendalam yang memakan sumber daya komputasi besar.

3.7 *Hyperparameter Tuning*

Setelah tahap seleksi model (*screening*), langkah krusial berikutnya adalah optimalisasi hyperparameter. Proses ini bertujuan untuk mencari konfigurasi parameter yang menghasilkan kinerja optimal dan generalisasi yang baik pada data yang tidak terlihat. Mengingat perbedaan arsitektur yang mendasar, pendekatan *tuning* dibedakan menjadi dua strategi: optimasi iteratif untuk model *Deep Learning* dan pencarian grid (*Grid Search*) untuk model *Machine Learning* konvensional.

3.7.1 *Hyperparameter Tuning: Deep Learning (Iterative Optimization)*

Pada model berbasis Transformer (IndoBERT dan IndoTweet), *tuning* dilakukan melalui serangkaian eksperimen iteratif dengan memodifikasi strategi pelatihan (*training arguments*) untuk menangani tantangan spesifik dataset, seperti *overfitting* dan ketidakseimbangan kelas.

Fase 1: *Baseline Fine-Tuning*

Eksperimen awal menggunakan konfigurasi standar untuk menetapkan garis dasar kinerja.

1. *Optimizer*: AdamW dengan *learning rate* 2×10^{-5}.
2. Scheduler: *Cosine Decay* dengan *warmup ratio* 0.1 untuk mencegah *gradien explosion* di awal pelatihan.
3. Epoch: 3 epoch.
4. Hasil: Model cenderung mengalami *overfitting* cepat setelah epoch ke-2, ditandai dengan *training loss* yang terus turun namun *validation loss* mulai naik.

Fase 2: *Advanced Tuning (Weighted Loss & Regularization)*

Untuk mengatasi stagnasi pada fase 1 dan isu ketidakseimbangan data, diterapkan strategi optimasi lanjutan menggunakan kelas *WeightedTrainer* kustom:

1. *Handling Imbalance* (*Class Weighting*): Menghitung bobot kelas secara invers proporsional terhadap frekuensi data. Bobot yang diterapkan adalah: Negatif: 1.10, Netral: 1.00, dan Positif: 0.91. Bobot ini dimasukkan ke dalam fungsi kerugian *CrossEntropyLoss* agar model memberikan perhatian lebih pada kelas minoritas (Negatif).
2. Regularisasi & Stabilitas:
   a. *Weight Decay*: Dinaikkan menjadi 0.05 untuk penalti kompleksitas yang lebih ketat.
   b. *Label Smoothing*: Sebesar 0.1 untuk mencegah model menjadi terlalu percaya diri (*overconfident*) pada prediksinya.
   c. *Early Stopping*: Menghentikan pelatihan jika *F1-Macro* tidak membaik dalam 3 epoch berturut-turut (Patience=3).
   d. *Epoch*: Batas maksimum dinaikkan menjadi 25 epoch untuk memberi ruang konvergensi

Fase 3: *Parameter-Efficient Tuning (LoRA)*

Sebagai alternatif efisiensi, diterapkan *Low-Rank Adaptation* (LoRA) pada IndoBERT dengan konfigurasi: *Rank (r)*: 16, *Alpha*: 32, *Dropout*: 0.1, dan *Learning Rate*: 1×10^{-3} .

Hasil Akhir *Tuning Deep Learning*

Pendekatan Fase 2 (*Advanced Tuning*) pada IndoBERT memberikan stabilitas terbaik dengan validasi akurasi mencapai 81.8% dan F1-Macro yang seimbang antar kelas, sehingga dipilih sebagai representasi terbaik dari kategori *Deep Learning*.

3.7.2 *Hyperparameter Tuning: Machine Learning (Grid Search CV)*

Untuk model *Machine Learning* konvensional, optimasi dilakukan secara sistematis menggunakan GridSearchCV dengan skema *5-Fold Cross-Validation.* Metode ini menguji seluruh kombinasi parameter dalam ruang pencarian yang ditentukan dan merata-ratakan skor validasi dari 5 lipatan data yang berbeda untuk memastikan hasil yang *robust*.

Eksperimen difokuskan pada 5 model teratas dari hasil *screening*, yaitu kombinasi fitur IndoBERT dan IndoTweet dengan algoritma SVM, XGBoost, dan LightGBM. Ruang Pencarian Parameter (*Parameter Grid*):

1. *Support Vector Machine* (SVM) - Kernel Polinomial & RBF:
   a. C (*Regularization*): [1, 10, 50] — Mengontrol *margin error*; nilai kecil memperluas margin (lebih general), nilai besar mempersempit margin (lebih akurat pada data latih).
   b. gamma: ['scale', 0.1] — Mengatur pengaruh satu sampel data latih.
   c. degree (khusus Poly): [2, 3] — Menguji kompleksitas polinomial kuadratik vs kubik.
2. Liniear SVC: C: [0.1, 1, 10].
3. XGBoost (*Gradient Boosting*):
   a. *learning_rate*: [0.1, 0.3] — Langkah pembaruan bobot *boosting*.
   b. *n_estimators*: [100, 300] — Jumlah pohon keputusan yang dibangun.

c. *max_depth*: [6] — Kedalaman maksimal pohon untuk mengontrol kompleksitas.

4. MLP Classifier (*Neural Network*):
   a. *alpha*: [0.0001, 0.001].
   b. *learning_rate_init*: [0.001].

Tabel 4.4. Hasil Evaluasi *Grid Search Cross-Validation (Top Models)*

Rank	Model	*Feature Extraction*	*Best Parameters*	*Average F1-Macro*
1	SVM (Polynomial)	IndoBERT	C = 1, degree = 3	**0.7402**
2	XGBoost	IndoBERT	Lr = 0.1, depth =6, est = 300	0.7186
3	SVM (RBF)	IndoBERT	C = 1, gamma = 'scale'	0.7174
4	*SVM (Polynomial)*	IndoTweet	C = 1, degree = 3	0.7139
5	SVM (RBF)	IndoTweet	C = 1, gamma = 'scale'	0.7054

Analisis Hasil Tuning ML:

a. Pergeseran Fitur Terbaik: Menariknya, setelah validasi silang (CV) diterapkan, fitur IndoBERT terbukti lebih stabil dan unggul dibandingkan IndoTweet yang sebelumnya memimpin pada tahap *screening* (*single split*).
b. Model Terpilih: SVM dengan Kernel *Polynomial* (Degree 3) yang menggunakan fitur IndoBERT menghasilkan skor F1-Macro rata-rata tertinggi sebesar 0.7402. Model ini menunjukkan keseimbangan terbaik antara bias dan varians.
c. Kestabilan: Skor 0.74 pada CV lebih dapat dipercaya sebagai estimasi kinerja pada data dunia nyata dibandingkan skor 0.77 pada tahap *screening*, karena telah diuji pada 5 bagian data yang berbeda.

Berdasarkan hasil komprehensif dari kedua pendekatan *tuning*, model SVM (*Polynomial*) + IndoBERT dipilih sebagai model final untuk dianalisis lebih lanjut karena efisiensi komputasi yang tinggi (dibandingkan *fine-tuning* BERT) namun tetap mempertahankan akurasi yang kompetitif dan teruji secara statistik.

3.8 Analisis Kesalahan

Evaluasi model diperdalam melalui analisis kesalahan (Error Analysis) untuk menguji reliabilitas di luar metrik standar. Menggunakan 385 data uji (20% dataset), tahap ini bertujuan mengidentifikasi pola kegagalan linguistik serta membandingkan karakteristik kesalahan antara Machine Learning dan Deep Learning. Kesalahan dikategorikan ke dalam dua taksonomi utama:

1. Kesalahan Fatal (*Fatal Errors*): Kesalahan prediksi yang berlawanan arah polaritas (Positif ke Negatif). Ini adalah jenis kesalahan yang paling berbahaya karena dapat membalikkan kesimpulan analisis opini publik.
2. Kesalahan Ambiguitas (*Ambiguity Errors*): Kesalahan klasifikasi yang melibatkan kelas Netral (Sentimen ke Netral). Kesalahan ini lebih dapat ditoleransi karena batas antara opini subjektif dan pernyataan fakta seringkali tipis.

3.8.1 Analisis Kesalahan pada *Model Machine Learning (SVM Polynomial)*

Model terbaik yang terpilih dari tahap *Hyperparameter Tuning* adalah *Support Vector Machine* (SVM) dengan kernel *Polynomial* (Degree=3) dan fitur IndoTweet Embeddings.

Distribusi Kesalahan (*Confusion Matrix*)

Berdasarkan evaluasi pada data uji, model SVM mencatatkan kinerja sebagai berikut:

1. Total Data Uji: 385 data.
2. Total Kesalahan: 56 data (Tingkat Kesalahan: 14,5%).
3. Akurasi: 85%.

Distribusi kesalahan secara spesifik adalah:

1. Kesalahan Fatal: 8 kasus (2% dari total data).
2. Kesalahan Ambiguitas: 48 kasus (12,5% dari total data).

Bedah Kasus: Kesalahan Fatal

Temuan paling menarik dari model SVM adalah ketidaksimetrisan kesalahan fatalnya.

1. Kasus Negatif diprediksi Positif (*False Optimism*): 0 Kasus.
   Model SVM menunjukkan kekokohan luar biasa dalam mengenali sentimen negatif. Tidak ada satupun tweet kritik/keluhan yang salah diklasifikasikan sebagai dukungan/positif. Ini sangat krusial untuk pemantauan isu RUU KUHAP agar tidak terjadi *underestimation* terhadap resistensi publik.
2. Kasus Positif diprediksi Negatif (*False Pessimism*): 8 Kasus.
   Seluruh kesalahan fatal terjadi pada arah ini. Contoh sampel:
   "banyak teriak darurat kitab undang undang hukum acara pidana padahal belum baca satu pasal"
   a. Label Asli: Positif (Mendukung RUU/Mengkritik penolak RUU).
   b. Prediksi: Negatif.
   c. Analisis Linguistik: Model terkecoh oleh kata-kata bermuatan negatif kuat seperti "teriak" dan "darurat". Secara sintaksis, kalimat ini adalah *kritik terhadap pengkritik* (defensif), yang secara pragmatik bermakna dukungan terhadap RUU. SVM gagal menangkap nuansa sarkasme atau kritik defensif ini.

Bedah Kasus: Kesalahan Ambiguitas

Mayoritas kesalahan (48 kasus) terjadi pada area abu-abu antara Netral dan Sentimen.

1. *Contoh:* "benar klaim polisi tangkap orang bukti pidana rancangan undang undang... memang hoaks"
2. *Analisis:* Kalimat yang berisi klarifikasi fakta (*debunking hoax*) sering dilabeli sebagai Positif (dukungan narasi), namun model memprediksinya sebagai Netral karena struktur kalimatnya yang deklaratif dan minim kata sifat emosional.

3.8.2 Analisis Kesalahan pada Model *Deep Learning (IndoBERT & IndoTweet)*

Sebagai pembanding, dilakukan analisis serupa pada model *Deep Learning* hasil *fine-tuning*. Berikut perbandingan tingkat kesalahan antara model *Deep Learning* dan model *SVM* terpilih:

Tabel 4.4. Distribusi Kesalahan Model Deep Learning vs SVM

Tipe Kesalahan	*SVM (Poly)*	*IndoBERT (Tuned)*	*IndoTweet (Tuned)*
Akurasi Total	85%	82%	80%
Total Kesalahan	56%	70%	78%
Fatal: Positif Negatif	8%	14%	15%
Fatal: Negatif Positif	0%	0%	0%
Ambiguitas (Netral)	48%	56%	63%

Analisis Kelemahan *Deep Learning*

Meskipun menggunakan arsitektur Transformer yang canggih, model *Deep Learning* (IndoBERT & IndoTweet) justru menghasilkan jumlah kesalahan fatal yang lebih tinggi (14-15 kasus) dibandingkan SVM (8 kasus).

1. Isu *Over-complexity*: Pada dataset berukuran sedang (±2.000 data), model *Deep Learning* dengan jutaan parameter cenderung mengalami kesulitan generalisasi (*overfitting* pada noise) dibandingkan SVM yang mencari *hyperplane* optimal dengan prinsip margin maksimal.

2. Contoh Kesalahan Spesifik IndoBERT:
   "rancangan undang undang... disahkan allah bakal banyak orang planga plongo bakal bilang salah apa..."
   a. Label Asli: Positif.
   b. Prediksi: Negatif.
   c. Analisis: Model gagal memahami konteks "planga plongo" yang ditujukan kepada pihak oposisi RUU. Kompleksitas kalimat yang panjang dan tidak baku menyulitkan model untuk menavigasi dependensi jarak jauh (*long-term dependency*) dalam kalimat tersebut.

3.8.3 Diskusi dan Kesimpulan Evaluasi

Berdasarkan analisis kesalahan yang komprehensif, dapat disimpulkan beberapa poin kunci:

1. Dominasi SVM: Untuk karakteristik dataset RUU KUHAP ini, model SVM (*Polynomial*) terbukti lebih unggul dan stabil dibandingkan pendekatan *Fine-Tuning* Transformer. SVM mampu meminimalkan kesalahan fatal secara signifikan.
2. Pola "Optimisme Palsu" Nihil: Baik model ML maupun DL menunjukkan performa sempurna (0 kesalahan) dalam memprediksi sentimen Negatif menjadi Positif. Ini menunjukkan fitur-fitur yang diekstraksi (terutama dari *embedding* IndoTweet) sangat kuat dalam merepresentasikan sinyal-sinyal kritik dan penolakan.
3. Tantangan Sarkasme: Kelemahan utama seluruh model terletak pada deteksi sentimen positif yang disampaikan melalui sarkasme atau serangan balik terhadap pihak kontra (*defensive sentiment*). Kata-kata negatif dalam kalimat tersebut mendominasi *attention mechanism* atau bobot fitur, sehingga model salah mengklasifikasikannya sebagai sentimen negatif.

3.9 Aspect Based Sentiment Analysis (IndoBERT)

3.9.1 Aspek Negatif

Berdasarkan hasil bedah aspek negatif, resistensi publik mengerucut pada tiga isu utama. Pertama, kekhawatiran terbesar berpusat pada perluasan wewenang aparat penegak hukum yang dinilai berlebihan dan berpotensi memicu penyalahgunaan kekuasaan (Topik 0). Kedua, publik menyoroti dampak langsung terhadap kebebasan sipil, khususnya ketakutan bahwa kritik terhadap pemerintah dapat dengan mudah dikriminalisasi/ berujung pidana (Topik 3). Ketiga, terdapat sentimen ketidakpercayaan pada prosedur legislasi yang dianggap terburu-buru dan tidak transparan, di mana publik membandingkan cepatnya pengesahan RUU ini dengan lambatnya RUU lain yang lebih mendesak seperti RUU Perampasan Aset (Topik 1 & 4).

3.9.2 Aspek Netral

Analisis aspek netral didominasi oleh percakapan yang bersifat informatif dan objektif. Mayoritas data (Topik 0 dan 1) berisi penyebaran berita faktual mengenai substansi hukum acara pidana serta pengumuman resmi dari DPR terkait pengesahan undang-undang, tanpa muatan emosi yang kuat. Selain narasi berita, teridentifikasi juga adanya noise atau gangguan data (Topik 2, 3, dan 4) berupa aktivitas spam promosi komersial yang tidak relevan, namun volumenya jauh lebih kecil dibandingkan percakapan substantif mengenai hukum.

3.9.3 Aspek Positif

Analisis sentimen positif didominasi oleh dua narasi utama: dukungan terhadap pembaruan paradigma hukum dan upaya masif meluruskan disinformasi. Pertama, publik mengapresiasi pergeseran menuju keadilan restoratif (restorative justice) yang dianggap mampu membatasi kesewenang-wenangan aparat melalui prosedur yang lebih ketat (Topik 0). Kedua, terdapat mobilisasi narasi yang kuat untuk melawan 'hoax' dan kepanikan masyarakat (Topik 1, 2, 3, dan 4), khususnya klarifikasi bahwa isu sensitif seperti penyadapan dan penangkapan tidak dilakukan

sembarangan, melainkan diatur ketat melalui undang-undang khusus dan wajib seizin pengadilan.

Conclusion

4.1 Kesimpulan

Penelitian ini dilakukan untuk memahami bagaimana masyarakat merespons isu RUU KUHAP di Platform X. Dilakukan dengan dua cara analisis utama, Analisis Jaringan Sosial (SNA) untuk melihat pola interaksi, dan Analisis Sentimen Berbasis Aspek (ABSA) untuk mengetahui sentimen pada topik-topik spesifik.

1. Dinamika Jaringan: Pembahasan publik mengenai RUU KUHAP di Platform X ternyata tidak seperti diskusi biasa, melainkan lebih sering berupa penyebaran informasi cepat dan satu arah (melalui *retweet* dan *hashtag*). Jaringan antar pengguna cenderung terpisah-pisah (terfragmentasi), yang menunjukkan bahwa isu ini lebih cepat menjadi viral daripada dibahas secara mendalam.
2. Kualitas Model Sentimen: Untuk memprediksi sentimen, kami menemukan bahwa model SVM (Support Vector Machine) dengan fitur IndoTweet adalah yang terbaik, mencapai akurasi tinggi dengan F1-Score 0.773. Ini menunjukkan bahwa model sederhana yang dibantu oleh teknologi *embedding* bahasa modern sudah cukup efektif untuk data ini.
3. Sentimen Berdasarkan Topik (ABSA): Analisis menunjukkan bahwa sentimen negatif yang paling kuat muncul pada aspek-aspek kontroversial yang berisi berita bohong atau menyesatkan (misalnya, klaster 'UNDANG_PANIK_UNDANG UNDANG_HOAX'). Ini membuktikan bahwa reaksi masyarakat sangat dipengaruhi oleh disinformasi yang beredar dalam jaringan.
4. Temuan Utama: Kesimpulannya, sentimen negatif yang kuat terbentuk karena adanya penyebaran berita bohong yang cepat oleh aktor-aktor tertentu di dalam jaringan yang terpisah-pisah di Platform X.

4.2 Saran untuk Penelitian Selanjutnya (*Future Works*)

Berdasarkan hasil penelitian ini, ada beberapa hal yang bisa dikembangkan di masa depan:

1. Penyempurnaan Model Sentimen: Membuat satu model yang bisa langsung mengidentifikasi topik sekaligus sentimen dalam satu kali proses, agar analisis lebih cepat dan efisien.
2. Analisis Jangka Panjang: Melakukan penelitian yang mengamati perubahan opini dari awal RUU diusulkan hingga setelah disahkan, untuk melihat bagaimana dinamika sentimen berubah seiring waktu.
3. Perbandingan Platform: Menguji metode yang sama pada media sosial lain di luar Platform X untuk melihat apakah pola diskusi dan sentimen yang ditemukan memiliki kesamaan atau perbedaan.
4. Analisis Aliran Informasi: Memperdalam analisis SNA dengan melihat seberapa cepat dan jauh disinformasi menyebar di jaringan.

References

[1] Veltri, G. A., & Atanasova, D. (2017). Climate change on Twitter: Content, media ecology and information sharing behaviour. *Public Understanding of Science, 26*(6), 721–737. https://doi.org/10.1177/0963662515613702

[2] Himelboim, I., Smith, M. A., Rainie, L., Shneiderman, B., & Espina, C. (2017). Classifying Twitter topic-networks using social network analysis. *Social Media + Society, 3*(1), 1–13. https://doi.org/10.1177/2056305117691545

[3] Pontiki, M., et al. (2016). SemEval-2016 Task 5: Aspect-based sentiment analysis. *Proceedings of the 10th International Workshop on Semantic Evaluation*, 19–30. https://doi.org/10.18653/v1/S16-1002

[4] Sumartias, S., Pulubuhu, D. A. T., Sudarmono, & Adi, A. N. (2023). Democracy in the Indonesian digital public sphere: Social network analysis of Twitter users' responses to the issue of nationalism knowledge test at the Corruption Eradication Commission (TWK-KPK). *Jurnal Ilmu Sosial dan Ilmu Politik*. https://doi.org/10.22146/jsp.70896

[5] Setiadi, T. (2023). Analisis jaringan opini publik tentang Pembatasan Sosial Berskala Besar di Twitter. *Jurnal Media dan Komunikasi Indonesia*. https://doi.org/10.22146/jmki.82650

[6]Sejati, P. T., Al Zami, F., Marjuni, A., Indrayani, H., & Puspitarini, I. D. (2024). Aspect-Based Sentiment Analysis for Enhanced Understanding of 'Kemenkeu' Tweets. *Journal of Applied Informatics and Computing*, 8(2), 487–498. https://doi.org/10.30871/jaic.v8i2.8558

[7] Jasim, Y. A., Saeed, M. G., & Raewf, M. B. (2024). *Analyzing Social Media Sentiment: Twitter as a Case Study.* ADCAIJ: Advances in Distributed Computing and Artificial Intelligence Journal. https://doi.org/10.14201/adcaij.28394

[8] Puluhulawa, F. Y., & Rajiyem, R. (2022). *What Do Opinion Leaders Share from the New Normal on Twitter?: A Qualitative Content Analysis.* Jurnal Ilmu Sosial dan Ilmu Politik, 26(2). https://doi.org/10.22146/jsp.71844

[9] Zitri, I., Kurniawan, C., & Rifaid, R. (2024). *Moving Public Opinion by Politicians: Action Study #AyoMoveOn2024 Through Social Media X.* Journal of Governance and Local Politics (JGLP), 7(1). https://doi.org/10.47650/jglp.v7i1.1608

[10] Suhariyanto, S., Sarno, R., Fatihah, C., & Faisal, E. (2023). Aspect Based Sentiment Analysis: systematic literature review. *Journal of Applied Intelligent System*, 5(1). https://doi.org/10.33633/jais.v5i1.3807

[11] Pertiwi, R. F. (2025). Analysis of the impact of social media on shaping public perception law enforcement in Indonesia. *Public Service and Society Journal, 1*(1), 1–12. https://doi.org/10.55942/pssj.v5i9.614

[12] Durotoye, T. (2024). Online and social media political participation: Differential effects across platforms. *Social Science Computer Review, 42*(5), 1234–1256. https://doi.org/10.1177/08944393251332640

[13] Magdaci, O., & Colleagues. (2022). Modeling the debate dynamics of political communication in social networks. *Expert Systems with Applications, 201*, 117138. https://doi.org/10.1016/j.eswa.2022

[14] Where do parties interact? Issue engagement in press releases, parliamentary questions, and Twitter. (2023). *European Journal of Political Research, 62*(4), 1020–1042. https://doi.org/10.1111/1475-6765.12729

[15] Han, R., & Colleagues. (2025). Aspect-based sentiment evolution and its correlation with review dynamics. *Knowledge-Based Systems, 304*, 112563. https://doi.org/10.1016/j.dim.2025.
[16] Aryanti, F. A. D., & Colleagues. (2025). Aspect-based sentiment analysis with LDA and IndoBERT for mental health app reviews. *Journal of Applied Informatics and Computing, 9*(1), 100–115. https://doi.org/10.30871/jaic.v9i2.8958.
[17] Wafda, A., Sari, R. F., & Raharjo, A. B. (2025). Aspect-based sentiment analysis on Twitter towards the Merdeka Curriculum using IndoBERT. *Jurnal Teknologi Informasi dan Ilmu Komputer, 12*(1), 45–56. https://doi.org/10.33480/jitk.v10i3.5692.
[18] Turangan, A. D. P., & Pratama, B. (2025). Implementation of feature extraction using BERT in aspect-based sentiment analysis. *EECCIS, 19*(1), 12–20. https://doi.org/10.21776/jeeccis.v19i2.1770.
[19] Rahayu, D., & Putra, B. (2025). The use of social media as a provocation tool: A case analysis of political conflict in Indonesia. *Journal of Law, Policy and Humanities, 4*(1), 70–86. https://doi.org/10.38035/jlph.v5i3.1233.
[20] The role of public opinion in shaping new criminal law. (2023). *ShodhKosh: Journal of Visual and Performing Arts, 4*(2), 90–101.
https://doi.org/10.29121/shodhkosh.v4.i2.2023.3298
[21] Sumartias, S., Pulubuhu, D. A. T., Sudarmono, & Adi, A. N. (2023). Democracy in the Indonesian digital public sphere: Social network analysis of Twitter users' responses to the issue of nationalism knowledge test at the Corruption Eradication Commission (TWK-KPK). *Jurnal Ilmu Sosial dan Ilmu Politik, 27*(1), 1–20. https://doi.org/10.22146/jsp.70896
[22] Irawan, D., Sensuse, D. I., Putro, P. A. W., & Prasetyo, A. (2023). Public response to the legalization of the Criminal Code Bill with Twitter data sentiment analysis. *International Journal of Advanced Computer Science and Applications, 14*(2), 282–291.
https://doi.org/10.14569/IJACSA.2023.0140236
[23] Pratama, R., & Lestari, A. (2023). Democracy on social media: The analysis of the new Criminal Code ratification polemic on Twitter. *Kajian Jurnalisme, 7*(1), 45–60. DOI: https://doi.org/10.24198/jkj.v7i1.46588.
[24] Cahyaningrum, N. I., Yoshida Fatima, D. W., Kusuma, W. A., Ramadhani, S. A., Destanto, M. R., & Nooraeni, R. (2020). Analysis of user sentiment of Twitter to Draft KUHP. Jurnal Matematika, Statistika dan Komputasi, 16(3), 273–286. https://doi.org/10.20956/jmsk.v16i3.8239
[25] Hua, Y. C., Denny, P., Wicker, J., & Taskova, K. (2024). A systematic review of aspect-based sentiment analysis: Domains, methods, and trends. Artificial Intelligence Review, 57, Article 296. https://doi.org/10.1007/s10462-024-10906-z
[26] Lakhani, A., Upadhyay, V., & Fiaidhi, J. (2022). Aspect-based sentiment analysis—Twitter. TechRxiv. https://doi.org/10.36227/techrxiv.21699203.v1
[27] Luceri, L., Deb, A., Badawy, A., & Ferrara, E. (2019). Red bots do it better: Comparative analysis of social bot partisan behavior. arXiv. https://arxiv.org/abs/1902.02765
[28] Purwitasari, D., Purnama Putra, C. B., & Raharjo, A. B. (2023). A stance dataset with aspect-based sentiment information from Indonesian COVID-19 vaccination-related tweets. Data in Brief, 47, 108951. https://doi.org/10.1016/j.dib.2023.108951
[29] Radicioni, T., Saracco, F., Pavan, E., & Squartini, T. (2020). Analysing Twitter semantic networks: The case of 2018 Italian elections. arXiv. https://arxiv.org/abs/2009.02960

[30] Tanoto, K. (2024). Investigation of challenges in aspect-based sentiment analysis enhanced using softmax function on Twitter during the 2024 Indonesian presidential election. Procedia Computer Science. https://doi.org/10.1016/j.procs.2024.01.123

Lampiran

Sumber Data (Code Scraping) :
https://colab.research.google.com/drive/1hsZehvW8pVL8h21Kw1y6HiII94E2gV3S?usp=sharing
Code :
https://drive.google.com/drive/folders/1gPwo4YEKnSekFbVOsHVyZ1oTZhuyXkpa?usp=sharing