Class Activity Data Mining I TM5
Kelompok J

Nama Anggota:

Tresnaldi Galih Pratama	(164231031)
Radam Gumelar	(164231032)
Aqila Malfa	(164231036)
Fanti Amaliyah	(164231045)
Faiz Iqbal I'tishom	(164231059)
Venedict Grinaldy Prasetyo	(164231063)

UNIVERSITAS AIRLANGGA
TEKNOLOGI SAINS DATA
SURABAYA

2025

Ringkasan Algoritma Stacking

a. Description

Stacking adalah teknik ensemble learning yang bertujuan untuk meningkatkan performa model dengan menggabungkan beberapa algoritma *machine learning* yang berbeda. Dalam pendekatan ini, beberapa model dasar *(base learners)* dilatih secara independen menggunakan dataset yang sama. Setelah itu, hasil prediksi dari setiap *base learner* digunakan sebagai input untuk model kedua yang disebut *meta-learner* atau *blender*. *Meta-learner* bertanggung jawab untuk mempelajari pola dari prediksi base learners dan menghasilkan output akhir yang lebih akurat. Teknik ini berbeda dengan metode *ensemble* lain seperti *bagging* dan *boosting* karena tidak hanya menggabungkan prediksi melalui *voting* atau *averaging,* tetapi menggunakan model lain untuk menentukan cara terbaik dalam mengkombinasikan hasil-hasil prediksi tersebut.

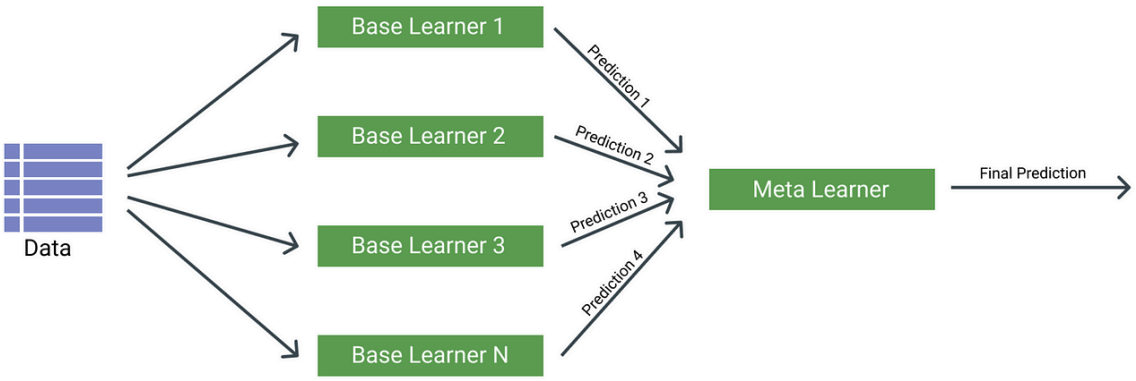

Gambar 1. Diagram cara kerja algoritma *stacking*

Struktur stacking umumnya terdiri dari dua atau lebih lapisan (layers). Lapisan pertama berisi base learners yang bisa terdiri dari berbagai jenis model, seperti *Random Forest*, *Support Vector Machine (SVM)*, *Gradient Boosting,* atau *Neural Networks*. Lapisan kedua berisi meta-learner yang biasanya berupa model sederhana seperti *Logistic Regression* atau *Decision Tree* untuk menghindari *overfitting.* Dengan pendekatan ini, stacking memungkinkan model untuk menangkap hubungan kompleks yang tidak dapat ditangkap oleh satu algoritma tunggal.

b. Primary Use

Stacking digunakan secara luas dalam berbagai aplikasi *machine learning* karena kemampuannya meningkatkan akurasi dibandingkan dengan model individual. Teknik ini bekerja dengan menggabungkan beberapa model dasar *(base models)* yang memiliki keunggulan masing-masing, lalu menggunakan model tingkat lanjut *(meta-learner)* untuk menyusun prediksi akhir yang lebih akurat. Salah satu penerapan utama stacking adalah dalam kompetisi *data science*, seperti *Kaggle* dan *Data Science Bowl*, di mana peserta sering memanfaatkannya untuk mengoptimalkan performa model dan memperoleh skor terbaik. Dengan menggabungkan pendekatan dari model yang berbeda—misalnya, *Random Forest* untuk menangkap pola non-linear

dan Regresi Logistik untuk generalisasi yang baik. *stacking* mampu memberikan hasil yang lebih stabil dan presisi dibandingkan metode individual.

Dalam konteks industri, stacking telah menjadi alat yang kuat dalam sektor keuangan, terutama untuk memprediksi harga saham, mengevaluasi risiko kredit, serta mendeteksi penipuan transaksi. Kombinasi model yang berbeda memungkinkan sistem untuk menganalisis pola data dari berbagai sudut pandang, sehingga meningkatkan ketahanan terhadap *noise* dan ketidakseimbangan data. Selain itu, di bidang kesehatan, stacking digunakan dalam diagnosis penyakit dan klasifikasi gambar medis, seperti mendeteksi kanker dari hasil pemindaian MRI atau *CT scan*. Model ini juga semakin banyak diterapkan dalam sistem pendukung keputusan medis untuk memberikan rekomendasi pengobatan berbasis data pasien.

Tak hanya terbatas pada analisis numerik dan gambar, stacking juga memainkan peran penting dalam pengolahan bahasa alami (*NLP*). Dalam aplikasi seperti *sentiment analysis*, chatbot berbasis AI, dan *machine translation*, stacking dapat menggabungkan model berbasis aturan dengan model berbasis deep learning untuk meningkatkan akurasi pemahaman dan penerjemahan bahasa. Fleksibilitas stacking dalam menangani berbagai jenis data baik numerik, citra, maupun teks menjadikannya teknik yang sangat adaptif dan efektif untuk berbagai domain, baik dalam industri maupun penelitian akademik.

c. Advantages

Salah satu keuntungan utama dari stacking adalah kemampuannya untuk meningkatkan akurasi prediksi. Dengan menggabungkan beberapa model yang memiliki karakteristik yang berbeda, stacking dapat mengurangi bias yang ada pada model tertentu, mengurangi varians, dan memperbaiki kemampuan generalisasi model. Misalnya, jika sebuah model sering membuat kesalahan dalam mengenali pola tertentu, model lain dapat mengimbangi kelemahan tersebut, sehingga prediksi keseluruhan menjadi lebih akurat.

Selain itu, stacking juga mampu mengatasi kelemahan dari model individu. Sebagai contoh, model berbasis pohon keputusan seperti *Random Forest* sangat efektif dalam menangani data dengan fitur kategorikal, tetapi mungkin tidak seoptimal itu dalam mengelola data numerik yang kompleks. Sebaliknya, model berbasis regresi atau jaringan saraf *(neural networks)* lebih baik dalam mengenali pola hubungan numerik, namun kurang tangguh terhadap noise dalam data. Dengan menggabungkan berbagai jenis model dalam stacking, sistem dapat memanfaatkan kekuatan masing-masing model.

Keunggulan lain dari stacking adalah fleksibilitasnya dalam menggabungkan model dari berbagai algoritma machine learning. Berbeda dengan metode ensemble lain seperti *bagging* atau *boosting* yang biasanya menggunakan satu jenis model dengan variasi yang berbeda, *stacking* memungkinkan penggunaan model yang sangat berbeda, seperti algoritma berbasis pohon (*Random Forest, XGBoost*), berbasis kernel (SVM), berbasis probabilitas *(Naïve Bayes)*, hingga model deep learning *(Neural Networks)*. Dengan demikian, *stacking* dapat memberikan solusi yang lebih kuat untuk berbagai jenis permasalahan dalam pemodelan data.

d. Drawbacks

Meskipun *stacking* menawarkan beberapa keuntungan, terdapat beberapa kelemahan yang perlu dipertimbangkan. Salah satunya adalah kebutuhan komputasi yang sangat besar. *Stacking* melibatkan pelatihan beberapa model dasar secara terpisah sebelum hasilnya digabungkan dalam meta-model. Proses ini dapat memerlukan waktu dan sumber daya komputasi yang signifikan, terutama jika menggunakan model yang kompleks seperti *Gradient Boosting* atau *Deep Learning*. Oleh karena itu, *stacking* mungkin tidak menjadi pilihan terbaik untuk proyek yang terbatas pada waktu atau sumber daya komputasi.

Selain itu, penerapan *stacking* dalam sistem produksi seringkali lebih rumit dibandingkan dengan model *machine learning* tradisional. Karena *stacking* memerlukan pelatihan beberapa model secara bersamaan dan penggabungan prediksi dari model-model tersebut dalam sebuah *pipeline* yang kompleks, penerapan sistem ini dalam aplikasi *real-time* membutuhkan pemrosesan tambahan. Jika implementasi ini tidak dioptimalkan dengan baik, sistem *stacking* dalam skala besar bisa menjadi sulit untuk dikelola dan memerlukan biaya tinggi untuk pemeliharaannya.

Kelemahan lain yang perlu diperhatikan adalah potensi terjadinya *overfitting*. Jika *stacking* tidak dirancang dengan hati-hati, model *meta-learner* mungkin terlalu bergantung pada pola yang ditemukan oleh *base learners*, yang dapat menyebabkan kesulitan dalam melakukan generalisasi terhadap data baru. Untuk mengurangi risiko ini, teknik seperti *cross-validation* sering diterapkan pada *base learners* dan *meta-learner* agar model dapat menghindari pembelajaran dari *noise* dalam data dan lebih fokus pada pola yang relevan.

Kesimpulan

Algoritma stacking merupakan teknik algoritma yang menggabungkan berbagai model yang berbeda untuk meningkatkan kinerja model pembelajaran mesin termasuk sebagai teknik *ensemble* yang sangat efektif. Peningkatan akurasi, kemampuan untuk menangani kelemahan model tertentu, dan fleksibilitas dalam penggunaan dengan berbagai algoritma yang terlibat didalamnya adalah beberapa keunggulan yang dimiliki metode ini.

Namun, meski *stacking* sangat bagus untuk proyek dengan kebutuhan akurasi tinggi, itu juga memiliki beberapa masalah, seperti kebutuhan komputasi yang lebih tinggi, masalah dalam implementasi produksi, dan risiko *overfitting* jika tidak diimplementasikan dengan baik sesuai dataset yang digunakan. Kendati demikian, dengan pemahaman yang mendalam terhadap dataset dan dataset digunakan, metode *stacking* dapat menjadi solusi optimal dalam pengklasifikasian dataset kita.

Referensi

Syarif, I., Zaluska, E., Prugel-Bennett, A., & Wills, G. (2012). Application of bagging, boosting and stacking to intrusion detection. In *Machine Learning and Data Mining in Pattern Recognition: 8th International Conference, MLDM 2012, Berlin, Germany, July 13-20, 2012. Proceedings 8* (pp. 593-602). Springer Berlin Heidelberg.

Chand, N., Mishra, P., Krishna, C. R., Pilli, E. S., & Govil, M. C. (2016, April). A comparative analysis of SVM and its stacking with other classification algorithm for intrusion detection. In *2016 International Conference on Advances in Computing, Communication, & Automation (ICACCA)(Spring)* (pp. 1-6). IEEE.

Sikora, R. (2017). A modified stacking ensemble machine learning algorithm using genetic algorithms. In *Artificial intelligence: Concepts, methodologies, tools, and applications* (pp. 395-405). IGi Global.