Analisis Diskriminan untuk Mengidentifikasi Faktor Risiko Diabetes Melitus pada Pima Indians

Ratu Aphrodite Cinta Aurora[a], Yasika Widiyastuti[b], Faiz Iqbal I'tishom[c], Anelia Ika Shafiyah[d]

[a](*164231009*) *Teknologi Sains Data, Fakultas Teknologi Maju dan Multidisiplin, Universitas Airlangga, Surabaya*
[b](*164231030*) *Teknologi Sains Data, Fakultas Teknologi Maju dan Multidisiplin, Universitas Airlangga, Surabaya*
[c](*164231059*) *Teknologi Sains Data, Fakultas Teknologi Maju dan Multidisiplin, Universitas Airlangga, Surabaya*
[d](*164231078*) *Teknologi Sains Data, Fakultas Teknologi Maju dan Multidisiplin, Universitas Airlangga, Surabaya*

Abstrak
Diabetes melitus merupakan tantangan kesehatan global yang memerlukan metode deteksi dini yang akurat. Penelitian ini bertujuan untuk mengklasifikasikan status diabetes (positif atau negatif) pada wanita keturunan Pima Indian berusia minimal 21 tahun menggunakan *Linear Discriminant Analysis* (LDA). Data yang digunakan adalah *Pima Indians Diabetes Dataset* yang mencakup delapan variabel prediktor (*Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin*, BMI, *DiabetesPedigreeFunction, Age*). Metodologi penelitian meliputi uji asumsi (normalitas, multikolinearitas, dan homogenitas matriks varians-kovarians) dan pembentukan model diskriminan menggunakan metode stepwise. Uji asumsi statistik (termasuk uji multikolinearitas dan Box's M) dilakukan sebelum pemodelan. Hasil analisis stepwise menunjukkan bahwa dari delapan variabel, hanya empat yang merupakan pembeda signifikan, yaitu *Glucose*, BMI, *Age*, dan *DiabetesPedigreeFunction*. Fungsi diskriminan yang dihasilkan dari keempat variabel ini menunjukkan kemampuan pemisahan yang sangat baik, dengan nilai korelasi kanonik 0,797 dan *eigenvalue* 1,739. Temuan ini mengindikasikan bahwa fungsi tersebut mampu menjelaskan sekitar 63.5% (0.797^2) varians pada status diabetes. Model ini divalidasi menggunakan matriks klasifikasi dan menunjukkan tingkat akurasi yang tinggi. Analisis diskriminan terbukti menjadi alat yang efektif dan dapat diinterpretasikan untuk memetakan faktor-faktor risiko utama diabetes.

Kata Kunci: Analisis Diskriminan, Klasifikasi, Diabetes Melitus, *Pima Indians Diabetes Dataset*, Faktor Risiko

1. Pendahuluan

1.1 Latar Belakang

Diabetes melitus telah menjadi salah satu tantangan kesehatan masyarakat global yang paling mendesak. Peningkatan prevalensinya menuntut pengembangan metode diagnostik yang akurat dan efisien untuk deteksi dini (Maniruzzaman et al., 2020). Deteksi dini sangat penting untuk mencegah komplikasi serius seperti penyakit jantung, kerusakan ginjal, dan neuropati. Dalam upaya ini, para peneliti semakin beralih ke pendekatan komputasional untuk menganalisis data medis (Tasin et al., 2022).

Dataset Pima Indians Diabetes secara khusus telah menjadi tolok ukur (benchmark) standar dalam penelitian klasifikasi diabetes, karena mencakup variabel-variabel prediktor medis yang relevan seperti kadar glukosa, indeks massa tubuh (BMI), dan usia (Chang et al., 2022). Banyak penelitian modern telah menerapkan berbagai algoritma machine learning (ML) seperti XGBoost (Li et al., 2024), Random Forest (Wang et al., 2021), dan metode hybrid lainnya untuk mencapai akurasi prediksi tertinggi pada data ini (Butt et al., 2021; Kaliappan et al., 2024).

Meskipun algoritma ML modern menunjukkan performa yang kuat, metode statistik klasik seperti Analisis Diskriminan (*Linear Discriminant Analysis* atau LDA) tetap menjadi alat yang relevan dan fundamental. LDA tidak hanya berfungsi sebagai model klasifikasi, tetapi juga memberikan pemahaman tentang variabel mana yang paling signifikan dalam membedakan kelompok (Sisodia & Sisodia, 2018). Penelitian ini bertujuan untuk menerapkan Analisis Diskriminan untuk mengklasifikasikan pasien diabetes dan non-diabetes menggunakan dataset Pima, dengan fokus pada pemenuhan asumsi statistik dan interpretasi model.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, penelitian ini berfokus pada:

1. Apakah terdapat perbedaan yang signifikan secara statistik antara kelompok pasien yang didiagnosis diabetes dan yang tidak, berdasarkan variabel prediktor (*Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin,* BMI*, DiabetesPedigreeFunction, Age*)?
2. Variabel prediktor manakah yang memiliki kontribusi paling signifikan dalam membedakan antara pasien diabetes dan non-diabetes?
3. Bagaimana model fungsi diskriminan yang optimal untuk mengklasifikasikan pasien berdasarkan dataset Pima Indians Diabetes?
4. Seberapa tinggi tingkat akurasi model diskriminan yang terbentuk dalam mengklasifikasikan pasien?

1.3 Tujuan

Sejalan dengan rumusan masalah, tujuan dari penelitian ini adalah:

1. Menguji signifikansi perbedaan rata-rata variabel prediktor antara kelompok pasien diabetes dan non-diabetes.
2. Mengidentifikasi variabel prediktor yang paling dominan dalam membedakan kedua kelompok tersebut.
3. Membentuk satu atau lebih fungsi diskriminan untuk memprediksi status diabetes pasien.
4. Mengevaluasi akurasi klasifikasi dari model diskriminan yang telah dibentuk.

1.4 Batasan Masalah

Penelitian ini memiliki batasan sebagai berikut:

1. Data yang digunakan adalah data sekunder *Pima Indians Diabetes Dataset* (Chang et al., 2022).
2. Subjek data terbatas pada wanita keturunan Indian Pima berusia minimal 21 tahun.
3. Metode analisis yang digunakan adalah Analisis Diskriminan Linier (LDA).
4. Pengujian asumsi yang dilakukan meliputi uji normalitas multivariat (Ebner et al., 2020), uji multikolinearitas (Kim, 2019), dan uji homogenitas matriks varians-kovarians (Box's M).

2. Landasan Teori

2.1 Analisis Diskriminan

Analisis Diskriminan Linier (LDA) adalah salah satu teknik statistik multivariat dan algoritma klasifikasi terawasi (*supervised*) yang paling klasik. Tujuannya adalah untuk menemukan kombinasi linier dari variabel-variabel prediktor (independen) yang paling baik dalam memisahkan dua atau lebih kelompok (variabel dependen kategorikal) (Sisodia & Sisodia, 2018).

Berbeda dengan banyak algoritma *machine learning* (misalnya, *Random Forest* atau XGBoost) yang seringkali berfokus murni pada akurasi prediksi (Wang et al., 2021; Gündoğdu, 2023), LDA beroperasi dengan mencari "fungsi diskriminan" atau hiperbidang yang memaksimalkan rasio varians antar-kelompok terhadap varians dalam-kelompok.

Model umum untuk fungsi diskriminan linier (untuk dua kelompok) adalah:

$$D = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots.. + \beta_p X_p$$

Dimana:

D : Skor diskriminan (*Discriminant Score*)

β_0 : Konstanta (Intercept)

β_i : Koefisien diskriminan (bobot) untuk variabel ke-i

X_i : Variabel independen (prediktor) ke-i

Skor D yang dihasilkan kemudian digunakan untuk mengklasifikasikan observasi. Sebuah nilai potong (*cutoff value*) akan ditentukan. Jika skor D observasi berada di atas nilai potong, ia akan diklasifikasikan ke dalam satu kelompok, dan jika di bawahnya, ia akan diklasifikasikan ke kelompok lain.

2.3 Tujuan Analisis Diskriminan

Tujuan utama dari analisis diskriminan adalah::

1. Signifikansi Perbedaan: Menguji apakah rata-rata variabel independen berbeda secara signifikan antar kelompok.
2. Identifikasi Variabel Pembeda: Menentukan variabel independen mana yang memiliki bobot terbesar atau kontribusi paling penting dalam membedakan kelompok.
3. Klasifikasi: Membangun fungsi (model) untuk mengklasifikasikan observasi baru ke dalam kelompok yang paling sesuai.
4. Evaluasi Model: Mengukur seberapa baik model yang terbentuk dalam mengklasifikasikan data (Sisodia & Sisodia, 2018).

2.3 Asumsi Analisis Diskriminan

Untuk menghasilkan model LDA yang valid, reliabel, dan optimal, beberapa asumsi statistik harus dipenuhi:

1. Normalitas Multivariat: Variabel-variabel independen (prediktor) diasumsikan berdistribusi normal multivariat dalam setiap kelompok. Pengujian asumsi ini sangat penting, meskipun seringkali sulit dilakukan secara langsung, sehingga banyak peneliti menggunakan uji turunan atau inspeksi visual (Ebner et al., 2020).
2. Homogenitas Matriks Varians-Kovarians: Matriks varians-kovarians dari variabel independen diasumsikan sama (homogen) untuk semua kelompok. Asumsi ini diuji menggunakan Uji Box's M. Jika asumsi ini tidak terpenuhi, model cenderung tidak stabil, dan Analisis Diskriminan Kuadratik (QDA) mungkin lebih tepat.
3. Tidak Adanya Multikolinearitas: Tidak boleh ada korelasi yang sangat tinggi di antara variabel-variabel independen. Multikolinearitas yang serius dapat menyebabkan estimasi koefisien diskriminan menjadi tidak stabil dan interpretasi menjadi menyesatkan (Kim, 2019).
4. Penanganan Data: Meskipun bukan asumsi formal, LDA sensitif terhadap outlier. Data juga harus dibersihkan dari nilai yang hilang (*missing values*) agar model dapat berjalan dengan baik (Torkey et al., 2022).

2.4 Pengujian Model dan Evaluasi

2.4.1 Uji Signifikansi Model (Wilks' Lambda)

Wilks' Lambda (Λ) adalah statistik yang digunakan untuk menguji signifikansi model diskriminan secara keseluruhan. Statistik ini mengukur seberapa baik model membedakan antar kelompok. Nilai Wilks' Lambda berkisar antara 0 hingga 1.

1. Nilai Λ mendekati 0 menunjukkan bahwa rata-rata kelompok sangat berbeda (pemisahan baik).
2. Nilai Λ mendekati 1 menunjukkan bahwa rata-rata kelompok tidak berbeda (pemisahan buruk).

Signifikansi Wilks' Lambda diuji menggunakan transformasi *Chi-Square* atau F. Jika nilai signifikansi $< \alpha$ (0.05), maka disimpulkan bahwa model diskriminan secara signifikan mampu membedakan antar kelompok.

2.4.2 Korelasi Kanonik (Canonical Correlation)

Korelasi kanonik mengukur tingkat asosiasi atau kekuatan hubungan antara fungsi diskriminan (skor D) dengan variabel dependen (kelompok). Nilainya berkisar antara 0 dan 1. Kuadrat dari korelasi kanonik (*Canonical* R^2) menunjukkan proporsi varians pada variabel dependen (kelompok) yang dapat dijelaskan oleh fungsi diskriminan tersebut. Nilai yang lebih tinggi menunjukkan fungsi yang lebih baik dalam membedakan kelompok.

2.5 Tinjauan Pustaka Variabel Prediktor

Variabel-variabel yang digunakan dalam Pima Indians Diabetes Dataset telah diakui secara luas dalam literatur medis dan analitika data sebagai faktor risiko kunci untuk diabetes. Banyak penelitian yang bertujuan memprediksi diabetes menggunakan variabel-variabel ini sebagai dasar (Maniruzzaman et al., 2020; Tasin et al., 2022).

1. *Glucose* (Glukosa): Ini adalah variabel prediktor yang paling penting secara klinis. Kadar glukosa plasma yang tinggi (hiperglikemia) adalah tanda diagnostik utama diabetes. Hampir setiap model prediksi diabetes, termasuk yang menggunakan *feature selection*, mengidentifikasi glukosa sebagai kontributor paling signifikan (Gündoğdu, 2023; Kaliappan et al., 2024).

2. BMI (*Body Mass Index*): BMI adalah ukuran obesitas. Obesitas, khususnya obesitas sentral, merupakan faktor risiko utama untuk resistensi insulin dan pengembangan diabetes tipe 2 (Sisodia & Sisodia, 2018).
3. Age (Usia): Prevalensi diabetes tipe 2 meningkat secara signifikan seiring bertambahnya usia. Ini menjadikannya faktor demografis fundamental dalam model risiko (Chang et al., 2022).
4. Insulin: Variabel ini mengukur kadar insulin serum 2 jam. Pada tahap awal diabetes tipe 2 atau pre-diabetes, tubuh mungkin memproduksi insulin dalam jumlah besar (hiperinsulinemia) untuk mengkompensasi resistensi insulin. Pada tahap selanjutnya, produksi insulin bisa menurun. Nilai '0' pada variabel ini dalam dataset Pima sering ditafsirkan sebagai data yang hilang (*missing*) dan memerlukan penanganan khusus (Torkey et al., 2022).
5. Pregnancies (Kehamilan) dan *DiabetesPedigreeFunction*: *Pregnancies* relevan karena riwayat diabetes gestasional (diabetes selama kehamilan) meningkatkan risiko diabetes tipe 2 di kemudian hari. *DiabetesPedigreeFunction* adalah skor yang mengukur kemungkinan diabetes berdasarkan riwayat keluarga (faktor genetik). Kedua variabel ini menangkap faktor risiko historis dan genetik (Maniruzzaman et al., 2020).
6. *BloodPressure* (Tekanan Darah) dan *SkinThickness* (Tebal Lipatan Kulit): Tekanan darah tinggi (hipertensi) sering terjadi bersamaan dengan diabetes sebagai bagian dari sindrom metabolik. *SkinThickness* (tebal lipatan kulit trisep) adalah metode lain untuk memperkirakan lemak tubuh. Kedua variabel ini, bersama dengan BMI, membantu melengkapi gambaran profil metabolik pasien (Butt et al., 2021).

Banyak studi *feature selection* (Alhussan et al., 2023; Kaliappan et al., 2024) telah mengkonfirmasi bahwa Glucose, BMI, Age, dan Insulin secara konsisten muncul sebagai prediktor terkuat, yang memvalidasi penggunaan variabel-variabel ini dalam analisis diskriminan.

3. Sumber Data dan Metodologi

3.1 Sumber Data

Dataset yang digunakan dalam penelitian ini adalah Pima Indians Diabetes Dataset. Data ini berasal dari hasil riset oleh National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK), Amerika Serikat. Tujuan utama dari dataset ini adalah untuk memprediksi secara diagnostik apakah seorang pasien menderita diabetes atau tidak berdasarkan sejumlah pengukuran dan faktor yang tercantum di dalam dataset tersebut. Dataset ini memiliki beberapa batasan dalam pemilihan sampel, yaitu seluruh pasien yang menjadi responden adalah perempuan keturunan suku Indian Pima serta tiap observasi memiliki kategori dengan usia minimal 21 tahun. Dataset ini bersifat data sekunder, hal ini tidak melakukan pengumpulan data secara langsung melainkan menggunakan data publik yang tersedia dan terbuka melalui *platform* UCI *Machine Learning Repository*.

Secara keseluruhan, dataset ini berjumlah 768 observasi, terdiri atas 8 variabel independen dan 1 variabel dependen (*Outcome*). Namun, untuk menjaga keseimbangan antara kelas positif dan negatif serta menyesuaikan dengan kebutuhan analisis diskriminan yang memerlukan jumlah sampel relatif seimbang per kelas, data ini kemudian dilakukan proses *resampling* (*undersampling*). Berikut adalah variable variabel yang akan digunakan dalam proses analisis :

Tabel 1. Variabel Penelitian

Variabel	Nama Variabel	Keterangan
X1	*Pregnancies*	Jumlah Kehamilan yang pernah dialami
X2	*Glucose*	Kadar glukosa
X3	*BloodPressure*	Tekanan darah diastolik
X4	*SkinThickness*	Ketebalan lipatan kulit
X5	Insulin	Konsentrasi insulin serum
X6	BMI	Indeks massa tubuh yang dihitung dari berat dan tinggi
X7	*DiabetesPedigreeFunction*	Indeks riwayar keluarga dan risiko genetik terhadap diabets
X8	*Age*	Usia responden
Y	*target_diabetes*	Kelas target yang menunjukkan status diabetes (1 = positif, 0 = negatif)

3.2 *Metodologi*

Pada penelitian ini, digunakan metode analisis diskriminan yang diolah dengan bantuan perangkat lunak SPSS Statistics. Metode ini digunakan untuk membedakan dua atau lebih kelompok berdasarkan variabel variabel prediktor yang ada dan bersifat kuantitatif. Analisis diskriminan dalam penelitian ini juga dilakukan penentuan variabel yang paling berpengaruh dalam membedakan kelompok serta membentuk fungsi klasifikasi yang dapat digunakan untuk memprediksi suatu objek terhadap kelompok tertentu. Berikut adalah tahap tahap dalam penelitian ini yang akan dilakukan untuk mencapai tujuan utama penelitian diantaranya:

1. Penentuan Ukuran Sampel

   Dataset awal dari platform UCI Machine Learning Repository terdiri dari 768 observasi. Berdasarkan pertimbangan keseimbangan kelas dan efisiensi analisis yang akan dilakukan, penelitian ini akan menggunakan 200 observasi sebagai sampel akhir. Ukuran sampel tersebut menggunakan rumus Slovin yang menentukan jumlah sampel representatif

2. Pengambilan Sampel (*Resampling*)

   Pengambilan sampel dilakukan menggunakan metode random undersampling, yaitu memilih secara acak 100 data dari tiap kelompok. Teknik ini dipilih agar proporsi antar kelas menjadi seimbang sehingga hasil analisis tidak menimbulkan bias yang tinggi.

3. *Preprocessing* dan Eksplorasi Data

   Proses ini terjadi di tahap awal. Proses ini akan dilakukan pemeriksaan terhadap data untuk memastikan bahwa data memenuhi dan dapat dilakukan analisis lebih lanjut. Langkah ini mencakup identifikasi nilai yang hilang, deteksi nilai ekstrem (outliers), serta pemeriksaan format data agar sesuai dengan kebutuhan analisis. Sebagai tambahan, dilakukan beberapa tahap seperti proses transformasi data untuk menyamakan skala data yang berbeda. Apabila ditemukan data yang tidak sesuai, dilakukan pembersihan atau penyesuaian data agar hasil analisis sesuai.

4. Uji Asumsi Analisis Diskriminan

   Kemudian, proses dilanjutkan dengan pengecekan beberapa asumsi. Dilakukan beberapa uji asumsi agar hasil analisis valid. Hal ini mencakup uji normalitas multivariat untuk memastikan bahwa data tiap kelompok memiliki distribusi normal. Kemudian, homogenitas matriks kovarians antar kelompok yang diuji menggunakan Box's M Test, sedangkan uji multikolinearitas antar variabel diperiksa melalui matriks korelasi. Apabila asumsi asumsi tersebut terpenuhi, maka analisis dapat dilanjutkan.

5. Pemilihan Variabel

   Setelah data memenuhi asumsi, proses kemudian dilanjutkan dengan pemilihan variabel menggunakan metode stepwise. Teknik ini secara otomatis memilih variabel variabel independen yang memiliki kontribusi secara signifikan. Proses ini dilakukan dan disajikan secara bertahap, yaitu dengan menambahkan atau mengeluarkan variabel berdasarkan nilai signifikansi statistik. Hasilnya adalah variabel variabel yang sesuai akan membentuk fungsi diskriminan yang paling efektif.

6. Pembentukan Fungsi Diskriminan

   Proses dilanjutkan dengan pembentukan fungsi diskriminan. Hal ini dilakukan secara otomatis dalam proses pembentukan dalam analisis diskriminan yang menghitung koefisien untuk masing masing variabel, sehingga diperoleh fungsi yang mampu memisahkan kelompok berdasarkan kombinasi variabel independen. Koefisien koefisien tersebut menunjukkan besar pengaruh setiap variabel terhadap kemampuan fungsi dalam membedakan kelompok.

7. Uji Signifikansi dan Klasifikasi Model

   Proses ini akan dilakukan analisis dari hasil nilai fungsi centroid. Hal ini berisi nilai rata rata skor diskriminan dari masing-masing kelompok yang menunjukkan posisi setiap kelompok pada fungsi diskriminan. Nilai-nilai centroid yang dihasilkan tersebut kemudian dimasukkan ke dalam rumus cutting score yang berfungsi sebagai nilai batas klasifikasi. Cutting score akan digunakan untuk menentukan suatu observasi akan masuk dalam kelompok tertentu. Jika nilai diskriminannya lebih dekat ke centroid kelompok tertentu, data tersebut akan diklasifikasikan ke kelompok pertama, dan seterusnya.

   Setelah fungsi dan cutting score ditentukan, tahap selanjutnya adalah evaluasi ketepatan model melalui tabel Classification Results. Hal ini akan didapatkan jumlah data yang diklasifikasikan dengan benar dan salah serta persentase ketepatan klasifikasi secara keseluruhan. Nilai tersebut digunakan sebagai indikator akurasi model diskriminan yang telah dihasilkan.

8. Interpretasi Hasil Analisis dan Kesimpulan

   Tahap terakhir adalah interpretasi hasil analisis. Hal ini akan dilakukan penarikan interpretasi serta kesimpulan dari hasil yang ada. Melalui serangkaian tahapan analisis yang telah dilakukan, secara keseluruhan akan diperoleh gambaran mengenai hasil analisis diskriminan terhadap data yang digunakan. Hasil ini juga menjadi dasar dalam penarikan temuan yang relevan dengan tujuan penelitian.

4. Analisis dan Pembahasan

4.1 Statistika Deskriptif

Analisis statistik deskriptif dilakukan untuk mengetahui gambaran umum mengenai karakteristik data yang digunakan dalam proses analisis yang akan dilakukan. Dataset *Pima Indians Diabetes* memiliki variabel bertipe data numerik. Pada data asli ini juga tidak ditemukan adanya nilai kosong (*missing value*). Namun, setelah dilakukan pemeriksaan lebih lanjut, teradapt nilai nilai yang tidak logis pada variabel tertentu. Hal ini terdapat pada variabel *Glucose, BloodPressure, SkinThickness*, Insulin, dan BMI. Pada data, ditemukan bahwa terdapat beberapa nilai nol yang secara medis tidak mungkin bernilai tersebut. Oleh karena itu, nilai nol tersebut dianggap sebagai data yang hilang. Berdasarkan hasil identifikasi, terdapat 5 nilai hilang pada variabel *Glucose*, 35 nilai hilang pada *BloodPressure*, 227 nilai hilang pada *SkinThickness*, 374 nilai hilang pada Insulin, dan 11 nilai hilang pada BMI. Nilai nilai yang hilang tersebut kemudian akan diimputasi menggunakan nilai median untuk masing masing variabel agar distribusi tetap representatif dan tidak menimbulkan bias terhadap hasil analisis nantinya. Kemudian, dilakukan analisis secara statistik deskriptif yang disajikan dalam Tabel 2 sebagai berikut :

Tabel 2. Statistika Deskriptif Tiap Variabel

Nama Variabel	***Mean***	***Median***	**Standar Deviasi**	***Min***	***Max***
Pregnancies	3,85	3	3,37	0	17
Glucose	121,66	117	30,44	44	199
BloodPressure	72,39	72	12,1	24	122
SkinThickness	29,11	29	8,79	7	99
Insulin	140,67	125	86,38	14	846
BMI	32,46	32.3	6,88	18,2	67,1
DiabetesPedigreeFunction	0,47	0,37	0,33	0,078	2,42
Age	33,24	29	11,76	21	81
target_diabetes	0,35	0	0,48	0	1

Berdasarkan hasil deskriptif pada Tabel 2, rata-rata jumlah kehamilan (*Pregnancies*) didapati dalam data sebanyak sekitar 4 kali, dengan kadar glukosa (*Glucose*) rata rata 121,66 mg/dL yang menunjukkan adanya responden dengan kadar gula darah rerata yang cukup tinggi. Kemudian, tekanan darah diastolik (*BloodPressure*) memiliki rata-rata 72,39 mmHg, hal ini masih masih termasuk dalam kategori normal,

sedangkan ketebalan kulit (*SkinThickness*) rata-rata 29,11 mm menunjukkan rerata lemak bawah kulit antar responden. Lalu, kadar Insulin dalam tabel didapati memiliki rata rata sebesar 140,67 dengan sebaran yang tinggi, serta nilai rata-rata BMI sebesar 32,46 mengindikasikan bahwa sebagian besar responden mengalami obesitas yang ringan. Didapati pula terkait nilai rerata *DiabetesPedigreeFunction* yang sebesar 0,47, hal ini menunjukkan tingkat risiko genetik yang berada dalam kategori sedang, kemudian rata rata usia (*Age*) responden yang akan dilakukan analisis berada pada umur kurang lebih 33 tahun, hal ini menandakan dominasi kelompok berada pada usia dewasa. Secara keseluruhan, data memberikan nilai *outcome* status diabetes pada populasi ini sekitar 35% responden terdiagnosis diabetes dan 65% tidak terdiagnosis, sehingga proses akan dilakukan resampling untuk menyeimbangkan data untuk analisis diskriminan selanjutnya.

4.2 Exploratory Data Analysis

4.2.1 Distribusi Data Menggunakan Histogram

Histogram digunakan untuk memvisualisasikan sebaran frekuensi dari delapan variabel numerik, yang mana menunjukkan pola distribusi data bervariasi.

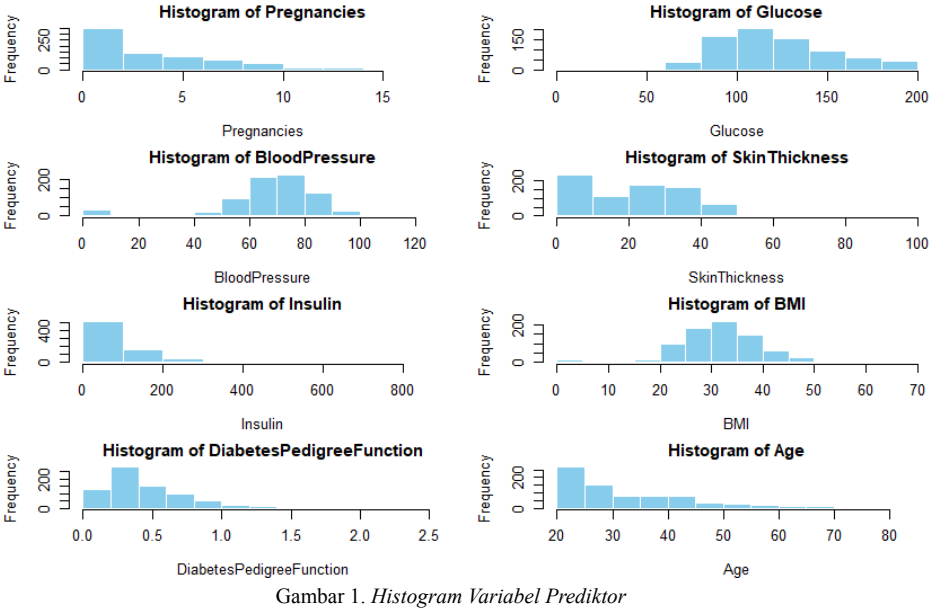

Gambar 1. *Histogram Variabel Prediktor*

Interpretasi :

1. Pregnancies : Distribusi *Pregnancies* menunjukkan sebaran yang cenderung asimetris dengan *skewness* ke kanan. Sebagian besar data berada pada rentang 0 hingga 5 kali kehamilan, menunjukkan bahwa mayoritas responden memiliki riwayat kehamilan rendah. Hanya sebagian kecil individu yang memiliki jumlah kehamilan lebih dari 10 kali, sehingga distribusi data menurun tajam di sisi kanan.
2. Glucose : Variabel *Glucose* memiliki distribusi yang relatif mendekati normal dengan sedikit *skewness* ke kanan. Nilai glukosa terbanyak berada di kisaran 90 hingga 130, menunjukkan bahwa sebagian besar responden memiliki kadar glukosa dalam rentang yang tergolong normal hingga sedikit meningkat. Beberapa nilai ekstrem di atas 180 mengindikasikan keberadaan individu dengan kadar glukosa tinggi yang relatif jarang.
3. BloodPressure : Distribusi *BloodPressure* terlihat cukup simetris dengan konsentrasi data di sekitar nilai tengah, khususnya pada kisaran 60 hingga 80. Hal ini menunjukkan bahwa tekanan darah mayoritas responden berada pada kategori normal. Namun, terdapat sedikit penyebaran ke arah nilai rendah dan tinggi, menandakan adanya variasi kecil pada tekanan darah di populasi.

4. SkinThickness : Variabel *SkinThickness* menunjukkan distribusi yang sedikit miring ke kanan. Sebagian besar data berada dalam rentang 10 hingga 40, menandakan bahwa ketebalan lipatan kulit umumnya rendah hingga sedang. Nilai yang sangat tinggi di atas 60 jarang ditemukan, sehingga distribusi menurun di sisi kanan grafik.
5. Insulin : Distribusi *Insulin* menunjukkan *skewness* ke kanan yang sangat kuat. Sebagian besar nilai insulin berkumpul pada rentang 0 hingga 100, sedangkan beberapa nilai ekstrem mencapai lebih dari 600. Pola ini menunjukkan adanya perbedaan besar antara individu dengan kadar insulin rendah dan sangat tinggi, serta kemungkinan adanya outlier yang signifikan.
6. BMI (Body Mass Index) : Variabel *BMI* memperlihatkan distribusi yang relatif normal dengan puncak pada kisaran 25 hingga 35. Sebagian besar responden memiliki indeks massa tubuh dalam kategori berat badan normal hingga obesitas ringan. Distribusi ini menurun secara perlahan ke arah kanan dan kiri, menandakan bahwa ekstremitas nilai BMI jarang terjadi.
7. DiabetesPedigreeFunction : Distribusi *DiabetesPedigreeFunction* tampak sangat miring ke kanan. Sebagian besar nilai berada di bawah 0.5, menunjukkan bahwa mayoritas responden memiliki riwayat genetik diabetes yang rendah. Meskipun demikian, terdapat beberapa nilai tinggi di atas 1.5 yang mengindikasikan adanya individu dengan risiko keturunan diabetes yang cukup besar.
8. Age : Variabel *Age* menunjukkan distribusi dengan *skewness* ke kanan. Sebagian besar responden berusia di bawah 40 tahun, sedangkan jumlah individu menurun tajam pada kelompok usia di atas 50 tahun. Hal ini menunjukkan bahwa populasi penelitian didominasi oleh responden usia muda hingga paruh baya, dengan sedikit representasi dari kelompok lanjut usia.

4.2.2 Visualisasi Variabel Target

Variabel 'Outcome' merupakan variabel target (dependen) pada penelitian ini yang bersifat kategorikal, dengan nilai '0' untuk 'Tidak Diabetes' dan '1' untuk 'Diabetes'. Visualisasi variabel ini bertujuan untuk memahami komposisi dan distribusi dari kedua kelas tersebut.

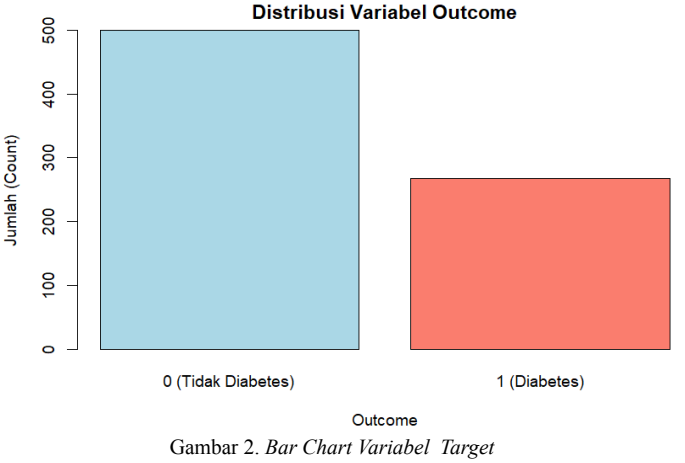

Gambar 2. *Bar Chart Variabel Target*

Pada grafik di atas, variabel *Outcome* menunjukkan distribusi kategori yang tidak seimbang antara responden yang terdiagnosis diabetes dan yang tidak. Kelompok dengan nilai 0 (Tidak Diabetes) memiliki jumlah yang lebih tinggi, yaitu sekitar 500 individu, sedangkan kelompok dengan nilai 1 (Diabetes) berjumlah sekitar 260 individu. Hal ini menandakan adanya ketidakseimbangan kelas (*class imbalance*) pada data. Karena variabel ini bersifat kategorik, proses transformasi data tidak dilakukan pada variabel *Outcome*. Namun, untuk mengatasi ketidakseimbangan distribusi tersebut, penyesuaian proporsi kelas dapat dilakukan pada tahap analisis lanjutan, misalnya melalui teknik *resampling*, agar model prediksi yang dibangun tidak bias terhadap kelas mayoritas.

4.3 Uji Asumsi

4.3.1 Uji Asumsi Normalitas

H_0: Data berdistribusi normal

H_1: Data tidak berdistribusi normal

Tabel 3. Asumsi Normalitas

Variable	*Death_Event*	KS	SW
Pregnancies	0	,200	,621
	1	,200	,839
Glucose	0	,200	,395
	1	,200	,015
BloodPressure	0	,200	,188
	1	,200	,069
SkinThickness	0	,200	,074
	1	,174	,193
Insulin	0	,200	,098
	1	,200	,014
BMI	0	,200	,662
	1	,200	,020
DiabetesPedigreeFunction	0	,200	,883
	1	,200	,430
Age	0	,200	,790
	1	,200	,713

Pada tabel uji asumsi normalitas menggunakan metode Kolmogorov-Smirnov dan Shapiro-Wilk pada tabel di atas, seluruh variabel memiliki nilai signifikansi (Sig.) lebih besar dari 0,05. Hal ini menunjukkan bahwa tidak terdapat cukup bukti untuk menolak hipotesis nol (H_0), sehingga dapat disimpulkan bahwa data pada masing-masing variabel berdistribusi normal, baik pada kelompok *target_diabetes* = 0 maupun *target_diabetes* = 1. Dengan demikian, data memenuhi asumsi normalitas dan layak digunakan untuk analisis selanjutnya.

4.3.2 Uji Asumsi Homogenitas

H_0 : Matriks kovarians bersifat homogen

H_1 : Matriks kovarians tidak bersifat homogen

Tabel 4 Output. *Box's M*

Box's M	9,184
F	,898
df 1	10
df 2	187429.482
Sig.	,534

Pada tabel *Box's M* hasil pada tabel di atas, diperoleh nilai signifikansi sebesar 0,534 (> 0,05). Hal ini menunjukkan bahwa tidak terdapat perbedaan yang signifikan pada matriks kovarians antar kelompok. Dengan demikian, hipotesis nol (H_0) yang menyatakan bahwa matriks kovarians populasi adalah sama tidak ditolak. Oleh karena itu, dapat disimpulkan bahwa data memenuhi asumsi kesamaan matriks kovarians (homogenitas kovarians), sehingga analisis dapat dilanjutkan.

4.3.3 Uji Asumsi Multikolinieritas

Tabel 5. *Pooled Within-Groups Matrices*

	Pregnancies	*Glucose*	*BloodPressure*	*SkinThickness*	*Insulin*	*BMI*	*DiabetesPedigreeFunction*	*Age*
Pregnancies	1,000							
Glucose	,084	1,000						
BloodPressure	,037	,151	1,000					
SkinThickness	,013	,006	,047	1,000				
Insulin	,089	,490	-,016	-,050	1,000			
BMI	-,184	,058	,193	-,031	,091	1,000		
DiabetesPedigree Function	,019	,054	-,030	,117	,022	,126	1,000	
Age	,055	,134	,270	,013	,112	,154	,061	1,000

Pada table matriks korelasi hasil uji asumsi multikolinearitas pada tabel *Pooled Within-Groups Matrices* di atas, terlihat bahwa nilai korelasi antarvariabel independen berada di bawah 0,80. Hal ini menunjukkan bahwa tidak terdapat hubungan yang sangat kuat antar variabel bebas yang dapat menimbulkan masalah multikolinearitas. Dengan demikian, dapat disimpulkan bahwa tidak terjadi multikolinearitas dalam data, sehingga seluruh variabel independen layak digunakan secara simultan dalam analisis multivariat.

4.3.4 Uji Asumsi Outlier

Tabel 6.*Chisquare Crit Number*

Alpha	0,01
df	8
Chisq Crit	26,12

Pada tabel *Chisquare Crit Number* hasil pengujian outlier multivariat menggunakan Jarak Mahalanobis, diperoleh nilai maksimum sebesar 26.1246. Nilai ini kemudian dibandingkan dengan nilai kritis X^2 pada tingkat signifikansi 0.1%, yang juga sebesar 26.1246. Karena nilai Jarak Mahalanobis maksimum tidak melebihi ambang batas kritis, maka keputusan yang diambil adalah gagal menolak H_0. Hal ini menginterpretasikan bahwa data telah bebas dari outlier multivariat, sehingga asumsi normalitas multivariat dapat terpenuhi dan analisis diskriminan dapat dilanjutkan.

4.4 Analisis Diskriminan

Analisis diskriminan digunakan untuk membedakan antara dua kelompok individu, yaitu kelompok yang tidak terkena diabetes (diberi kode 0) dan kelompok yang terkena diabetes (diberi kode 1), berdasarkan sejumlah variabel prediktor.

4.4.1 Test of Equality of Group Means

Sebelum membentuk fungsi diskriminan, terlebih dahulu dilakukan uji *Equality of Group Means* untuk mengetahui apakah setiap variabel memiliki perbedaan yang signifikan antara kelompok diabetes dan non-diabetes. Hasil uji ini ditampilkan pada tabel berikut.

Tabel 7. *Test of Equality of Group Means*

Variabel	Wilks' Lambda	F	df1	df2	Sig.
Pregnancies	.925	16.092	1	198	.000
Glucose	.701	84.254	1	198	.000
BloodPressure	.977	4.735	1	198	.031
SkinThickness	.988	2.370	1	198	.125
Insulin	.871	29.403	1	198	.000
BMI	.924	16.327	1	198	.000
DiabetesPedigreeFunction	.962	7.829	1	198	.006
Age	.964	7.343	1	198	.007

H_0: Variabel tidak berpengaruh signifikan dalam pengelompokan.

H_1: Variabel berpengaruh signifikan dalam pengelompokan.

Hasil *Test of Equality of Group Means* menunjukkan bahwa variabel *Pregnancies, Glucose, BloodPressure, Insulin,* BMI, *DiabetesPedigreeFunction,* dan *Age* memiliki nilai Sig. < 0,05, sehingga keputusan yang diambil adalah menolak H_0, yang berarti terdapat perbedaan signifikan antara rata-rata nilai variabel-variabel tersebut pada kelompok diabetes dan non-diabetes. Dengan demikian, variabel-variabel tersebut berpengaruh signifikan dalam membedakan kedua kelompok.

Sebaliknya, variabel *SkinThickness* memiliki nilai Sig. = 0,125 (> 0,05), sehingga keputusan yang diambil adalah gagal menolak H_0. Dengan demikian, dapat disimpulkan bahwa *SkinThickness* tidak berpengaruh signifikan dalam membedakan kelompok diabetes dan non-diabetes serta tidak dianggap berkontribusi pada pemisahan kelompok..

4.4.2 Variables Entered/Removed

Selanjutnya dilakukan analisis *stepwise discriminant*, di mana variabel dimasukkan secara bertahap berdasarkan kontribusinya dalam meningkatkan kemampuan diskriminan model. Proses dan hasil pemilihan variabel ditunjukkan pada tabel berikut.

Tabel 8. *Variabel Entered/Removed*

Step		Wilks' Lambda							
						Exact F			
	Entered	Statistic	df1	df2	df3	Statistic	df1	df2	Sig.
1	*Glucose*	.701	1	1	198.000	84.254	1	198.000	.000
2	*Age*	.664	2	1	198.000	49.762	2	197.000	.000
3	BMI	.628	3	1	198.000	38.682	3	196.000	.000
4	*Pregnancies*	.593	4	1	198.000	33.499	4	195.000	.000

H_0: Variabel yang dimasukkan tidak meningkatkan kemampuan diskriminan model secara signifikan.

H_1: Variabel yang dimasukkan meningkatkan kemampuan diskriminan model secara signifikan.

Proses pemilihan variabel dilakukan secara bertahap (*stepwise*) dengan tujuan memperoleh kombinasi variabel terbaik yang mampu membentuk fungsi diskriminan paling optimal. Berdasarkan hasil analisis, pada langkah pertama variabel *Glucose* dipilih karena memiliki kemampuan diskriminasi paling tinggi, ditunjukkan oleh nilai *Wilks' Lambda* terendah dan nilai F tertinggi.

Pada langkah kedua, variabel *Age* dimasukkan ke dalam model. Penambahan variabel ini menurunkan nilai *Wilks' Lambda* menjadi 0,664, yang berarti kemampuan diskriminan meningkat. Langkah ketiga menambahkan variabel BMI, yang kembali memperkuat fungsi diskriminan dengan menurunkan *Wilks' Lambda* lebih lanjut. Pada langkah keempat, variabel *Pregnancies* dimasukkan dan menjadi variabel final yang melengkapi model.

Variabel *Glucose, Age,* BMI, dan *Pregnancies* terpilih karena secara bertahap memberikan peningkatan signifikan terhadap kemampuan model dalam membedakan kelompok individu diabetes dan non-diabetes. Hal ini juga didukung oleh nilai signifikansi (Sig. < 0,05) pada setiap langkah, sehingga keputusan yang diambil adalah menolak H_0 dan menerima H_1, yang berarti bahwa setiap variabel yang dimasukkan meningkatkan kemampuan diskriminan model secara signifikan.

Kombinasi akhir dari keempat variabel tersebut merupakan model terbaik dalam membentuk fungsi diskriminan yang mampu memisahkan kedua kelompok secara efektif. Variabel *Glucose* memiliki kontribusi paling dominan, sedangkan penambahan *Age,* BMI, dan *Pregnancies* memberikan penguatan bertahap terhadap kemampuan klasifikasi model.

4.4.3 Variables in the Analysis

Setelah variabel-variabel utama terpilih, dilakukan analisis terhadap nilai *Tolerance* dan *F to Remove* untuk memastikan tidak terjadi multikolinearitas antar variabel dan menilai kontribusi masing-masing variabel terhadap model. Hasilnya disajikan pada tabel berikut.

Tabel 9. *Variables in the Analysis*

Step		Tolerance	F to Remove
1	*Glucose*	1.000	84.254
2	*Glucose*	.982	88.919
	Age	.982	11.010
3	*Glucose*	.981	77.748
	Age	.961	13.720
	BMI	.975	11.313
4	*Glucose*	.973	63.335
	Age	.955	14.780
	BMI	.936	15.275
	Pregnancies	.952	11.648

Tabel *Variables in the Analysis* menampilkan nilai *Tolerance* dan *F to Remove* untuk setiap variabel pada tiap langkah analisis. Nilai *Tolerance* yang mendekati 1,00 menunjukkan bahwa tidak terdapat masalah multikolinearitas yang serius antar variabel prediktor, sehingga masing-masing variabel bersifat independen dan layak dipertahankan dalam model.

Selain itu, nilai *F to Remove* yang tinggi pada setiap variabel menunjukkan bahwa penghapusan variabel tersebut akan menurunkan kemampuan model dalam membedakan kelompok secara signifikan. Sebagai contoh, pada Step ke-4, nilai *F to Remove* mencapai 63,335 untuk variabel *Glucose* dan 15,275 untuk BMI, yang menegaskan bahwa kedua variabel tersebut memiliki peran penting dalam mempertahankan kekuatan diskriminasi model.

Dengan demikian, seluruh variabel yang terdapat dalam model akhir yaitu *Glucose, Age,* BMI, dan *Pregnancies* dipertahankan karena masing-masing memberikan kontribusi signifikan terhadap kemampuan fungsi diskriminan dalam memisahkan kelompok individu yang terkena diabetes dan yang tidak.

4.4.4 Function at Group Centroid

Langkah berikutnya adalah melihat nilai *Function at Group Centroid* untuk masing-masing kelompok. Nilai ini menunjukkan rata-rata skor diskriminan dari tiap grup dan membantu menentukan batas pemisahan *(cutting score*) antar kelompok. Hasilnya ditampilkan pada tabel berikut.

Tabel 10. *Function at Group Centroid*

	Function
target_diabetes	**1**
0	-.825
1	.825

Nilai *centroid* (rata-rata skor diskriminan) untuk kelompok non-diabetes adalah -0,825, sedangkan untuk kelompok diabetes adalah 0,825. Perbedaan yang cukup jauh dan tanda yang berlawanan antara kedua nilai ini menunjukkan bahwa fungsi diskriminan mampu memisahkan kedua kelompok dengan baik.

Cutting score dihitung dengan rumus:

$$Z_{CU} = \frac{(N_A \times Z_B) + (N_B \times Z_A)}{N_A + N_B}$$

Keterangan:

Z_{CU}: *Cutting Score*

N_A: Jumlah anggota grup Non-Diabetes = 100

N_B: Jumlah anggota grup Diabetes = 100

Z_A: Nilai *centroid* grup Non-Diabetes = -0.825

Z_B: Nilai *centroid* grup Diabetes = 0.825

Perhitungan *Cutting Score*:

$$Z_{CU} = \frac{(100\times 0{,}825) + (100 \times (-0{,}825))}{100 + 100}$$

$$Z_{CU} = \frac{(8{,}25) + (-8{,}25))}{200}$$

$$Z_{CU} = \frac{0}{200}$$

$$Z_{CU} = 0$$

Dengan demikian, individu dengan skor diskriminan di bawah 0 diklasifikasikan sebagai non-diabetes, sedangkan yang di atas 0 diklasifikasikan sebagai diabetes. Karena *centroid* kelompok diabetes bernilai positif, individu dengan skor diskriminan positif cenderung diklasifikasikan sebagai diabetes.

4.4.5 Persamaan Fungsi Diskriminan

Setelah diperoleh variabel terbaik, langkah selanjutnya adalah membentuk fungsi diskriminan menggunakan koefisien kanonik yang dihasilkan. Nilai koefisien untuk masing-masing variabel ditampilkan pada tabel berikut.

Tabel 11. *Canonical Discriminant Function Coefficients*

	Function
	1
Pregnancies	.395
Glucose	.937
BMI	.453
Age	-.432
(Constant)	.000

Berdasarkan hasil analisis, diperoleh persamaan fungsi diskriminan Fisher sebagai berikut:

$$D = 0,395(Pregnancies) + 0,937(Glucose) + 0,453(BMI) - 0,432(Age)$$

Koefisien terbesar terdapat pada variabel *Glucose* (0,937), yang menunjukkan bahwa kadar glukosa darah merupakan variabel paling dominan dalam membedakan individu yang terkena diabetes dan yang tidak. Nilai koefisien positif (*Pregnancies, Glucose*, dan BMI) menunjukkan arah hubungan searah, artinya peningkatan nilai pada variabel-variabel tersebut meningkatkan score diskriminan (D), sehingga individu cenderung diklasifikasikan sebagai diabetes. Sebaliknya, koefisien negatif pada variabel *Age* (-0,432) mengindikasikan bahwa peningkatan usia justru menurunkan score diskriminan, atau dengan kata lain, individu dengan usia lebih tinggi cenderung memiliki kemungkinan lebih kecil untuk diklasifikasikan sebagai diabetes berdasarkan model ini.

Untuk mengklasifikasikan individu, nilai keempat variabel tersebut dimasukkan ke dalam persamaan di atas untuk menghitung score diskriminan (D). Hasil *score* kemudian dibandingkan dengan *cutting score* (0). Individu dengan nilai D di bawah 0 dikategorikan sebagai non-diabetes, sedangkan individu dengan nilai D di atas 0 dikategorikan sebagai diabetes.

4.4.6 Hasil Analisis Klasifikasi

Tahap terakhir dalam analisis diskriminan adalah mengevaluasi kemampuan model dalam mengklasifikasikan individu ke dalam kelompok diabetes dan non-diabetes. Hasil pengelompokan berdasarkan fungsi diskriminan disajikan pada tabel berikut.

Tabel 12. *Classification Result*

			Predicted Group Membership		
		target_diabetes	**0**	**1**	**Total**
Original	Count	0	85	15	100
		1	22	78	100
	%	0	85.0	15.0	100.0
		1	22.0	78.0	100.0
Akurasi					81,5

Matriks klasifikasi menunjukkan hasil klasifikasi model diskriminan terhadap data individu dengan dan tanpa diabetes. Berdasarkan hasil tersebut, model memiliki kemampuan yang baik dalam mengelompokkan kedua kelompok secara akurat.

Untuk kelompok Non-Diabetes (0), dari 100 subjek yang sebenarnya tidak menderita diabetes, sebanyak 85 subjek (85,0%) berhasil diklasifikasikan dengan benar sebagai non-diabetes, sedangkan 15 subjek (15,0%) salah diklasifikasikan sebagai diabetes. Sementara itu, pada kelompok Diabetes (1), dari 100 subjek yang sebenarnya menderita diabetes, model mampu mengklasifikasikan 78 subjek (78,0%) secara benar sebagai diabetes dan 22 subjek (22,0%) salah diidentifikasi sebagai non-diabetes.

Secara keseluruhan, model diskriminan berhasil mengklasifikasikan 81,5% dari kasus asli (*original grouped cases*) dengan benar. Nilai ini menunjukkan tingkat akurasi keseluruhan model sebesar 81,5%, yang berarti fungsi diskriminan mampu memisahkan individu berdasarkan status diabetesnya dengan tingkat ketepatan yang tinggi.

Nilai spesifisitas sebesar 85,0% menunjukkan bahwa model cukup efektif dalam mengenali individu non-diabetes, sedangkan sensitivitas sebesar 78,0% menunjukkan bahwa sebagian besar individu diabetes berhasil diidentifikasi dengan benar oleh model. Meskipun masih terdapat misklasifikasi sebesar 15% pada kelompok non-diabetes dan 22% pada kelompok diabetes, hasil ini tetap mencerminkan kinerja model yang baik dan seimbang dalam mendeteksi kedua kelompok. Hasil ini menunjukkan bahwa fungsi diskriminan yang terbentuk memiliki kemampuan klasifikasi yang baik dan dapat diandalkan untuk memprediksi status diabetes berdasarkan keempat variabel prediktor tersebut.

5. Kesimpulan

5.1 Kesimpulan

Berdasarkan hasil analisis diskriminan yang telah dilakukan pada *Pima Indians Diabetes Dataset*, dapat disimpulkan bahwa metode *Linear Discriminant Analysis* (LDA) berhasil diaplikasikan untuk mengklasifikasikan status diabetes pada wanita keturunan *Pima Indian.* Hasil uji asumsi menunjukkan bahwa data memenuhi persyaratan normalitas multivariat, homogenitas matriks kovarians, dan tidak terdapat masalah multikolinearitas, sehingga analisis diskriminan dapat dilakukan dengan hasil yang valid.

Temuan utama analisis ini menunjukkan bahwa dari delapan variabel prediktor yang dianalisis, tujuh variabel menunjukkan perbedaan signifikan antara kelompok diabetes dan non-diabetes, sementara variabel *SkinThickness* tidak signifikan dalam membedakan kedua kelompok. Melalui proses seleksi variabel *stepwise*, teridentifikasi empat variabel yang paling dominan dalam membedakan status diabetes, yaitu *Glucose, Age*, BMI, dan *Pregnancies*. Variabel *Glucose* teridentifikasi sebagai prediktor terkuat dengan koefisien diskriminan tertinggi (0,937), yang konsisten dengan pengetahuan medis bahwa kadar glukosa darah merupakan indikator utama dalam diagnosis diabetes.

Fungsi diskriminan optimal yang terbentuk menghasilkan persamaan $D = 0,395(Pregnancies) + 0,937(Glucose) + 0,453(BMI) - 0,432(Age)$ dengan *cutting score* 0. Model ini menunjukkan performa klasifikasi yang mengesankan dengan akurasi keseluruhan mencapai 81,5%, spesifisitas 85,0%, dan sensitivitas 78,0%. Tingkat akurasi yang tinggi ini menunjukkan bahwa model tidak hanya efektif dalam mengklasifikasikan pasien, tetapi juga memiliki keseimbangan yang baik antara kemampuan mendeteksi pasien diabetes dan non-diabetes.

5.2 Saran

Berdasarkan temuan penelitian ini, beberapa rekomendasi dapat diajukan untuk pengembangan lebih lanjut. Pertama, disarankan untuk mengeksplorasi teknik machine learning lain seperti Quadratic Discriminant Analysis (QDA), Support Vector Machine (SVM) untuk membandingkan dan mungkin meningkatkan performa klasifikasi. Kedua, perlu dilakukan penanganan yang lebih komprehensif terhadap nilai-nilai yang tidak logis dalam dataset, khususnya pada variabel medis seperti Insulin dan BloodPressure yang mengandung nilai nol yang secara klinis tidak mungkin, dengan menggunakan metode imputasi yang lebih canggih. Ketiga, model yang dihasilkan perlu divalidasi menggunakan dataset eksternal atau melalui teknik cross-validation yang lebih ketat untuk memastikan kemampuan generalisasinya pada populasi yang lebih beragam. Keempat, untuk penyempurnaan model prediksi diabetes di masa depan, disarankan untuk mengintegrasikan variabel-variabel lain seperti pola makan, aktivitas fisik, riwayat keluarga, dan faktor gaya hidup lainnya yang diketahui berpengaruh terhadap risiko diabetes.

Daftar Pustaka

Tobias, S., & Carlson, J. E. (1969). Brief Report: Bartlett's Test of Sphericity and Chance Findings in Factor Analysis. *Multivariate Behavioral Research*, *4*(3), 375–377. https://doi.org/10.1207/s15327906mbr0403_8

Todorov, V., & Filzmoser, P. (2010). Robust statistic for the one-way MANOVA. *Computational Statistics & Data Analysis*, *54*(1), 37–48. https://doi.org/10.1016/j.csda.2009.08.015

Zwick, R. (1985). Nonparametric one-way multivariate analysis of variance: A computational approach based on the Pillai-Bartlett trace. *Psychological Bulletin*, *97*(1), 148–152. https://doi.org/10.1037/0033-2909.97.1.148

Maniruzzaman, M., Rahman, M. J., Ahammed, B., & Abedin, M. M. (2020). Classification and prediction of diabetes disease using machine learning paradigm. Health Information Science and Systems, 8, Article 7. https://doi.org/10.1007/s13755-019-0095-z

Tasin, I., Nabil, T. U., Islam, S., & Khan, R. (2022). Diabetes prediction using machine learning and explainable AI techniques. Healthcare Technology Letters. [Open access] https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10107388/

Chang, V., Sun, Z., & Xu, Q. (2022). Pima Indians diabetes mellitus classification based on machine learning algorithms. Applied Sciences / PMC article (example article). https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8943493/

Butt, U. M., Ahmad, M., & Khan, S. (2021). Machine learning based diabetes classification and prediction. International Journal of Advanced Computer Science and Applications / Scientific Reports style — see Wiley/MDPI summary: https://doi.org/10.1155/2021/9930985

Li, W., et al. (2024). Diabetes prediction model based on GA-XGBoost ensemble and interpretability (SHAP). PLOS ONE. https://doi.org/10.1371/journal.pone.0311222

Gündoğdu, S. (2023). Efficient prediction of early-stage diabetes using XGBoost with feature selection. Multimedia Tools and Applications. https://doi.org/10.1007/s11042-023-15165-8

Kaliappan, J., et al. (2024). Analyzing classification and feature selection strategies for diabetes prediction. Frontiers in Artificial Intelligence. https://doi.org/10.3389/frai.2024.1421751

Alhussan, A. A., Alhussan, A. N., & Alhussan, E. (2023). Classification of diabetes using feature selection and hybrid metaheuristic optimization. Scientific Reports / PMC article. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10297693/

Hajian-Tilaki, K. (2013). Receiver Operating Characteristic (ROC) curve analysis for medical diagnostic test evaluation. Caspian Journal of Internal Medicine / PMC review. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3755824/

Kim, J. H. (2019). Multicollinearity and misleading statistical results: diagnosis and remedies. Journal of Korean Medical Science / PMC review. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6900425/

Ebner, B., et al. (2020). Tests for multivariate normality — a critical review with emphasis on weighted L2-statistics (arXiv / preprint). https://arxiv.org/abs/2004.07332

Sisodia, D., & Sisodia, D. S. (2018). Prediction of diabetes using classification algorithms. Procedia Computer Science, 132, 1578–1585. https://doi.org/10.1016/j.procs.2018.05.122

Wang, X., Zhai, M., Ren, Z., Ren, H., Li, M., Quan, D., Chen, L., & Qiu, L. (2021). Exploratory study on classification of diabetes mellitus through a combined random forest classifier. BMC Medical Informatics and Decision Making, 21, Article 105. https://doi.org/10.1186/s12911-021-01471-4

Torkey, H., Ibrahim, E., Hemdan, E. E.-D., El-Sayed, A., & Shouman, M. A. (2022). Diabetes classification with efficient missing/outlier handling algorithms. Complex & Intelligent Systems. https://doi.org/10.1007/s40747-021-00349-2

Sadeghi, S., Khalili, D., Ramezankhani, A., Mansournia, M. A., & Parsaeian, M. (2022). Diabetes risk prediction in the presence of class imbalance using flexible machine learning methods. BMC Medical Informatics and Decision Making, 22, Article 36. https://doi.org/10.1186/s12911-022-01775-z

Lampiran

Lampiran 1. Data

a. link dataset : https://drive.google.com/drive/folders/1REg_opBQ7J_iMjKOSYGVf0zOdoRwLRbY?usp=sharing
b. link *platform website* data : https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database

Lampiran 2. Preprocessing, Statistika deskriptif, EDA
link *code* dan output :
https://drive.google.com/drive/folders/1KtEER1OXooK_Auu2GTK2axxyyBtRHQFK?usp=sharing