IDENTIFIKASI FAKTOR PEMBEDA SIGNIFIKAN PADA PENDERITA DIABETES MELITUS PIMA INDIANS MENGGUNAKAN ANALISIS DISKRIMINAN

Tugas Kelompok 4 - Multivariat SD A1

KELOMPOK 10

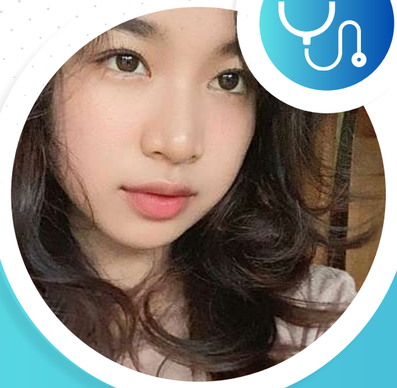

Ratu Aphrodite Cinta Aurora

Yasika Widiyastuti

Faiz Iqbal I'tishom

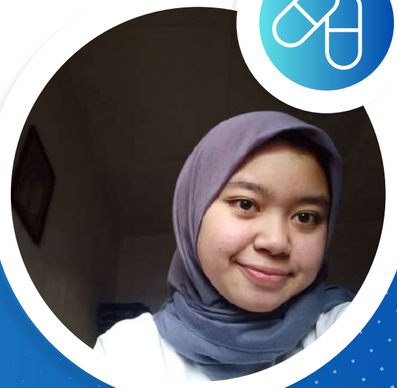

Anelia Ika Shafiyah

LATAR BELAKANG

1

Diabetes mellitus adalah tantangan kesehatan global yang signifikan.

2

Penelitian ini bertujuan untuk membuat model klasifikasi yang akurat untuk status diabetes (positif/negatif).

3

Deteksi dini sangat penting untuk mencegah komplikasi.

METODE DAN DATA

Metode

Analisis Diskriminan Linear (LDA)

Dataset

Pima Indians Dataset (*Source*: Kaggle)

Subjek

Wanita keturunan Pima Indian (usia 21 tahun ke atas).

Variabel yang Digunakan

Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin, BMI, DiabetesPedigreeFunction, dan Age.

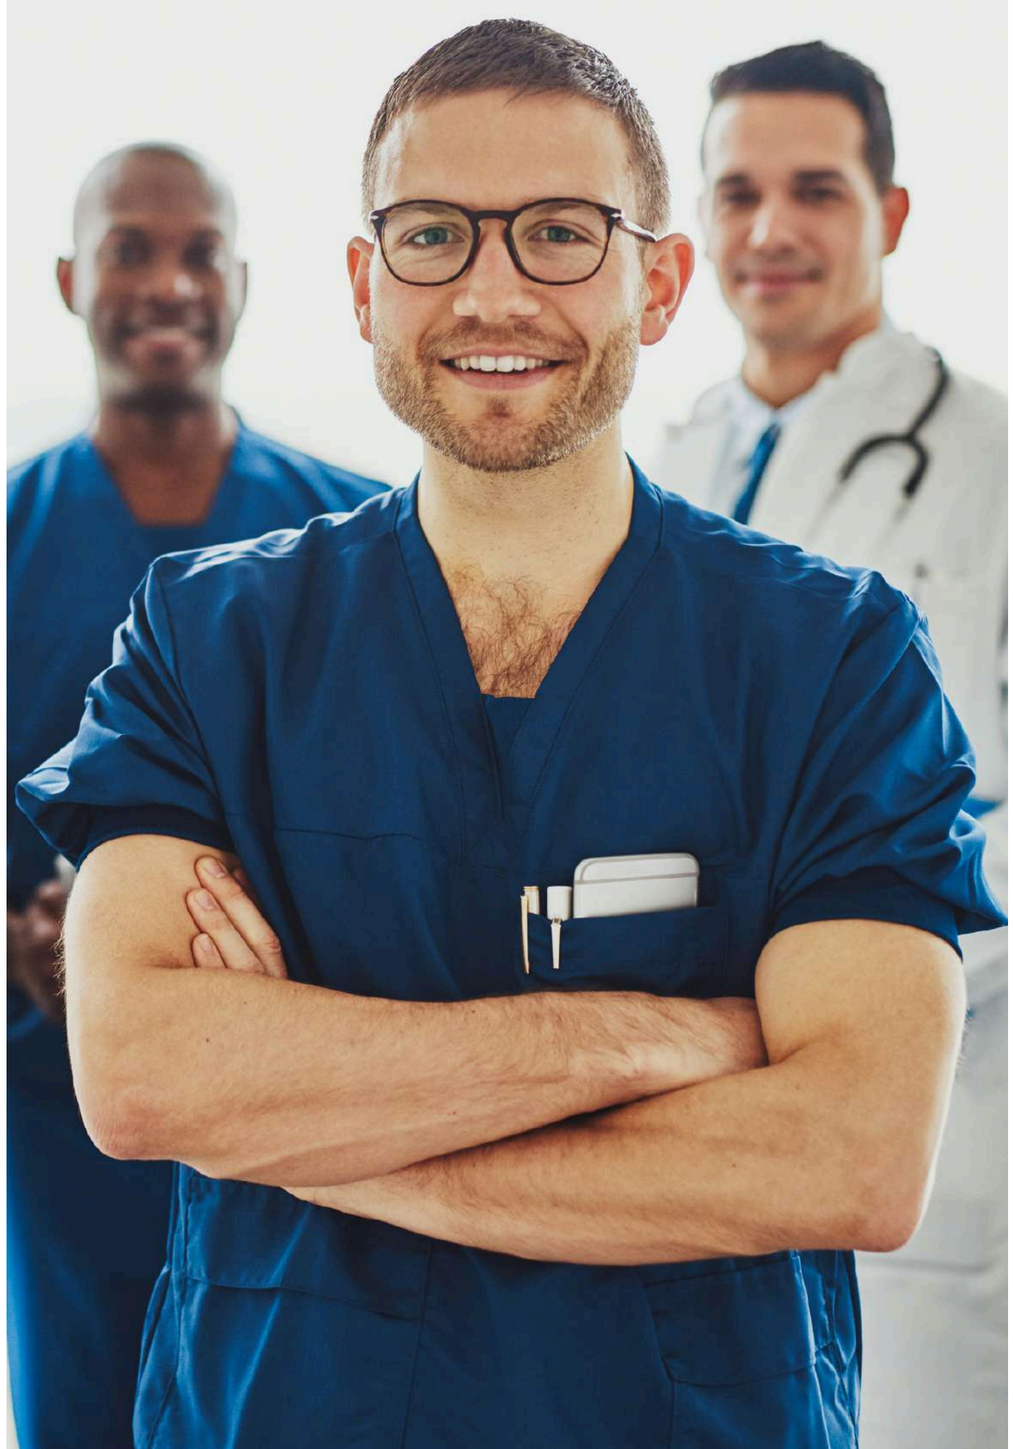

SYARAT ASUMSI

Analisis Dskriminan ini perlu untuk setidaknya memenuhi uji-uji asumsi sebagai berikut

Normalitas

Homogenitas

Outlier

Multikolinearitas

SUMBER DATA & METODOLOGI

Dataset: Pima Indians Diabetes Dataset
Sumber: National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK), USA melalui UCI Machine Learning Repository

Tabel 1. Variabel Penelitian

Variabel	Nama Variabel	Keterangan
X1	*Pregnancies*	Jumlah Kehamilan yang pernah dialami
X2	*Glucose*	Kadar glukosa
X3	*BloodPressure*	Tekanan darah diastolik
X4	*SkinThickness*	Ketebalan lipatan kulit
X5	Insulin	Konsentrasi insulin serum
X6	BMI	Indeks massa tubuh yang dihitung dari berat dan tinggi
X7	*DiabetesPedigreeFunction*	Indeks riwayar keluarga dan risiko genetik terhadap diabets
X8	*Age*	Usia responden
Y	*target_diabetes*	Kelas target yang menunjukkan status diabetes (1 = positif, 0 = negatif)

Karakteristik Data

- Jumlah data: 768 observasi
- Responden: Perempuan keturunan Indian Pima, usia ≥ 21 tahun
- Jenis data: Data sekunder (publik)
- Variabel: 8 independen + 1 dependen (Outcome)

Metodologi

1. Penentuan Sampel dan resampling.
2. Preprocessing dan EDA: Cek missing values, outlier, dan visualisasi persebaran
3. Uji Asumsi : Uji normalitas, homogenitas (Box's M), dan multikolinearitas.
4. Pemilihan Variabel : Metode stepwise untuk pilih variabel signifikan.
5. Pembentukan Fungsi Diskriminan : Menentukan koefisien variabel pemisah antar kelompok.
6. Evaluasi Model: Menggunakan cutting score dan classification result untuk ukur akurasi.
7. Interpretasi & Kesimpulan

STATISIKA DESKRIPTIF

- Semua variabel bertipe numerik
- Tidak ada missing value asli
- Namun terdapat nilai tidak logis (0) pada variabel : Glucose, BloodPressure, SkinThickness, Insulin, BMI
- Nilai 0 dianggap sebagai data hilang, lalu diimputasi menggunakan nilai median

Tabel 2. Statistika Deskriptif Tiap Variabel

Nama Variabel	*Mean*	*Median*	Standar Deviasi	*Min*	*Max*
Pregnancies	3,85	3	3,37	0	17
Glucose	121,66	117	30,44	44	199
BloodPressure	72,39	72	12,1	24	122
SkinThickness	29,11	29	8,79	7	99
Insulin	140,67	125	86,38	14	846
BMI	32,46	32.3	6,88	18,2	67,1
DiabetesPedigreeFunction	0,47	0,37	0,33	0,078	2,42
Age	33,24	29	11,76	21	81
target_diabetes	0,35	0	0,48	0	1

1. Rata-rata kehamilan 4 kali, usia 33 tahun (dewasa).
2. Kadar glukosa 121,66 mg/dL, menunjukkan kecenderungan gula darah tinggi.
3. Tekanan darah 72,39 mmHg → masih dalam batas normal.
4. BMI 32,46 → menunjukkan kecenderungan obesitas ringan.
5. Insulin 140,67 → sebaran tinggi antar responden.
6. Risiko genetik (DPF) 0,47 → kategori sedang.
7. Status diabetes: 35% positif, 65% negatif → dilakukan resampling agar seimbang dengan slovin

EDA

histogram

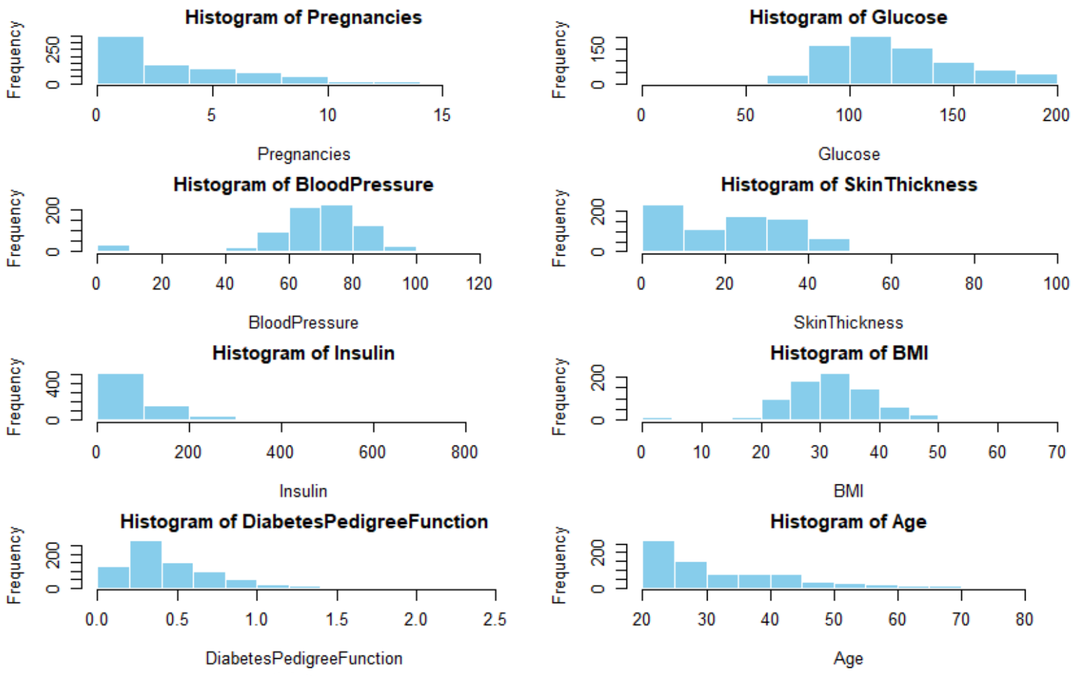

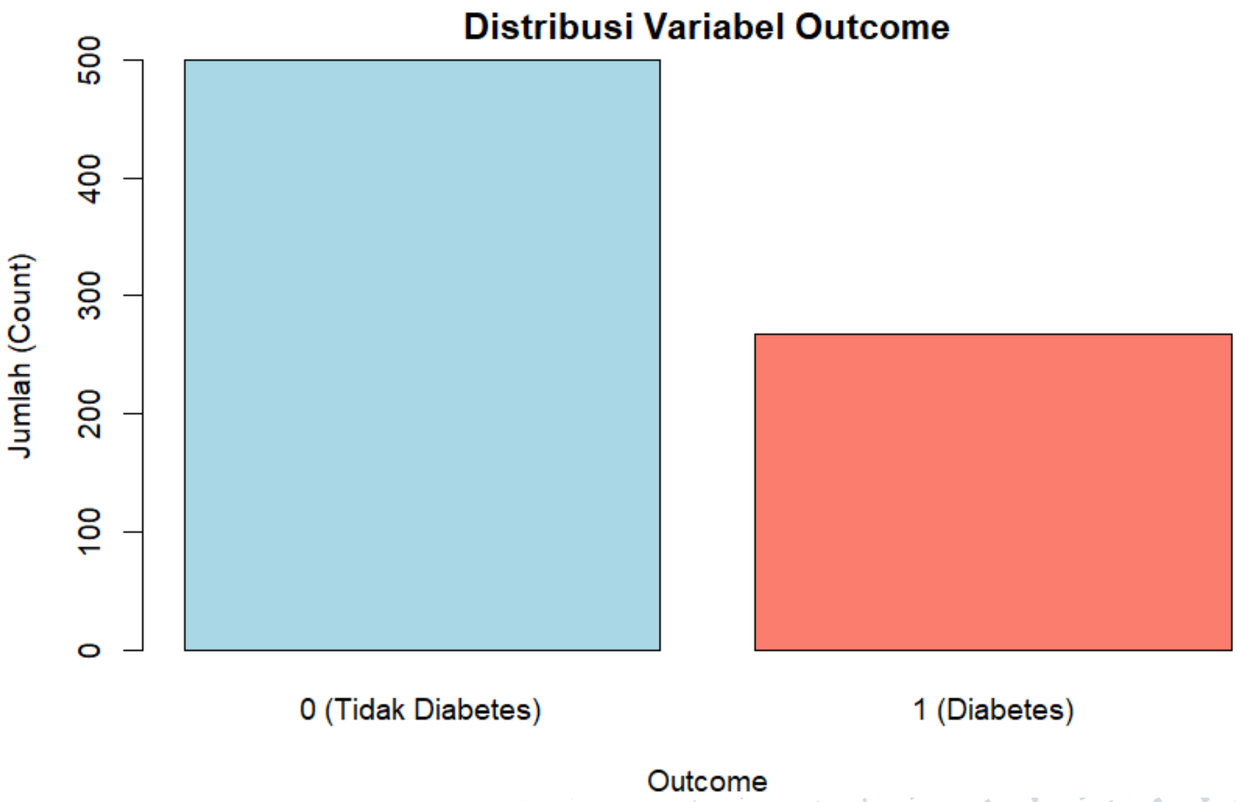

Sebagian besar variabel seperti Glucose, BloodPressure, dan BMI memiliki distribusi yang relatif normal, menandakan penyebaran data yang seimbang di sekitar nilai tengah. Namun, variabel Pregnancies, SkinThickness, Insulin, DiabetesPedigreeFunction, dan Age menunjukkan skewness ke kanan, di mana sebagian besar nilai terkonsentrasi pada rentang rendah dengan sedikit nilai ekstrem di sisi kanan. Hal ini menggambarkan bahwa mayoritas responden memiliki karakteristik umum yang serupa, sementara nilai ekstrem hanya muncul pada sebagian kecil individu.

Variabel Outcome menunjukkan ketidakseimbangan kelas, dengan kelompok tidak diabetes (0) lebih banyak dibandingkan diabetes (1). Karena bersifat kategorik, variabel ini tidak ditransformasi, namun ketidakseimbangan dapat diatasi dengan resampling agar model tidak bias terhadap kelas mayoritas.

UJI ASUMSI

H_0: Data berdistribusi normal
H_1: Data tidak berdistribusi normal

Tabel 3. Asumsi Normalitas

Variable	*Death_Event*	KS	SW
Pregnancies	0	,200	,621
	1	,200	,839
Glucose	0	,200	,395
	1	,200	,015
BloodPressure	0	,200	,188
	1	,200	,069
SkinThickness	0	,200	,074
	1	,174	,193
Insulin	0	,200	,098
	1	,200	,014
BMI	0	,200	,662
	1	,200	,020
DiabetesPedigreeFunction	0	,200	,883
	1	,200	,430
Age	0	,200	,790
	1	,200	,713

Hasil uji normalitas dengan metode Kolmogorov–Smirnov dan Shapiro–Wilk menunjukkan seluruh variabel memiliki nilai signifikansi di atas 0,05. Artinya, data berdistribusi normal pada kedua kelompok target_diabetes, sehingga memenuhi asumsi normalitas dan dapat digunakan untuk analisis lanjutan.

Hasil uji multikolinearitas pada tabel Pooled Within-Groups Matrices menunjukkan bahwa seluruh nilai korelasi antarvariabel independen berada di bawah 0,80. Dengan demikian, tidak terdapat indikasi multikolinearitas, sehingga semua variabel bebas layak digunakan dalam analisis multivariat.

Tabel 5. *Pooled Within-Groups Matrices*

	Pregnancies	*Glucose*	*BloodPressure*	*SkinThickness*	*Insulin*	*BMI*	*DiabetesPedigreeFunction*	*Age*
Pregnancies	1,000							
Glucose	,084	1,000						
BloodPressure	,037	,151	1,000					
SkinThickness	,013	,006	,047	1,000				
Insulin	,089	,490	-,016	-,050	1,000			
BMI	-,184	,058	,193	-,031	,091	1,000		
DiabetesPedigreeFunction	,019	,054	-,030	,117	,022	,126	1,000	
Age	,055	,134	,270	,013	,112	,154	,061	1,000

UJI ASUMSI

Tabel 4 Output. *Box's M*

Box's M	9,184
F	,898
df 1	10
df 2	187429.482
Sig.	,534

Hasil uji Box's M menunjukkan nilai signifikansi sebesar 0,534 (> 0,05), yang berarti tidak terdapat perbedaan signifikan pada matriks kovarians antar kelompok. Dengan demikian, data memenuhi asumsi homogenitas kovarians dan layak untuk analisis lanjutan.

Tabel 6 *Chisquare Crit Number*

Alpha	0,01
df	8
Chisq Crit	26,12

Hasil uji outlier multivariat dengan Jarak Mahalanobis menunjukkan nilai maksimum sebesar 26.1246, sama dengan nilai kritis Chi-square pada taraf signifikansi 0,1%. Karena nilai tersebut tidak melebihi batas kritis, maka data dinyatakan bebas dari outlier multivariat dan memenuhi asumsi normalitas multivariat, sehingga analisis diskriminan dapat dilanjutkan.

ANALISIS DISKRIMINAN

Analisis diskriminan digunakan untuk membedakan antara dua kelompok individu, yaitu kelompok yang tidak terkena diabetes (diberi kode 0) dan kelompok yang terkena diabetes (diberi kode 1), berdasarkan sejumlah variabel prediktor.

1 TEST OF EQUALITY OF GROUP MEANS

untuk mengetahui apakah setiap variabel memiliki perbedaan yang signifikan antara kelompok diabetes dan non-diabetes.

H0: Variabel tidak berpengaruh signifikan dalam pengelompokan.
H1: Variabel berpengaruh signifikan dalam pengelompokan.

Variabel	Sig.
Pregnancies	.000
Glucose	.000
BloodPressure	.031
SkinThickness	.125
Insulin	.000
BMI	.000
DiabetesPedigreeFunction	.006
Age	.007

Pregnancies, Glucose, BloodPressure, Insulin, BMI, DiabetesPedigreeFunction, Age semua Sig. < 0.05, jadi Tolak H0. Sehingga berpengaruh Signifikan dalam membedakan kelompok diabetes dan non-diabetes.

variabel SkinThickness memiliki SIg. 0.125, artinya Gagal Tolak H0, dan Tidak Berpengaruh Signifikan dalam membedakan kelompok.

ANALISIS DISKRIMINAN

2. VARIABLES ENTERED/REMOVED

proses pemilihan variabel dilakukan secara bertahap (stepwise) dengan tujuan memperoleh kombinasi variabel terbaik yang mampu membentuk fungsi diskriminan paling optimal.

Step		Wilks' Lambda							
						Exact F			
	Entered	Statistic	df1	df2	df3	Statistic	df1	df2	Sig.
1	Glucose	.701	1	1	198.000	84.254	1	198.000	.000
2	Age	.664	2	1	198.000	49.762	2	197.000	.000
3	BMI	.628	3	1	198.000	38.682	3	196.000	.000
4	Pregnancies	.593	4	1	198.000	33.499	4	195.000	.000

Proses & Hasil:

- Variabel dimasukkan bertahap (stepwise) berdasarkan kontribusi signifikan (Sig. < 0,05).
- Urutan masuk variabel:
- . Glucose → Wilks' Lambda terendah, kontribusi tertinggi
- . Age → meningkatkan kemampuan diskriminan
- . BMI → memperkuat model
- . Pregnancies → finalisasi model

Kesimpulan:

- Variabel Glucose, Age, BMI, dan Pregnancies membentuk model terbaik.
- Glucose menjadi variabel paling dominan dalam membedakan kelompok diabetes dan non-diabetes.

ANALISIS DISKRIMINAN

3. VARIABLES IN THE ANALYSIS

tujuannya unutk memastikan tidak terjadi multikolinearitas antar variabel dan menilai kontribusi tiap variabel terhadap model.

Step		Tolerance	F to Remove
1	Glucose	1.000	84.254
2	Glucose	.982	88.919
	Age	.982	11.010
3	Glucose	.981	77.748
	Age	.961	13.720
	BMI	.975	11.313
4	Glucose	.973	63.335
	Age	.955	14.780
	BMI	.936	15.275
	Pregnancies	.952	11.648

Dari tabel terlihat bahwa:

- Tolerance mendekati 1,00 artinya tidak ada multikolinearitas.
- F to Remove tinggi, artinya setiap variabel penting untuk dipertahankan.

Kesimpulan:

- Seluruh variabel (Glucose, Age, BMI, Pregnancies) signifikan dan berkontribusi penting.
- Model akhir stabil dan efektif dalam membedakan kelompok diabetes dan non-diabetes.

ANALISIS DISKRIMINAN

4 FUNCTION AT GROUP CENTROID

tujuannya unutk menentukan rata-rata skor diskriminan tiap kelompok dan cutting score untuk klasifikasi.

	Function
target_diabetes	1
0	-.825
1	.825

$$Z_{CU} = \frac{(N_A \times Z_B) + (N_B \times Z_A)}{N_A + N_B}$$

$$Z_{CU} = \frac{(100 \times 0{,}825) + (100 \times (-0{,}825))}{100 + 100}$$

$$Z_{CU} = \frac{(8{,}25) + (-8{,}25))}{200}$$

$$Z_{CU} = \frac{0}{200}$$

$$Z_{CU} = 0$$

Hasil Utama:

- Centroid Non-Diabetes: -0,825
- Centroid Diabetes: 0,825
- Perbedaan tanda dan nilai menunjukkan pemisahan kelompok yang jelas.

Cutting Score:

- Berdasarkan perhitungan, cutting score = 0
- individu dengan skor diskriminan di bawah 0 diklasifikasikan sebagai non-diabetes, sedangkan yang di atas 0 diklasifikasikan sebagai diabetes.

Kesimpulan:

Fungsi diskriminan efektif memisahkan kelompok diabetes dan non-diabetes dengan baik.

ANALISIS DISKRIMINAN

5 PERSAMAAN FUNGSI DISKRIMINAN

Berdasarkan hasil analisis, diperoleh persamaan fungsi diskriminan Fisher sebagai berikut:

$$D = 0,395(Pregnancies) + 0,937(Glucose) + 0,453(BMI) - 0,432(Age)$$

- Glucose (0,937) merupakan variabel paling dominan dalam membedakan diabetes dan non-diabetes.
- Koefisien positif (Pregnancies, Glucose, BMI) menunjukkan bahwa peningkatan nilai meningkatkan skor D, cenderung diklasifikasikan sebagai diabetes.
- Koefisien negatif (Age) artinya peningkatan usia menurunkan skor D, cenderung diklasifikasikan sebagai non-diabetes.

Untuk mengklasifikasikan individu, nilai keempat variabel tersebut dimasukkan ke dalam persamaan di atas untuk menghitung score diskriminan (D). Hasil score kemudian dibandingkan dengan cutting score (0). Individu dengan nilai D di bawah 0 dikategorikan sebagai non-diabetes, sedangkan individu dengan nilai D di atas 0 dikategorikan sebagai diabetes.

ANALISIS DISKRIMINAN

5 PERSAMAAN FUNGSI DISKRIMINAN

Tahap terakhir dalam analisis diskriminan adalah mengevaluasi kemampuan model dalam mengklasifikasikan individu ke dalam kelompok diabetes dan non-diabetes.

			Predicted Group Membership		
		target_diabetes	0	1	Total
Original	Count	0	85	15	100
		1	22	78	100
	%	0	85.0	15.0	100.0
		1	22.0	78.0	100.0
Akurasi					81,5

Matriks klasifikasi menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan kedua kelompok:

- Kelompok Non-Diabetes (0): Dari 100 subjek yang sebenarnya non-diabetes, 85 subjek (85,0%) diklasifikasikan dengan benar, sedangkan 15 subjek (15,0%) salah diklasifikasikan sebagai diabetes.
- Kelompok Diabetes (1): Dari 100 subjek yang sebenarnya diabetes, 78 subjek (78,0%) diklasifikasikan dengan benar, sedangkan 22 subjek (22,0%) salah diklasifikasikan sebagai non-diabetes.
- Secara keseluruhan, model berhasil mengklasifikasikan 81,5% dari kasus asli dengan benar, menunjukkan tingkat akurasi yang tinggi. Nilai spesifisitas sebesar 85,0% menandakan model efektif dalam mengenali individu non-diabetes, sedangkan sensitivitas sebesar 78,0% menunjukkan sebagian besar individu diabetes berhasil diidentifikasi.
- Meskipun terdapat sedikit misklasifikasi(15% pada non-diabetes dan 22% pada diabetes), model tetap menunjukkan kinerja baik dan dapat diandalkan untuk memprediksi status diabetes

KESIMPULAN

Analisis diskriminan Linear Discriminant Analysis (LDA) berhasil digunakan untuk mengklasifikasikan status diabetes pada wanita Pima Indian. Data memenuhi asumsi normalitas multivariat, homogenitas matriks kovarians, dan bebas multikolinearitas, sehingga hasil analisis valid. Dari delapan variabel prediktor, tujuh menunjukkan perbedaan signifikan antara kelompok diabetes dan non-diabetes. Empat variabel paling dominan adalah Glucose, Age, BMI, dan Pregnancies, dengan Glucose menjadi prediktor terkuat. Fungsi diskriminan yang terbentuk mampu membedakan status diabetes secara efektif dengan akurasi, spesifisitas, dan sensitivitas yang baik.

Untuk pengembangan lebih lanjut, disarankan mengeksplorasi metode machine learning lain seperti QDA atau SVM, menangani nilai nol pada variabel medis dengan imputasi canggih, memvalidasi model pada dataset eksternal atau melalui cross-validation, serta menambahkan variabel risiko lain seperti pola makan, aktivitas fisik, dan faktor gaya hidup untuk meningkatkan kemampuan prediksi.

1

2

3